

باسمه تعالی

پایان نامه کارشناسی ارشد

عنوان: بررسی، ارزیابی و تحلیل کاربردهای رویکرد مبتنی بر خوشه‌بندی معنایی
متون چند زبانه جهت پاسخگویی به سوالات در محیط‌های با دامنه بسته

**Investigating, evaluating, and analyzing the applications of
semantic folding approach for multilingual texts questions
answering in closed domain environments**

نگارنده: وحید مرادی سرکشتی – استاد راهنما: دکتر مسعود رهگذر دانشکده
مهندسی برق و کامپیوتر، پردیس دانشکدگان فنی، دانشگاه تهران پروپوزال
مصوب: ۳۱/۰۶/۱۴۰۳

با افزایش حجم متون دیجیتال و گسترش منابع چندزبانه، بازیابی اطلاعات مرتبط و پاسخ‌گویی دقیق به پرسش‌ها، به‌ویژه در محیط‌های دامنه‌بسته، از مسائل مهم در حوزه پردازش زبان طبیعی و بازیابی اطلاعات محسوب می‌شود. هدف این پژوهش، بررسی، ارزیابی و تحلیل کاربردهای رویکرد مبتنی بر **Semantic Folding** متون چندزبانه در بازیابی و پاسخ‌گویی به پرسش‌ها در محیط‌های دامنه‌بسته است.

در این پژوهش، متون ابتدا با استفاده از روش‌های استخراج عبارت پردازش شده و ماتریس واژه-مفهوم مبتنی بر وزن‌دهی TF-IDF ایجاد می‌شود. سپس با استفاده از روش کاهش ابعاد UMAP، روابط معنایی عبارات به یک فضای دوبعدی نگاشت و بر روی ماتریسی 64×64 قرار داده می‌شوند. بر اساس این فضا، برای هر عبارت یک **اثرانگشت معنایی** دارد؛ با تجمیع اثرانگشت‌های عبارات، برای هر سند یک **اثرانگشت معنایی** ایجاد می‌شود. در مرحله بازیابی، پرسش نیز به اثرانگشت تبدیل شده و با استفاده از گسترش مکانی و محاسبه شباهت کسینوسی، اسناد مرتبط رتبه‌بندی می‌شوند. همچنین امکان ترکیب نتایج خوشه‌بندی معنایی با مدل تنک بازیابی SPLADE با استفاده از روش‌های Linear و RRF^2 بررسی می‌شود.

برای ارزیابی روش پیشنهادی، یک چارچوب^۳ مستقل طراحی شده است که عملکرد سیستم را با معیارهای **MAP**، **MRR** و **NDCG** ارزیابی می‌کند. در نهایت، نتایج ارزیابی‌ها برای بررسی توانایی خوشه‌بندی معنایی در نمایش فضایی و بازیابی متون چندزبانه و همچنین تاثیر ترکیب آن با روش‌های بازیابی عصبی تحلیل می‌شوند.

^۱ . Abstract

^۲ . Reciprocal Rank Fusion

^۳ . benchmark

کلمات کلیدی: خوشه‌بندی معنایی، بازیابی اطلاعات، پاسخ‌گویی به پرسش، دامنه‌بسته، بازیابی متون چندزبانه، نقشه و فضای معنایی، ادغام خطی و ادغام رتبه متقابل با SPLADE.

فهرست شکل‌ها

شماره	عنوان	بخش
شکل ۱-۳	نقشه‌راه هشت مرحله‌ای پژوهش	۳-۱
شکل ۲-۳	معماری خط لوله پیاده‌سازی شده	۳-۱
شکل ۳-۳	نقشه معنایی UMAP پیکره دوزبانه (۴۸۸ مفهوم)	۳-۵
شکل ۴-۳	اثرانگشت دوبعدی دو سند نمونه (شبکه ۶۴×۶۴)	۳-۶
شکل ۱-۴	مقایسه بهترین SF با ۲۵BM روی ۱۳ بنچمارک (MRR)	۴-۴
شکل ۲-۴	جاروب وزن فیوژن خطی SPLADE روی Belebele	۴-۵-۱
شکل ۳-۴	نمودار ablation واریانت‌های پارامتری بر حسب AP	۴-۵-۲

فایل تصاویر: docs/thesis/fa/figures/*.png – تولیدشده با scripts/make_thesis_figures.py.

فهرست جداول

شماره	عنوان	بخش
جدول ۱-۲	مقایسه کیفی روش‌های تعبیه کلمات با خوشه‌بندی معنایی	۲-۳-۴
جدول ۱-۳	نگاشت نقشه‌راه پروپوزال بر پیاده‌سازی	۳-۱
جدول ۱-۴	مجموعه داده‌های ارزیابی	۴-۲
جدول ۲-۴	بهترین نتیجه هر بنچمارک در برابر ۲۵BM	۴-۴
جدول ۳-۴	آزمون معناداری آماری custom_ar_en	۴-۴-۱
جدول ۴-۴	آزمون شبکه واژگان (v1/v WordNet)	۴-۴-۳
جدول ۵-۴	ablation سهم اجزا (پیکره QA-sample)	۴-۵-۲
جدول ۶-۴	سایر یافته‌های پارامتری	۴-۵-۳
جدول ۷-۴	خط مبنای تراکمی MiniLM روی SciFact	۴-۷-۱
جدول ۸-۴	MRR خط مبنای E5-multi در برابر بهترین SF و ۲۵BM	۴-۷-۱

۴-۷-۲

مقایسه ادبی با مدل‌های تعبیه کلمات

جدول ۹-۴

پیوست

مرجع پارامترهای خط لوله

جدول ۱-A

A

فصل ۱: کلیات پژوهش

۱-۱. مقدمه

در سال‌های اخیر، رشد سریع حجم اطلاعات متنی و گسترش منابع دیجیتال، نیاز به روش‌های کارآمد برای دسترسی، بازیابی و استخراج اطلاعات مرتبط از میان مجموعه‌های بزرگ متنی را افزایش داده است. در این میان، بازیابی اطلاعات (Information Retrieval) و پاسخ‌گویی به سوالات (Question Answering) از حوزه‌های مهم پردازش زبان طبیعی به شمار می‌روند. هدف سامانه‌های بازیابی اطلاعات، شناسایی و رتبه‌بندی اسنادی است که بیشترین ارتباط را با نیاز اطلاعاتی کاربر دارند، در حالی که سامانه‌های پاسخ‌گویی به سوالات تلاش می‌کنند اطلاعات مورد نیاز را در پاسخ به یک پرسش مشخص از میان منابع موجود استخراج یا تولید کنند.

با وجود پیشرفت روش‌های مبتنی بر یادگیری عمیق و مدل‌های زبانی، بازیابی اطلاعات در مجموعه‌های چندزبانه همچنان با چالش‌هایی از جمله تفاوت ساختار زبان‌ها، تنوع واژگانی، تفاوت‌های نحوی و دشواری ایجاد نمایش معنایی مشترک مواجه است. این چالش در محیط‌های دامنه‌بسته (Closed-Domain) اهمیت بیشتری پیدا می‌کند؛ زیرا سامانه باید بتواند از میان مجموعه‌ای مشخص از اسناد، اطلاعات مرتبط با پرسش را با دقت مناسبی شناسایی کند.


یکی از رویکردهایی که می‌تواند برای ایجاد نمایش متفاوتی از اطلاعات متنی مورد بررسی قرار گیرد، خوشه‌بندی معنایی (Semantic Folding) است. در این رویکرد، اطلاعات معنایی موجود در متن به یک فضای معنایی [۱] ساختاریافته و قابل نمایش نگاشت می‌شود و روابط میان واحدهای متنی بر اساس موقعیت آن‌ها در این فضا مورد استفاده قرار می‌گیرد. ایده اصلی پژوهش حاضر، بررسی قابلیت استفاده از چنین نمایش فضایی برای بازیابی متون چندزبانه و ارزیابی عملکرد آن در یک چارچوب قابل تکرار است.

در این پژوهش، یک pipeline مبتنی بر Semantic Folding طراحی و پیاده‌سازی شده است که طی آن عبارات متنی استخراج شده، روابط context میان آن‌ها محاسبه و به یک فضای معنایی دوبعدی نگاشت می‌شوند. سپس برای عبارات و اسناد، fingerprintهای فضایی ایجاد شده و از آن‌ها برای مقایسه پرسش با اسناد استفاده می‌شود. در ادامه، عملکرد این رویکرد به صورت تجربی ارزیابی شده و امکان ترکیب آن با روش‌های نوین بازیابی sparse، از جمله SPLADE، نیز مورد بررسی قرار می‌گیرد.

۲-۱. ضرورت و اهمیت موضوع تحقیق

با رشد حجم محتوای دیجیتال چندزبانه و افزایش نیاز کاربران به دسترسی به اطلاعات فارغ از زبان تولید آن، توسعه روش‌های بازیابی اطلاعات که بتوانند با دقت مناسبی در میان زبان‌های مختلف عمل کنند، به یک نیاز کاربردی و پژوهشی مهم تبدیل شده است. این نیاز به‌ویژه در محیط‌های دامنه‌بسته—مانند سامانه‌های پرسش‌وپاسخ سازمانی، آرشیوهای تخصصی، یا سامانه‌های پشتیبانی چندزبانه—محسوس‌تر است؛ زیرا در این محیط‌ها امکان اتکا به حجم عظیم داده‌های آموزشی که در بازیابی دامنه‌باز در دسترس است، وجود ندارد.

پیشنهاد یک روش کارآمد از لحاظ مصرف منابع و زمان لازم (شکل ۱) و در مواقعی که داده‌های زیادی در دست نیست، به لحاظ اینکه در سایر روش‌های پاسخگویی به سوالات نیاز به وجود منابع پردازشی قدرتمند و یا داده‌های خیلی زیاد به شدت احساس می‌شود [۵] از ضرورت‌هایی است که نمی‌توان از آنها چشم‌پوشی کرد.



شکل ۱. مقایسه مصرف انرژی و سرعت روش خوشه‌بندی معنایی و [36] BERT

یکی دیگر از ویژگی‌های روش خوشه‌بندی معنایی که موجب انگیزه مضاعفی برای بررسی، ارزیابی و تحلیل آن شد، امکان یادگیری بدون ناظر^۴ آن است، که منجر به کاهش هزینه‌های مادی و زمانی برچسب‌گذاری داده‌ها می‌شود [۱۶].

روش‌های واژگانی کلاسیک مانند BM25 با وجود کارایی و سادگی، در مواجهه با عدم تطابق واژگانی (Vocabulary Mismatch) میان زبان‌ها با محدودیت جدی روبه‌رو هستند. از سوی دیگر، روش‌های dense retrieval که با بردارهای متراکم کار می‌کنند، معمولاً نیازمند حجم زیادی داده‌ی آموزشی چندزبانه و منابع محاسباتی بالا هستند و تفسیرپذیری کمی دارند [۶۱]. این شکاف میان کارایی و تفسیرپذیری، ضرورت بررسی رویکردهای جایگزین را توجیه می‌کند.

^۴ Unsupervised learning .

خوشه‌بندی معنایی رویکردی است که به‌جای بازنمایی متن صرفاً به‌صورت یک بردار متراکم غیرقابل تفسیر، اطلاعات معنایی را در یک فضای توپولوژیک قابل مشاهده نگاشت می‌کند [۱۳]. با وجود پیشینه نظری این روش، تاکنون کاربرد آن در مسئله بازیابی اطلاعات چندزبانه دامنه‌بسته و ترکیب آن با روش‌های بازیابی sparse عصبی نوین مانند SPLADE به‌صورت تجربی و با چارچوب ارزیابی استاندارد بررسی نشده است [۳۸]. این پژوهش با هدف پر کردن همین خلأ نیز انجام شده است.

از منظر کاربردی نیز، نتایج این پژوهش می‌تواند برای سامانه‌هایی که نیازمند بازیابی اطلاعات دقیق و قابل‌تفسیر در محیط‌های چندزبانه با منابع محدود هستند (مانند بایگانی‌های حقوقی یا سلامت چندزبانه) کاربرد داشته باشد، چراکه نمایش فضایی اثرانگشت می‌تواند نسبت به بردارهای dense معمول، شفافیت بیشتری در تحلیل نتایج فراهم کند.

سامانه‌های زیادی برای پاسخگویی خودکار به سوالات کاربر بر اساس روش‌های مختلف همچون یادگیری ماشین و پردازش متن ساخته شده‌اند [۹]. با وجود تاریخچه طولانی این موضوع و پیشرفت‌های اخیر که در این حوزه به کمک یادگیری عمیق و شبکه‌های عصبی مبتنی بر گراف انجام شده است [۱۷]، اما همچنان چالش‌هایی در این حوزه وجود دارند که عبارت‌اند از:

۱. **نگاشت چندزبانه:** تشکیل یک نقشه معنایی واحد که واژگان زبان‌های مختلف را حول مفاهیم مشترک بچیند؛ بازیابی cross-lingual محض (پرسش عربی، سند انگلیسی بدون متن موازی) تقریباً ناممکن است و باید با پیکره‌های موازی دوزبانه حل شود.

۲. **نبود مبنای ارزیابی استاندارد:** تا انتشار مبنای ارزیابی کای^۰ و همکاران (۲۰۲۴) هیچ benchmark جامعی برای روش‌های مبتنی بر خوشه‌بندی معنایی وجود

نداشت[۱۶]؛ در این پژوهش از پروتکل بازیابی استاندارد (MRR/AP/NDCG) IR در برابر (۲۵BM) استفاده شده است.

۳. **تنظیم پارامترها:** ابعاد نقشه معنایی، درصد تنک‌سازی و میزان انتشار باید تعادل میان تمایزپذیری و پوشش را حفظ کنند؛ ابعاد خیلی کم یا خیلی زیاد دقت را می‌کاهند.

۴. **واژگان خارج از پیکره (OOV):** واژه‌ای که در پیکره نباشد اثرانگشت تهی دارد؛ مرحله «شبکه واژگان»^۱ در فصل ۳ برای رفع آن ارائه شده است.

۳-۱. بیان و تعریف مسئله تحقیق

با وجود پیشرفت‌های قابل توجه در روش‌های بازیابی اطلاعات، دستیابی به نمایش مناسبی از محتوای معنایی اسناد و پرسش‌ها همچنان یکی از مسائل اساسی این حوزه است. روش‌های مبتنی بر تطبیق واژگان، در مواجهه با تفاوت‌های واژگانی و بیان یک مفهوم با کلمات متفاوت، ممکن است نتوانند ارتباط معنایی میان پرسش و سند را به‌خوبی شناسایی کنند. از سوی دیگر، بسیاری از روش‌های dense retrieval متن را در قالب بردارهای با ابعاد بالا نمایش می‌دهند که اگرچه قابلیت مناسبی برای اندازه‌گیری شباهت معنایی دارند، تفسیر ساختار فضایی این نمایش‌ها و بررسی نحوه شکل‌گیری ارتباط میان واحدهای متنی همواره ساده نیست.

تاکنون روش‌های گوناگونی برای پاسخگویی به سوالات ایجاد و توسعه داده شده است[۳]. با رشد استفاده از متون چندزبانه، نیاز به رویکردهای کارآمدتر برای پردازش و استخراج اطلاعات در محیط‌های تخصصی احساس می‌شود[۸]. استفاده از شبکه‌های عصبی و یادگیری عمیق دقت سامانه‌های پاسخگویی خودکار به سوالات را بسیار بالا برده است که این امر جز با استفاده از منابع پردازشی زیاد میسر نخواهد بود[۹]. از طرفی دقت این

^۱ Word net

سامانه‌ها، کاملاً وابسته به حجم و کیفیت داده‌های ورودی است اما مغز انسان با سرعت بالاتر و حجم داده بسیار کمتری قادر به پاسخگویی لحظه‌ای به سوالات است [۱۰]، [۱۱] که همین موضوع باعث شده مبحث علوم شناختی که براساس رهیافت مغز انسان در شناخت مفاهیم کار می‌کند توجهات زیادی را به خود جلب کند [۱۲]. روش خوشه‌بندی معنایی یکی از این رهیافت‌ها است که با هدف رسیدن به سرعت و دقت بالا در پردازش و درک متن توسط محققین توسعه یافته است [۱۳].

موضوع این پژوهش، بررسی، ارزیابی و تحلیل کاربرد رویکرد مبتنی بر خوشه‌بندی معنایی متون چند زبانه برای بازیابی و پاسخگویی به سوالات در محیط‌های دامنه‌بسته است.

در این پژوهش، Semantic Folding به‌عنوان یک رویکرد برای تبدیل اطلاعات متنی به یک نمایش فضایی مورد استفاده قرار می‌گیرد. ابتدا واحدهای متنی و عبارت‌ها از پیکره استخراج می‌شوند. سپس روابط context میان این واحدها با استفاده از اطلاعات آماری پیکره مدل‌سازی شده و با کاهش ابعاد، به یک فضای معنایی دوبعدی نگاشت می‌شوند.

در ادامه، فضای معنایی بر روی یک شبکه 64×64 نگاشت شده و برای هر عبارت یک اثرانگشت ایجاد می‌شود. fingerprintهای عبارات موجود در هر سند نیز با یکدیگر جمع شده و Document Fingerprint را تشکیل می‌دهند. به همین ترتیب، پرسش کاربر نیز به یک نمایش fingerprint تبدیل شده و میزان شباهت آن با fingerprint اسناد محاسبه می‌شود.

بنابراین، در این پژوهش، واحد اصلی مقایسه صرفاً تطبیق مستقیم کلمات نیست، بلکه موقعیت و الگوی فعال‌شده در فضای معنایی نیز در فرآیند بازیابی مورد استفاده قرار می‌گیرد.

این مسئله در محیط‌های چندزبانه پیچیده‌تر می‌شود؛ زیرا زبان‌های مختلف دارای ویژگی‌های واژگانی و نحوی متفاوتی هستند و استخراج واحدهای معنایی مناسب و ایجاد نمایش مشترک میان آن‌ها نیازمند توجه به ویژگی‌های زبانی است.

از این رو، مسئله اصلی این پژوهش را می‌توان به صورت زیر بیان کرد:

آیا می‌توان با استفاده از رویکرد Semantic Folding، یک نمایش فضایی از عبارات و اسناد چندزبانه ایجاد کرد که بتوان از آن برای بازیابی اسناد مرتبط با پرسش در محیط‌های دامنه‌بسته استفاده کرد و عملکرد آن را به صورت کمی با معیارهای استاندارد بازیابی ارزیابی نمود؟

همچنین پرسش‌های فرعی پژوهش عبارت‌اند از:

آیا نمایش فضایی حاصل از Semantic Folding می‌تواند روابط معنایی میان عبارات را برای استفاده در بازیابی حفظ کند؟

تأثیر ایجاد fingerprint برای عبارات و تجمیع آن‌ها در سطح سند بر عملکرد بازیابی چیست؟

spreading در فضای معنایی چه تأثیری بر میزان شباهت پرسش و اسناد دارد؟

عملکرد Semantic Folding در مقایسه با روش‌های متداول و روش‌های sparse عصبی چگونه است؟

آیا ترکیب Semantic Folding با SPLADE می‌تواند کیفیت رتبه‌بندی اسناد را بهبود دهد؟

۱-۳-۱. زیرمسئله‌های عملیاتی پژوهش

۱. **بازنمایی:** چگونه متون چندزبانه را به یک نقشه معنایی مشترک نگاشت کنیم تا

واژه‌های هم‌معنا در زبان‌های مختلف اثرانگشت‌های مشابه به دست آورند؟

۲. **وزن دهی و ترکیب:** هنگام ساخت اثرانگشت اسناد و پرس وجوها، اهمیت هر واژه/عبارت را چگونه محاسبه کنیم (TF-IDF، هم‌رخدادی سند-محور)؟
۳. **بازیابی:** شباهت میان اثرانگشت پرس وجو و اثرانگشت اسناد را چگونه بسنجیم که هم دقت بالا و هم سرعت مناسب تضمین شود – و آیا ادغام سیگنال واژگانی عصبی (SPLADE) می‌تواند نتایج را بهبود دهد؟

۴-۱. اهداف تحقیق

هدف اصلی این پژوهش، بررسی، ارزیابی و تحلیل کاربردهای رویکرد خوشه‌بندی معنایی در ایجاد نمایش فضایی متون چندزبانه برای درک مفاهیم آنان و استفاده از این نمایش برای بازیابی اطلاعات و پاسخ‌گویی به سوالات در محیط‌های دامنه‌بسته است.

اهداف فرعی پژوهش عبارت‌اند از:

طراحی و پیاده‌سازی کامل یک خط لوله مبتنی بر خوشه‌بندی معنایی برای پردازش متون چندزبانه.

بررسی روش‌های استخراج عبارت برای زبان‌های مختلف و ایجاد یک نمایش یکپارچه از عبارات.

بررسی تأثیر پارامترهای کلیدی (ابعاد فضای معنایی، وزن دهی TF-IDF، هموارسازی گاوسی، انتشار فعال‌سازی، spatial spreading و ...) بر دقت بازیابی اسناد مرتبط.

ارزیابی عملکرد روش پیشنهادی با معیارهایی مانند MRR، AP، Precision، Recall و NDCG و مقایسه آن با خط مبنای BM25 و بررسی معناداری آماری تفاوت‌ها

بررسی و آزمودن بهبودهایی بر روش پایه، از جمله امکان ترکیب SF با SPLADE و مقایسه روش‌های Linear و RRF و یا سازوکار شبکه‌های واژگان برای واژگان خارج از پیکره.

ایجاد یک چارچوب معیار^۷ قابل تکرار برای ارزیابی روش پیشنهادی روی مجموعه داده‌های چندزبانه (قرآن کریم با ۶,۲۳۶ آیه، پیکره دوزبانه عربی-انگلیسی، PubMedQA، Belebele، NarrativeQA، PopQA و زیرمجموعه‌ای از BEIR).

۵-۱. روش انجام پژوهش

نظریه خوشه‌بندی معنایی و کاربرد آن در اثرانگشت معنایی، توسط فرانسیسکو دی سوزا وبر، روش جدیدی را برای پردازش زبان طبیعی بر اساس یک مدل الهام گرفته از مغز، برگرفته از حافظه زمانی سلسله‌مراتبی (HTM^۸) بیان شده توسط جف هاوکینز^۹ در سال ۲۰۱۶، ارائه می‌دهد [۱۰]، [۱۸]. در ادامه به مسئله بازنمایی می‌پردازد، اینکه زبان چگونه در مغز نمایش داده می‌شود [۱۱]. نویسندگان استدلال می‌کنند که مدل‌های آماری موجود برای درک زبان کوتاه‌مدت هستند و نیاز به رویکردی مبتنی بر زیست‌شناسی بیشتری، احساس می‌شود [۱۳]. خوشه‌بندی معنایی متن را به قالبی دودویی، پراکنده و مبتنی بر یک نقشه معنایی تبدیل می‌کند که بیشتر شبیه فرآیندهای مغزی است که در آن بدون نیاز به منابع قوی و پردازش‌های سنگین می‌توان با دقت بالایی به سوالات پاسخ داد [۱۹]. در این روش، با تقلید از روش یادگیری در مغز انسان و ایجاد یک نقشه معنایی زمینه برای پاسخگویی دقیق‌تر و در زمان کمتر فراهم شده است [۱۳].

^۷ benchmark .

^۸ Hierarchical Temporal Memory .

^۹ Jeff Hawkins .

در این پژوهش که از نوع پیاده‌سازی و ارزیابی است؛ در ابتدا یک پیکره متنی^{۱۰} چندزبانه به‌عنوان ورودی سیستم در نظر گرفته می‌شود. سپس فرآیند نمایه‌سازی^{۱۱} در پنج مرحله انجام می‌شود که در فصل سوم به تفصیل شرح داده شده است.

در ادامه، نتایج Semantic Folding به‌صورت مستقل ارزیابی شده و امکان ترکیب آن با SPLADE نیز بررسی شده است. برای ارزیابی کمی، معیارهایی مانند AP، MRR و NDCG@K محاسبه و نتایج در سطح هر پرسش و به‌صورت تجمیعی تحلیل شده است.

۱-۶. نوآوری‌ها و دستاوردهای پژوهش

۱. پیاده‌سازی کامل و بازتولیدپذیر خط لوله خوشه‌بندی معنایی برای ارزیابی در دامنه بسته (ارزیابی نظام‌مند این روش روی ۱۴ مجموعه داده استاندارد).
۲. سازوکار وزن‌دهی دو سطحی: هم‌رخدادی واژه-مفهوم برای «ساختار» اثرانگشت و TF-IDF برای «اهمیت»، به‌صورت جمع خطی وزن‌دار.
۳. گزارش نخستین نتایج این روش روی پیکره قرآن کریم (۳۰ پرسش، ۶,۲۳۶ آیه) و پیکره دوزبانه عربی-انگلیسی (۴۸۸ قطعه) همراه با آزمون‌های معناداری آماری (McNemar و Wilcoxon).
۴. بهبود عملکرد از طریق ترکیب خطی α (SF+SPLADE=۰/۳) که در سه دیتاست از چهار دیتاست اصلی بهترین نتیجه را داده است.
۵. تحلیل جامع پارامتری و شکست‌ها (failure analysis) برای شناسایی مرزهای کاربرد روش.

۱-۷. ساختار پایان‌نامه

^{۱۰} Corpus .

^{۱۱} Indexing .

- **فصل ۱** به بیان کلیات پژوهش پرداخته شد.
- **فصل ۲** مبانی نظری (HTM، نظریه خوشه‌بندی معنایی، SDR) و مرور پیشینه (سامانه‌های QA، روش‌های تعبیه کلمات، کارهای مبتنی بر SF)، پوشش داده شده است.
- **فصل ۳** روش پیشنهادی، از استخراج عبارات از پیکره متنی ورودی تا جست‌وجو و تعیین پاسخ، همراه با جزئیات وزن‌دهی و نمایه‌سازی به تفصیل شرح داده شده است.
- **فصل ۴** محیط پیاده‌سازی، طرح آزمایش‌ها، مجموعه داده‌ها، معیارهای ارزیابی و نتایج کمی (به همراه آزمون‌های معناداری و تحلیل خطا)، ارائه شده است.
- **فصل ۵** به جمع‌بندی، نتیجه‌گیری، یافته‌ها، دستاوردها، محدودیت‌ها و پیشنهاد مسیرهای آتی برای ادامه پژوهش و توسعه روش پرداخته شده است.

فصل ۲: مبانی نظری و پیشینه پژوهش

۲-۱. مقدمه

در این فصل ابتدا مفاهیم پایه‌ی بازیابی اطلاعات و پاسخ‌گویی به سوال مرور شده است؛ سپس به بازیابی چندزبانه و میان‌زبانی پرداخته شده است. بخش‌های میانی، روش‌های وزن‌دهی و نمایش برداری متون (واژگانی، تنک، متراکم)، مبانی زیست‌الهامی، نظریه‌ی خوشه‌بندی معنایی، اجزای سازنده‌ی اثرانگشت‌ها و روش‌های کاهش بعد را تشریح کرده‌اند؛ در بخش‌های بعد، روش **SPLADE** و نقش آن در بازیابی sparse و ترکیب آن با سایر روش‌های بازیابی بررسی خواهد شد؛ و در پایان، معیارهای ارزیابی، مجموعه‌داده‌های استاندارد و مرور ساختارمند پیشینه پژوهش بررسی شده و جایگاه پژوهش حاضر در میان مطالعات پیشین مشخص خواهد شد.

۲-۱. مقدمه

در روش‌های کلاسیک بازیابی، نمایش‌هایی مانند **TF-IDF** نقش مهمی در تعیین اهمیت واژه‌ها و ایجاد بردارهای متنی داشته‌اند. در این روش، وزن یک واژه در یک سند بر اساس میزان حضور آن در سند و میزان نادر بودن آن در کل مجموعه اسناد تعیین می‌شود؛ بنابراین واژه‌هایی که در تعداد کمی از اسناد ظاهر می‌شوند، معمولاً قدرت تمایزبخشی بیشتری دارند. ([Stanford NLP](#)) با وجود سادگی و کارایی، چنین روش‌هایی عمدتاً بر اطلاعات واژگانی تکیه دارند و در مواجهه با مسئله عدم تطابق واژگانی میان پرس‌وجو و سند با محدودیت‌هایی روبه‌رو هستند.

در ادامه، روش‌های مبتنی بر نمایش‌های برداری و یادگیری بازنمایی تلاش کرده‌اند ارتباط معنایی میان واحدهای متنی را بهتر مدل کنند. یکی از مسیرهای مهم در این حوزه، استفاده از نمایش‌های **sparse** است. این نمایش‌ها برخلاف بردارهای **dense**، تعداد زیادی از مؤلفه‌های آن‌ها مقدار غیرصفر دارند، تنها بخش محدودی از مؤلفه‌های فضای نمایش را فعال می‌کنند. این ویژگی امکان استفاده از مزایایی مانند تطبیق صریح واژگان، تفسیرپذیری و استفاده از ساختارهای کارآمد نمایه‌سازی را فراهم می‌کند. روش **SPLADE** نمونه‌ای از رویکردهای نوین در این زمینه است که با استفاده از مدل زبانی و سازوکار گسترش واژگانی، نمایش‌های **sparse** برای پرس‌وجو و اسناد ایجاد می‌کند. ([NAVER LABS Europe](#))

در پژوهش حاضر، در کنار این رویکردها، مفهوم **Semantic Folding** به‌عنوان مبنایی برای ایجاد یک فضای معنایی توپولوژیک و تولید **fingerprint**های متنی مورد بررسی و استفاده قرار گرفته است. در **Semantic Folding**، واحدهای زبانی بر اساس روابط معنایی در یک فضای دوبعدی قرار گرفته و سپس موقعیت آن‌ها در این فضا به یک نمایش برداری موسوم به **fingerprint** تبدیل می‌شود. ایده اصلی **Semantic Folding**، تبدیل نمایش نمادین متن به یک بازنمایی صریح و مبتنی بر موقعیت در فضای معنایی (**Semantic Space**) است. ([arXiv](#))

برای ایجاد چنین فضای معنایی، مسئله کاهش بُعد نیز اهمیت پیدا می‌کند. روش‌هایی مانند **UMAP** برای نگاشت نمایش‌های با بُعد بالا به یک فضای دوبعدی استفاده می‌شود. **UMAP** یک روش یادگیری منیفلد برای کاهش بُعد است که با هدف حفظ ساختارهای مهم داده در فضای کم‌بعد طراحی شده و از نظر کیفیت نمایش و هزینه محاسباتی با روش‌هایی مانند **t-SNE** و **PCA** قابل مقایسه است. ([arXiv](#))

۲-۲. بازیابی اطلاعات

۲-۲-۱. تعریف بازیابی اطلاعات

بازیابی اطلاعات یکی از حوزه‌های اصلی علوم کامپیوتر و پردازش زبان طبیعی است که هدف آن یافتن و بازیابی اطلاعات مرتبط با نیاز اطلاعاتی کاربر از میان مجموعه‌ای از منابع اطلاعاتی است. در حالت متداول، منابع مورد نظر اسناد متنی هستند و نیاز اطلاعاتی کاربر، به وسیله یک پرس‌وجو بیان می‌شود. سیستم بازیابی اطلاعات پس از پردازش پرس‌وجو و اسناد، میزان ارتباط هر سند با پرس‌وجو را تخمین زده و اسناد را بر اساس میزان ارتباط آن‌ها مرتب می‌کند. (کتاب [IEEE](#) (*Introduction to Information Retrieval*) ([Stanford NLP](#)) ([Technology Navigator](#)))

تفاوت اساسی بازیابی اطلاعات با بازیابی داده‌های ساخت‌یافته در این است که در سیستم‌های پایگاه داده معمولاً هدف، یافتن رکوردهایی است که دقیقاً شرایط مشخص‌شده را برآورده می‌کنند؛ در حالی که در بازیابی اطلاعات، **میزان ارتباط** (**Relevance**) یک مفهوم تدریجی است. بنابراین ممکن است چندین سند با درجات مختلفی از ارتباط با یک پرس‌وجو وجود داشته باشند و سیستم باید آن‌ها را بر اساس میزان ارتباط رتبه‌بندی کند. ([ScienceDirect](#)))

در یک سیستم IR، دو مرحله اساسی وجود دارد: **نمایه‌سازی** (**Indexing**) و **جست‌وجو یا امتیازدهی** (**Search/Scoring**)).

در مرحله نمایه‌سازی، اسناد به یک نمایش داخلی مناسب تبدیل می‌شوند و در مرحله جست‌وجو، پرس‌وجو نیز به شکلی سازگار نمایش داده شده و میزان ارتباط آن با اسناد محاسبه می‌شود. ([ScienceDirect](#)) (DOI)

در سامانه‌های نوین، مسئله بازیابی اطلاعات دیگر صرفاً به تطبیق واژه‌های موجود در پرس‌وجو و اسناد محدود نمی‌شود، بلکه تلاش می‌شود ارتباط معنایی میان پرس‌وجو و محتوای اسناد نیز در فرایند بازیابی مورد توجه قرار گیرد. این موضوع به‌ویژه در کاربردهایی مانند پاسخ‌گویی به سوالات، که کیفیت پاسخ نهایی به انتخاب شواهد و اسناد مرتبط وابسته است، اهمیت بیشتری پیدا می‌کند. (DOI)

از سوی دیگر، گسترش محتوای چندزبانه در وب و افزایش نیاز کاربران به دسترسی به اطلاعات در زبان‌های مختلف، مسئله بازیابی چندزبانه و پاسخ‌گویی به پرسش‌های چندزبانه را به یکی از موضوعات مهم پژوهشی تبدیل کرده است. در این شرایط، روش بازیابی باید بتواند با تفاوت‌های واژگانی، ساختاری و زبانی میان زبان‌ها مواجه شود و در عین حال اطلاعات مرتبط را با دقت مناسبی بازیابی کند.

۲-۲-۲. سند، پرس‌وجو و مجموعه اسناد

سه مفهوم اساسی در مسئله بازیابی اطلاعات عبارت‌اند از **سند**، **پرس‌وجو** و **مجموعه اسناد**.

سند ((Document واحدی از اطلاعات است که سیستم می‌تواند آن را ذخیره، نمایه‌سازی و بازیابی کند. در بازیابی متنی، یک سند می‌تواند یک مقاله، صفحه وب، بخش از یک کتاب، یک پاراگراف یا حتی یک قطعه کوتاه از متن باشد.

پرس‌وجو ((Query بیان‌کننده نیاز اطلاعاتی کاربر است. پرس‌وجو می‌تواند از چند کلمه تا یک جمله یا حتی یک سؤال کامل تشکیل شود.

مجموعه اسناد ((Corpus مجموعه‌ای از اسناد است که سیستم بازیابی اطلاعات در میان آن‌ها به دنبال اسناد مرتبط با پرس‌وجو می‌گردد.

در پژوهش حاضر پرس‌وجوها از مجموعه پرسش‌های بنچمارک دریافت شده و با مجموعه‌ای از اسناد مقایسه می‌شوند و هدف، قرار گرفتن اسناد مرتبط در رتبه‌های بالاتر است.

۲-۲-۳. رتبه‌بندی اسناد

پس از دریافت پرس‌وجو، سیستم IR باید مشخص کند که هر سند تا چه اندازه با پرس‌وجو مرتبط است. برای این منظور، به هر زوج پرس‌وجو-سند یک امتیاز ارتباط (**Relevance Score**) اختصاص داده می‌شود و سپس اسناد بر اساس این امتیاز مرتب می‌شوند. ([DOI](#)) ([ScienceDirect](#))

در روش‌های سنتی، این امتیاز می‌تواند بر اساس عواملی مانند تعداد وقوع واژه‌های پرس‌وجو در سند، اهمیت واژه‌ها و میزان شباهت بردارهای سند و پرس‌وجو محاسبه شود. برای مثال، در مدل فضای برداری، سند و پرس‌وجو به صورت بردارهایی از وزن واژه‌ها نمایش داده شده و نزدیکی آن‌ها برای رتبه‌بندی استفاده می‌شود. ([PubMed Central](#)) ([PMC](#))

اهمیت رتبه‌بندی از آنجا ناشی می‌شود که معمولاً تعداد اسناد موجود در یک مجموعه بسیار بیشتر از آن است که کاربر بتواند همه آن‌ها را بررسی کند. بنابراین سیستم باید مرتبط‌ترین اسناد را در ابتدای فهرست نتایج قرار دهد ([Stanford NLP](#)) ([DOI](#)).

۲-۲-۴. تطبیق واژگانی (Lexical Matching)

در روش‌های مبتنی بر **تطبیق واژگانی**، ارتباط میان پرس‌وجو و سند عمدتاً بر اساس تطابق واژه‌ها یا واحدهای متنی مشترک تعیین می‌شود. به عبارت دیگر، سیستم بررسی می‌کند که واژه‌ها یا عبارات موجود در پرس‌وجو تا چه اندازه در سند نیز حضور دارند.

یکی از ساختارهای بنیادی برای پیاده‌سازی چنین جست‌وجویی **نمایه‌سازی معکوس** (**Inverted Index**) است. در این ساختار، برای هر واژه فهرستی از اسنادی که آن واژه را شامل می‌شوند نگهداری می‌شود و این ساختار امکان یافتن سریع اسناد حاوی واژه‌های پرس‌وجو را فراهم می‌کند. ([Stanford University](#)) (DOI)

مدل‌های سنتی مانند **TF-IDF** و **BM25** نمونه‌هایی از روش‌هایی هستند که از اطلاعات واژگانی و آماری موجود در اسناد برای امتیازدهی و رتبه‌بندی استفاده می‌کنند.

مزیت مهم تطبیق واژگانی، **دقت بالا در تطبیق اصطلاحات و کلمات خاص** است؛ اما محدودیت آن این است که الزاماً مفهوم و معنای واژه‌ها را درک نمی‌کند. برای مثال، اگر پرس‌وجو شامل عبارت *car accident* باشد و سندی عبارت *automobile collision* را داشته باشد، یک روش صرفاً واژگانی ممکن است به دلیل نبود تطابق مستقیم، ارتباط این دو را به خوبی تشخیص ندهد.

۵-۲-۲. تطبیق معنایی (Semantic Matching)

در مقابل تطبیق واژگانی، **تطبیق معنایی** (**Semantic Matching**) تلاش می‌کند ارتباط میان پرس‌وجو و سند را نه صرفاً از روی واژه‌های یکسان، بلکه بر اساس **معنا و مفهوم متن** تعیین کند.

در روش‌های جدید، پرس‌وجو و اسناد می‌توانند به نمایش‌هایی در یک فضای برداری تبدیل شوند و سپس میزان نزدیکی آن‌ها در این فضا به عنوان معیار شباهت مورد استفاده قرار گیرد. در بازیابی متراکم (Dense Retrieval)، این نمایش‌ها معمولاً بردارهای چگال هستند

و مدل یادگیری شده تلاش می‌کند متون دارای معنای مشابه را در فضای نمایش به یکدیگر نزدیک کند. ([DOI](#))

البته روش‌های معنایی و متراکم (Dense Retrieval) نیز محدودیت‌هایی دارند. مطالعات مربوط به بازیابی متراکم نشان داده‌اند که در برخی شرایط، مدل‌های dense در **semantic matching** عملکرد خوبی دارند، اما ممکن است در **lexical matching** نسبت به روش‌های sparse مانند BM25 ضعیف‌تر باشند. به همین دلیل، ترکیب اطلاعات واژگانی و معنایی به یکی از مسیرهای مهم پژوهش در بازیابی اطلاعات تبدیل شده است. (DOI)

۶-۲-۲. ارتباط بازیابی واژگانی و معنایی با پژوهش حاضر

روش‌های بازیابی معنایی در بسیاری از مسائل قادر به ایجاد تطبیق معنایی مؤثر هستند، اما در برخی شرایط محدودیت‌های دارند و ممکن است در تطبیق واژگانی، به‌ویژه برای عبارات مهم، نام‌های خاص و واژه‌های نادر، نسبت به روش‌های بازیابی واژگانی مانند BM25 عملکرد ضعیف‌تری داشته باشند. ([DOI](#))

از این رو، ترکیب روش‌های واژگانی و معنایی به یکی از رویکردهای مهم پژوهش در بازیابی اطلاعات تبدیل شده است. (DOI) ([ACL Anthology](#)) این تمایز برای پژوهش حاضر اهمیت ویژه‌ای دارد. روش پیشنهادی پایان‌نامه بر پایه **خوشه‌بندی معنایی** تلاش می‌کند متن را از سطح تطبیق مستقیم واژه‌ها فراتر برده و اطلاعات معنایی و ارتباط میان عبارات را در یک فضای ساخت‌یافته نمایش دهد.

از طرف دیگر، استفاده از روش‌هایی مانند **SPLADE** امکان استفاده همزمان از ویژگی‌های sparse و اطلاعات معنایی حاصل از مدل‌های زبانی را فراهم می‌کند. که در معماری کلی پژوهش حاضر به آن پرداخته شده است.

۲-۳. پاسخ‌گویی به سؤال (Question Answering)

۲-۳-۱. تعریف پاسخ‌گویی به سؤال

پاسخ‌گویی به سؤال (Question Answering یا QA) یکی از مسائل مهم در پردازش زبان طبیعی است که هدف آن، ارائه پاسخ مناسب به یک پرسش بیان‌شده به زبان طبیعی است. برخلاف جست‌وجوی سنتی که معمولاً فهرستی از اسناد مرتبط را در اختیار کاربر قرار می‌دهد، سیستم QA تلاش می‌کند اطلاعات مورد نیاز کاربر را از منابع موجود استخراج کرده و به صورت یک پاسخ ارائه کند.

در سیستم‌های مدرن QA، به‌ویژه در Open-Domain QA، معمولاً مسئله به دو بخش اصلی تقسیم می‌شود: بازیابی اطلاعات مرتبط (Retrieval) و استخراج یا تولید پاسخ (Answering). در معماری‌های retrieve-then-read، ابتدا یک Retriever اسناد یا passage‌های مرتبط را از یک مجموعه بزرگ بازیابی می‌کند و سپس یک Reader یا Answering Model پاسخ را از میان اطلاعات بازیابی‌شده استخراج یا تولید می‌کند. ([ACL Anthology](#)) (DOI)

تاکنون روش‌های گوناگونی برای پاسخ‌گویی به سوالات ایجاد و توسعه داده شده است. به عنوان مثال امکان پاسخ‌گویی به سوالات در یک جامعه تخصصی (CQA^{۱۲}) به روشی محبوب برای جست‌جوی مطالعات آنلاین تبدیل شده است. جایی که کاربران می‌توانند در قالب پرسش و پاسخ با یکدیگر تعامل داشته باشند و همچنین می‌تواند شامل میلیون‌ها پرسش و پاسخ باشد. حجم بسیار بالای پرسش و پاسخ در این سامانه‌ها امکان کشف شباهت بین سوال جدید با سوالات مرتبط و تبع آن پاسخ‌های مرتبط در میان پاسخ‌های موجود را فراهم می‌کند[۳۲].

پاسخ‌گویی به سوالات نه تنها حوزه‌ای از بازیابی اطلاعات است بلکه حوزه‌ای از استخراج اطلاعات و پردازش زبان طبیعی نیز است[۳۳]. در سال‌های اخیر نوع دیگری از سامانه‌ها به نام سامانه

^{۱۲} Community Questions Answering .

پاسخگویی به سوالات معنایی (SQA^{۱۳}) توسعه داده شده‌اند که در واقع از یک زبان مبتنی بر پرس و جوی رسمی مثل SPARQL استفاده می‌کنند که نوعی استاندارد برای مدل‌سازی و جست‌جوی داده‌ها هستند [۲۰]، [۳۰]. به دلیل امکان پرسش سوال به زبان طبیعی در این سامانه‌ها، باید مراحل مختلفی در آنها برای دستیابی به وظیفه درک نیازهای اطلاعاتی کاربران وجود داشته باشد که به برخی از این مراحل و تکنیک‌هایی که بعضاً استفاده شده اشاره شده است [۳۰].

معیارهایی برای طبقه بندی سامانه‌های پاسخگویی به سوالات معنایی وجود دارد، مثل طبقه بندی کردن بر اساس دامنه که در آن سوالات به سه دسته دامنه بسته، دامنه باز^{۱۴} و دامنه ترکیبی^{۱۵} تقسیم می‌شوند. که دسته اول برای پاسخگویی به سوالات در یک حوزه تخصصی است که به دلیل محدود بودن دامنه، پاسخ‌ها کیفیت خوبی دارند؛ دسته دوم مربوط به کاربران عادی برای پاسخگویی به سوالات عمومی است که نیاز به مخازن داده بسیار بزرگی دارند و دسته سوم یا محیط‌های با دامنه ترکیبی هر دو دسته از سوالات قبلی را در خود جای داده‌اند [۱۶]، [۳۰].

۲-۳-۲. پاسخ‌گویی به سؤال در دامنه باز و دامنه بسته

از نظر محدوده منابع اطلاعاتی، سیستم‌های QA را می‌توان به دو دسته کلی Open-Domain QA و Closed-Domain QA تقسیم کرد.

الف) پاسخ‌گویی به سؤال در دامنه باز (Open-Domain QA)

در Open-Domain QA، سیستم محدود به یک حوزه موضوعی یا یک مجموعه کوچک از منابع نیست و باید بتواند پاسخ پرسش را از میان یک مجموعه بزرگ و متنوع از اسناد پیدا کند. در چنین شرایطی، Retriever اهمیت بسیار زیادی پیدا می‌کند؛ زیرا بررسی تمام اسناد

^{۱۳} . Semantic Questions Answering

^{۱۴} . Open domain

^{۱۵} . Hybrid domain

توسط مدل پاسخ‌گو عملاً امکان‌پذیر یا مقرون‌به‌صرفه نیست. به همین دلیل، معماری‌های Open-Domain QA معمولاً از یک مرحله بازیابی برای کاهش مجموعه عظیم اسناد به تعداد محدودی از اسناد یا passage‌های کاندید استفاده می‌کنند. ([ACL Anthology](#))

(ب) پاسخ‌گویی به سؤال در دامنه بسته (Closed-Domain QA)

در Closed-Domain QA، سیستم با یک مجموعه مشخص و محدود از منابع یا یک حوزه موضوعی مشخص کار می‌کند. لذا منظور از محیط دامنه‌بسته، محدود بودن فضای جست‌وجو به یک مجموعه اسناد مشخص و از پیش تعریف‌شده است. بنابراین دامنه‌بسته الزاماً به معنای محدود بودن موضوعی محتوا نیست، بلکه به محدود بودن پیکره متنی قابل جست‌وجو اشاره دارد.

برای مثال، فرض کنیم مجموعه اسناد یک سازمان شامل مستندات مربوط به یک محصول باشد. کاربر می‌پرسد:

«حداکثر ظرفیت این محصول چقدر است؟»

سیستم فقط باید در همان مجموعه مستندات جست‌وجو کند.

در نتیجه، برخلاف Open-Domain QA، فضای جست‌وجو از ابتدا محدود شده است. این ویژگی باعث می‌شود طراحی و ارزیابی سیستم در یک حوزه مشخص امکان‌پذیرتر باشد و بتوان روش‌های مختلف بازیابی را به صورت کنترل‌شده با یکدیگر مقایسه کرد.

این مفهوم به پژوهش حاضر ارتباط مستقیمی دارد؛ زیرا Semantic Folding هم برای بازیابی از یک مجموعه مشخص از متون مورد استفاده قرار می‌گیرد و عملکرد آن بر اساس میزان موفقیت در بازیابی اسناد مرتبط با پرسش‌ها ارزیابی می‌شود.

۳-۲-۲. پاسخ‌گویی مبتنی بر بازیابی (Retrieval-based QA)

یکی از معماری‌های رایج در QA، معماری Retrieve-Then-Read است که در این معماری، Retriever نقش دروازه ورود اطلاعات را دارد.

ایده اصلی بسیار ساده است:

Question

|



Retriever

|



Relevant Documents / Passages

|



Reader / Answering Model

|



Answer

در مرحله اول، Retriever از میان مجموعه اسناد، تعدادی سند را که احتمال می‌دهد برای پاسخ‌گویی مرتبط باشند انتخاب می‌کند.

در مرحله دوم، مدل پاسخ‌گو این اطلاعات را بررسی کرده و پاسخ نهایی را استخراج یا تولید می‌کند.

بنابراین حتی اگر مدل پاسخ‌گو بسیار قدرتمند باشد، اگر Retriever سند مناسب را در میان کاندیدها قرار ندهد، سیستم نمی‌تواند پاسخ صحیح را پیدا کند.

به همین دلیل کیفیت Retriever یکی از عوامل تعیین‌کننده در عملکرد سیستم‌های Retrieval-based QA است. پژوهش‌های مربوط به رتبه‌بندی عصبی نیز Retriever و ranking را به عنوان اجزای مهم دسترسی به دانش خارجی در Open-Domain QA مورد بررسی قرار داده‌اند. ([ACL Anthology](#))

این مسئله دقیقاً همان جایی است که پژوهش حاضر اهمیت پیدا می‌کند: **هدف اصلی در این مرحله تولید پاسخ نیست، بلکه بررسی کیفیت روش Semantic Folding در پیدا کردن اسناد مرتبط با پرسش است.**

این معماری یک مزیت مهم دارد: به جای آنکه مدل پاسخ‌گو مجبور باشد کل مجموعه اسناد را بررسی کند، تنها با بخش کوچکی از اطلاعات کاندید کار می‌کند. معماری‌های retrieve-then-read از رویکردهای اصلی در Open-Domain QA محسوب می‌شوند. ([ACL Anthology](#))

۲-۴. بازیابی اطلاعات چندزبانه و میان‌زبانی

با گسترش منابع دیجیتال در زبان‌های مختلف، سیستم‌های بازیابی اطلاعات دیگر نمی‌توانند صرفاً بر منابع انگلیسی متکی باشند. در بسیاری از کاربردها، پرسش کاربر ممکن است به یک زبان بیان شود، در حالی که اطلاعات مورد نیاز در منابعی با زبان دیگر قرار

داشته باشد. از این رو، بازیابی اطلاعات چندزبانه و میان‌زبانی اهمیت ویژه‌ای پیدا کرده است.

۱-۴-۲. بازیابی اطلاعات چندزبانه (Multilingual Information Retrieval)

Multilingual Information Retrieval یا MLIR به مسئله بازیابی اطلاعات از مجموعه‌ای از منابع متنی با چند زبان مختلف اشاره دارد.

برای مثال، فرض کنیم مجموعه اسناد شامل اسنادی به زبان انگلیسی، عربی، فارسی، فرانسوی، آلمانی و غیره باشد. یک سیستم Multilingual IR می‌تواند برای این مجموعه، پرسش‌هایی را در زبان‌های مختلف دریافت کرده و اسناد مرتبط را از منابع چندزبانه بازیابی کند.

در این حالت، مسئله اصلی این است که سیستم باید بتواند ویژگی‌های زبانی متفاوت از جمله، تفاوت در واژگان، ساختار دستوری، شکل کلمات و شیوه توکن‌سازی را در یک چارچوب مشترک مدیریت کند.

پژوهش‌هایی مانند Mr. TyDi دقیقاً برای بررسی عملکرد سیستم‌های بازیابی در زبان‌های مختلف طراحی شده‌اند. که در ادامه به آن پرداخته شده است. ([ACL Anthology](#))

۲-۴-۲. بازیابی اطلاعات میان‌زبانی (Cross-Lingual Information Retrieval)

Cross-Lingual Information Retrieval یا CLIR حالت خاصی از بازیابی چندزبانه است که در آن زبان پرسش و زبان اسناد می‌توانند متفاوت باشند.

برای مثال:

Query:

What is artificial intelligence?



Documents:

"ما هو الذكاء الاصطناعي؟ ..."

"Was ist künstliche Intelligenz? ..."

در اینجا کاربر پرسش را به انگلیسی مطرح کرده است، اما سیستم باید بتواند اسناد عربی یا آلمانی مرتبط را نیز پیدا کند.

این مسئله از نظر معنایی چالش برانگیزتر از بازیابی تک‌زبانه است، زیرا سیستم باید ارتباط مفهومی میان دو زبان متفاوت را تشخیص دهد.

۳-۴-۲. چالش‌های بازیابی در زبان‌های مختلف

بازیابی چندزبانه با چالش‌های متعددی مواجه است. مهم‌ترین آن‌ها عبارت‌اند از:

۱. تفاوت واژگان

یک مفهوم مشابه می‌تواند در زبان‌های مختلف با واژه‌های کاملاً متفاوت بیان شود.

مثلاً:

English: artificial intelligence

Arabic: الذكاء الاصطناعي

Persian: هوش مصنوعی

بنابراین تطبیق صرفاً واژگانی نمی‌تواند ارتباط این عبارات را تشخیص دهد.

۲. تفاوت ساختار دستوری

زبان‌ها از نظر ترتیب واژه‌ها، صرف فعل، ساختار اسمی و سایر ویژگی‌های نحوی با یکدیگر تفاوت دارند.

۳. تفاوت در توکن‌سازی

در برخی زبان‌ها، فاصله الزاماً مرز مناسبی برای تعیین کلمات نیست و برخی زبان‌ها نیز دارای ساختار صرفی پیچیده‌تری هستند.

۴. تفاوت منابع آموزشی

میزان داده‌های متنی موجود برای زبان‌های مختلف یکسان نیست. برخی زبان‌ها دارای منابع بسیار زیاد و برخی دیگر دارای منابع محدود هستند.

۵. کمبود اطلاعات (Information Scarcity)

در برخی زبان‌ها تعداد منابع و مقالات موجود کمتر است.

۶. عدم تقارن اطلاعات (Information Asymmetry)

حتی اگر یک مفهوم در منابع یک زبان وجود داشته باشد، ممکن است همان اطلاعات در Wikipedia یا منابع زبان دیگر وجود نداشته باشد.

۲-۵. نمایش متون و روش‌های وزن‌دهی

۲-۵-۱. مدل کیسه کلمات (Bag-of-Words)

یکی از ساده‌ترین و قدیمی‌ترین روش‌های نمایش متون، مدل Bag-of-Words (BoW) است. در این روش، متن به مجموعه‌ای از واژه‌ها تبدیل شده و برای هر واژه موجود در واژگان مجموعه داده، یک بُعد در فضای ویژگی در نظر گرفته می‌شود. در نتیجه، هر سند را می‌توان به صورت یک بردار عددی نمایش داد.

برای مثال، فرض کنید واژگان مجموعه اسناد شامل چهار واژه زیر باشد:

$[V=\{\text{retrieval, semantic, query, document}\}]$

اگر یک سند به صورت زیر باشد:

semantic retrieval semantic document

نمایش BoW آن می‌تواند به شکل زیر باشد:

$[[1,2,0,1]]$

که در آن هر مقدار بیانگر تعداد وقوع واژه متناظر در سند است.

مزیت اصلی BoW سادگی، سرعت و امکان استفاده از ساختارهای کارآمد نمایه‌سازی مانند نمایه‌سازی معکوس (inverted index) است. با این حال، این روش روابط معنایی میان واژه‌ها و ترتیب آن‌ها را به صورت مستقیم مدل نمی‌کند. در واقع، در این نمایش واژه‌ها عمدتاً به صورت ویژگی‌های مستقل در نظر گرفته می‌شوند. این مسئله یکی از محدودیت‌های اساسی روش‌های واژگانی در بازیابی اطلاعات محسوب می‌شود. ([DOI](#))

۲-۵-۲. فراوانی واژه (Term Frequency)

برای بهبود نمایش BoW، می‌توان به جای استفاده صرف از تعداد خام وقوع واژه‌ها، به هر واژه یک وزن اختصاص داد. یکی از ساده‌ترین معیارهای وزن‌دهی، Term Frequency (TF) است.

TF میزان تکرار یک واژه در یک سند را اندازه‌گیری می‌کند. ساده‌ترین شکل آن به صورت زیر تعریف می‌شود:

$$[TF(t,d)=f(t,d)]$$

که در آن:

- t) واژه موردنظر است؛
- d) سند موردنظر است؛
- $f(t,d)$ تعداد دفعات وقوع واژه t در سند d است.

برای مثال، اگر واژه **retrieval** در یک سند پنج بار تکرار شده باشد، مقدار TF آن برابر با ۵ خواهد بود.

منطق TF این است که تکرار بیشتر یک واژه در یک سند می‌تواند نشان‌دهنده ارتباط بیشتر آن واژه با موضوع سند باشد. با این حال، TF به تنهایی نمی‌تواند میان واژه‌های عمومی و واژه‌های متمایزکننده تفاوت مناسبی ایجاد کند؛ زیرا واژه‌هایی مانند *the* یا *system* ممکن است در بسیاری از اسناد تکرار شوند.

۳-۵-۲. فراوانی معکوس سند (Inverse Document Frequency)

معیار (Inverse Document Frequency) IDF برای اندازه‌گیری میزان تمایزدهندگی یک واژه در کل مجموعه اسناد استفاده می‌شود.

ایده اصلی آن این است که واژه‌ای که در تعداد زیادی از اسناد ظاهر می‌شود، اطلاعات کمتری برای تشخیص یک سند خاص دارد؛ در مقابل، واژه‌ای که در تعداد کمی از اسناد ظاهر می‌شود، می‌تواند ویژگی متمایزکننده‌تری باشد.

فرم رایج IDF به صورت زیر است:

$$[IDF(t)=\log\frac{N}{df(t)}]$$

که در آن:

- N) تعداد کل اسناد مجموعه است؛
 - $df(t)$) تعداد اسنادی است که واژه (t) در آن‌ها ظاهر شده است.
- بنابراین، هرچه $df(t)$ بزرگ‌تر باشد، مقدار IDF کوچک‌تر خواهد بود.

۲-۵-۴. TF-IDF

با ترکیب دو معیار TF و IDF، روش TF-IDF به دست می‌آید:

$$[TFIDF(t,d)=TF(t,d)\times IDF(t)]$$

بنابراین TF-IDF دو عامل را هم‌زمان در نظر می‌گیرد:

۱. اهمیت واژه در داخل یک سند $\rightarrow TF$

۲. میزان تمایز واژه در کل مجموعه اسناد $\rightarrow IDF$

به بیان ساده، اگر واژه‌ای در یک سند زیاد تکرار شود ولی تقریباً در تمام اسناد مجموعه نیز وجود داشته باشد، وزن نهایی آن الزاماً زیاد نخواهد بود. در مقابل، واژه‌ای که در یک سند حضور قابل‌توجهی دارد و در تعداد کمی از اسناد دیگر دیده می‌شود، وزن بالاتری دریافت می‌کند.

این روش مبنای بسیاری از مدل‌های کلاسیک بازیابی اطلاعات بوده و همچنان برای ایجاد نمایش‌های sparse و وزن‌دهی واژگان کاربرد دارد. مدل‌های term-based مانند BM25

نیز از خانواده روش‌هایی هستند که بر matching واژگانی و اطلاعات مربوط به فراوانی واژه‌ها تکیه دارند. ([DOI](#))

۵-۲. محدودیت‌های روش‌های واژگانی

باوجود سادگی و کارایی روش‌هایی مانند BoW و TF-IDF، این روش‌ها دارای محدودیت‌هایی هستند. مهم‌ترین محدودیت روش‌های واژگانی، Vocabulary Mismatch یا عدم تطابق واژگان میان پرس‌وجو و سند است.

محدودیت دیگر این است که نمایش‌های واژگانی کلاسیک معمولاً معنای ضمنی و روابط معنایی میان واژه‌ها را مستقیماً مدل نمی‌کنند. همچنین ترتیب و ساختار جمله در مدل ساده Bag-of-Words از بین می‌رود. به همین دلیل، توسعه روش‌هایی که بتوانند اطلاعات معنایی را در کنار اطلاعات واژگانی مورد استفاده قرار دهند، به یکی از مسیرهای مهم تحقیقات بازیابی اطلاعات تبدیل شده است. ([DOI](#))

این محدودیت‌ها زمینه را برای معرفی دو خانواده مهم دیگر از نمایش‌های متنی، یعنی Sparse Representation و Dense Representation، فراهم می‌کنند.

۶-۲. نمایش‌های برداری متون

برای پردازش محاسباتی متن، لازم است متن‌های زبانی به نمایش‌های عددی تبدیل شوند. یکی از رایج‌ترین روش‌ها، نمایش متن به صورت یک بردار است. تفاوت روش‌های مختلف در نحوه ساخت این بردار و معنای ابعاد آن است.

به طور کلی، در بازیابی اطلاعات مدرن می توان نمایش های متنی را در دو گروه مهم sparse و dense دسته بندی کرد. البته روش هایی مانند SPLADE نشان داده اند که می توان ویژگی های معنایی مدل های عصبی را با نمایش sparse ترکیب کرد. ([DOI](#))

۱-۶-۲. نمایش Sparse

در یک نمایش Sparse، بردار دارای تعداد بسیار زیادی بُعد است، اما تنها تعداد نسبتاً کمی از این ابعاد دارای مقدار غیرصفر هستند.

TF-IDF نمونه کلاسیک یک نمایش sparse است. در این حالت، هر بُعد معمولاً به یک واژه یا term مشخص در واژگان مربوط می شود.

یکی از مزایای مهم نمایش sparse، تفسیرپذیری آن است؛ زیرا می توان مشخص کرد کدام واژه ها باعث ایجاد مقدار غیرصفر در بردار شده اند. همچنین ساختار sparse با inverted index سازگاری مناسبی دارد و می تواند برای بازیابی سریع در مجموعه های بزرگ استفاده شود. ([DOI](#))

در سال های اخیر، روش های Learned Sparse Retrieval مانند SPLADE تلاش کرده اند این ویژگی را با قدرت مدل های زبانی عصبی ترکیب کنند.

SPLADE متن را به یک بردار sparse تبدیل می کند و در عین حفظ ساختار sparse، امکان گسترش واژگان مرتبط با مفهوم متن را فراهم می کند. ([GitHub](#))

۲-۶-۲. نمایش Dense

در مقابل، در نمایش Dense تقریباً تمام یا بخش بزرگی از ابعاد بردار دارای مقادیر غیرصفر هستند.

در این حالت، بردار معمولاً دارای تعداد محدودی بُعد است؛ برای مثال ۳۸۴، ۷۶۸ یا ۱۰۲۴ بُعد، اما تقریباً همه این ابعاد اطلاعاتی را در خود نگه می‌دارند.

در نمایش dense، هر بُعد الزاماً یک واژه مشخص نیست. بلکه اطلاعات معنایی متن در یک فضای پیوسته و توزیع‌شده نمایش داده می‌شود.

این ویژگی باعث می‌شود دو متن که از واژگان متفاوتی استفاده می‌کنند، در صورتی که معنای مشابهی داشته باشند، بتوانند در فضای برداری به یکدیگر نزدیک شوند.

روش‌هایی مانند Dense Passage Retrieval (DPR) از همین ایده استفاده می‌کنند. در DPR، پرس‌وجو و passage توسط encoderهای عصبی به بردارهای dense تبدیل شده و میزان ارتباط آن‌ها در فضای برداری محاسبه می‌شود. این روش نشان داده است که نمایش dense می‌تواند در بسیاری از مسائل QA عملکرد بسیار خوبی داشته باشد. ([ACL Anthology](#))

۳-۶-۲. مقایسه Dense و Sparse

تفاوت اصلی این دو روش را می‌توان به صورت زیر خلاصه کرد:

Dense

Sparse

ویژگی

معمولاً محدودتر

معمولاً بسیار زیاد

تعداد ابعاد

تعداد مقادیر غیرصفر	کم	زیاد
معنای ابعاد	اغلب قابل تفسیر	معمولاً latent
تطبیق واژگانی	بسیار خوب	ضعیفتر در تطابق دقیق
تطبیق معنایی	محدودیت در روش‌های کلاسیک	معمولاً قوی
تفسیرپذیری	بالا	کمتر
Vocabulary mismatch	مشکل اصلی	تا حدی قابل کاهش
نمونه	BM25، SPLADE	DPR، embedding models

البته این جدول یک تفکیک مفهومی است و نباید آن را به این معنا در نظر گرفت که تمام روش‌های sparse صرفاً واژگانی یا تمام روش‌های dense در همه شرایط از sparse بهتر هستند. مطالعات مقایسه‌ای نشان داده‌اند که lexical matching و semantic matching نقاط قوت متفاوتی دارند و ترکیب آن‌ها می‌تواند نسبت به استفاده از هرکدام به تنهایی robust تر باشد. ([DOI](#))

به همین دلیل، در سال‌های اخیر توجه قابل‌توجهی به hybrid retrieval و ترکیب sparse و dense retrieval شده است.

یکی از مسائل اساسی در بازیابی اطلاعات، Vocabulary Mismatch است. این مسئله زمانی رخ می‌دهد که پرس‌وجو و سند مرتبط، برای بیان یک مفهوم از واژه‌های متفاوتی استفاده کنند.

این مسئله یکی از محدودیت‌های شناخته‌شده روش‌های واژگانی (term-based) است. در مرورهای مربوط به بازیابی معنایی نیز اشاره شده است که مدل‌های کلاسیک مبتنی بر نمایش Bag-of-Words و تطابق واژگانی ممکن است به دلیل vocabulary mismatch، اسناد مرتبط را در همان مرحله اول بازیابی از دست بدهند. ([DOI](#))

این مشکل یکی از انگیزه‌های اصلی توسعه روش‌های semantic retrieval بوده است. نمایش‌های dense با قرار دادن متن‌های معنایی مشابه در نواحی نزدیک فضای embedding تلاش می‌کنند این شکاف واژگانی را کاهش دهند. ([Springer](#))

با این حال، dense retrieval نیز بدون محدودیت نیست. فشردن سازی اطلاعات در یک بردار dense می‌تواند در برخی موارد باعث از دست رفتن اطلاعات مهم برای exact lexical matching شود؛ برای مثال زمانی که تطابق دقیق نام یک موجودیت، شماره، اصطلاح تخصصی یا واژه کم‌تکرار اهمیت زیادی دارد. پژوهش‌های مروری این تفاوت را به عنوان یکی از دلایل مهم توجه به ترکیب sparse و dense retrieval مطرح کرده‌اند. ([DOI](#))

روش مورد بررسی در پژوهش جاری تلاش می‌کند بین دو دیدگاه واژگانی و معنایی ارتباط برقرار کند. در Semantic Folding، عبارات استخراج‌شده از متن ابتدا با استفاده از اطلاعات آماری و هم‌رخدادی در یک فضای معنایی قرار می‌گیرند و سپس موقعیت آن‌ها در قالب fingerprint نمایش داده می‌شود. در نتیجه، برخلاف نمایش ساده TF-IDF که هر واژه را عمدتاً به عنوان یک ویژگی مستقل در نظر می‌گیرد، در این رویکرد رابطه و نزدیکی عبارات در فضای معنایی نیز در ساخت نمایش نهایی نقش دارد.

از طرف دیگر، استفاده از مؤلفه‌هایی مانند TF-IDF در مراحل ساخت فضای معنایی و وزن‌دهی fingerprintها باعث می‌شود اطلاعات آماری و واژگانی نیز کاملاً کنار گذاشته نشود. بنابراین، ایده کلی این روش را می‌توان در راستای ایجاد پلی میان lexical representation و semantic representation در نظر گرفت؛ موضوعی که در پژوهش‌های جدید بازایی اطلاعات نیز اهمیت زیادی پیدا کرده است. ([DOI](#))

Word2Vec و GloVe فضاها پیوسته متراکم می‌سازند که روابط خطی معنایی را ثبت می‌کنند [۴۷]، [۴۸]؛ FastText با تجزیه واژه به n-gram ها با OOV بهتر کنار می‌آید [۴۹]؛ BERT تعبیه‌های وابسته به زمینه تولید می‌کند [۴۶]. مقایسه کیفی این روش‌ها با خوشه‌بندی معنایی بر اساس معیارهای سامانه‌های QA دامنه بسته (برگرفته از فرم پروپوزال رساله دکتری بنایی، دانشجوی آزمایشگاه تحقیقاتی پایگاه داده):

جدول ۱-۲. مقایسه کیفی روش‌های نمایش برداری متن.

معیار	Word2Vec/GloVe	BERT/Transformers	FastText	خوشه‌بندی معنایی
تطابق با دامنه تخصصی	محدود	متوسط تا بالا	متوسط	بالا
قابلیت تفسیر	کم تا متوسط	کم	کم تا متوسط	بالا
مدیریت واژگان جدید	متوسط	بالا	بالا	متوسط*

حجم داده آموزش	بزرگ	بزرگ	متوسط	کم
نیازمندی سخت افزاری	متوسط	بالا	متوسط	کم
امکان تعبیه پاراگراف/سند	کم تا متوسط	بالا	کم تا متوسط	بالا

* با سازوکار شبکه واژگان (فصل ۳) بهبود می یابد.

۲-۷. مبانی زیست‌الهامی: HTM و بازنمایی‌های پراکنده

طبق تحقیقات محققان هوش مصنوعی، علم اعصاب می‌تواند برای ایجاد ماشین‌های هوشمند ضروری باشد و مسیری به سمت تحقق هوش مصنوعی عمومی ایجاد کند [۱۲]. علوم اعصاب محاسباتی شاخه‌ای از علم اعصاب است که از داده‌های تجربی برای ساخت مدل‌های ریاضی و انجام تحلیل‌های نظری برای درک اصول حاکم بر توانایی‌های شناختی مغز استفاده می‌کند [۱۰]. از آنجایی که این رشته بر روی مدل‌های قابل قبول بیولوژیکی نوروها و سامانه‌های عصبی تمرکز دارد ولی به رشته‌های غیر بیولوژیکی مانند یادگیری ماشین و شبکه‌های عصبی مصنوعی توجهی ندارد [۱۹]. در این رابطه تلاش‌های زیادی برای مهندسی معکوس مغز پستانداران، به ویژه درک اصول محاسباتی neo-cortex شده است [۳۴]. بر اساس اصول محاسباتی شناخته شده neo-cortex این نظریه زیست‌شناسی مغز را به گونه‌ای توصیف می‌کند که متخصصان می‌توانند از آن برای ایجاد هوش مصنوعی عمومی استفاده کنند [۱۸].

برندون^{۱۶}، دانشمند علوم شناختی و همکارانش در سال ۲۰۱۷ مقاله‌ای [۱۲] در مورد "ساخت ماشین‌هایی که مانند انسان‌ها می‌آموزند و فکر می‌کنند" منتشر کرده‌اند، که به طور گسترده

^{۱۶} Brendon M. Lake .

موردتوجه جامعه هوش مصنوعی قرار گرفت و به عنوان مرجع زمینه در این مطالعه استفاده می‌شود. از سوی دیگر شرکت Numenta، سعی می‌کند ساختار neo-cortex را شبیه‌سازی و از این دانش برای ساختن سامانه‌های هوش مصنوعی استفاده کند. نظریه Numentas HTM و برنامه اجرای آن NuPIC^{۱۷} در گذشته با موفقیت برای تشخیص الگو و تشخیص ناهنجاری داده‌های جریانی استفاده شده است. حافظه زمانی سلسله مراتبی یک فناوری مبتنی بر هوش ماشینی با محدودیت بیولوژیکی است که توسط شرکت Numenta توسعه یافته است. در علم اعصاب مغز ما مدل‌هایی از بدن و محیط ما می‌سازد [۱۸]. یافتن اصول محاسباتی یکپارچه بر اساس neo-cortex مطمئناً امکان پیشرفت‌هایی را در محاسبات توزیع‌شده، هوش مصنوعی و درک ما از مغز فراهم می‌کند [۳۵].

با توجه به عدم یکپارچگی الگوریتم‌ها در محیط‌های چند رسانه‌ای، به سامانه‌ای نیاز است که مشابه با مغز انسان از ترکیب داده‌های تصویری، صوتی و متنی بتواند پاسخ سوالات را بدهد و وابسته به یک نوع داده خاص مثل متن نباشد [۱۵]. برای حل این موضوع، در یک دهه گذشته دانشمندان علوم اعصاب به بررسی عملکرد مغز و بررسی مسئله شناخت پرداخته‌اند که متوجه شده‌اند مغز انسان به جای اینکه یک موتور پردازشگر باشد یک حافظه پیش‌بینی‌کننده است [۳۴].

در واقع مبنای این ایده‌ها برای درک متن، روش خوشه‌بندی معنایی است که در سال ۲۰۱۶ توسط تیم تحقیقاتی Numenta پیشنهاد شد [۱۳]. این شرکت تحقیقاتی مدلی را برای شبیه‌سازی مغز انسان در محیط‌های محاسباتی پیشنهاد داده است که به حافظه زمانی سلسله مراتبی معروف است [۱۸]. براساس مدل محاسباتی حافظه زمانی سلسله مراتبی که برگرفته از عملکرد نوروهای عصبی پستانداران است، مدلی برای پردازش متن به نام خوشه‌بندی معنایی پیشنهاد شده که سعی در مدل‌سازی مغز انسان در مواجهه با کلمات و تشکیل نقشه معنایی در ذهن انسان بر اساس آن دارد. بر اساس این روش، مطالعات مختلفی در حوزه دسته‌بندی و کار با متون در چند سال اخیر انجام شده است که در همه آنها توان محاسباتی پایین و دقت بالا در مواجهه با داده‌های جدید، از جمله مزیت‌های برشمرده شده آن است [۱۳]، [۳۴]

نظریه حافظه زمانی سلسله‌مراتبی (HTM) هاوکینز و احمد (۲۰۱۶) مبنای محاسباتی رفتار نورون‌های قشر جدید مخ را چنین توصیف می‌کند [۱۰]: (الف) هر نورون هزاران سیناپس دارد و الگوهای زمینه‌ای را یاد می‌گیرد؛ (ب) در هر لحظه تنها حدود ۲٪ نورون‌ها فعال‌اند [۳۴]؛ (ج) اطلاعات در قالب بازنمایی‌های پراکنده توزیع شده (SDR) ذخیره می‌شود – بردارهای دودویی بزرگ که تعداد کمی از بیت‌هایشان فعال است و معنا در *الگوی توزیع* بیت‌های فعال نهفته است، نه در بیت منفرد [۱۳].

ویژگی‌های کلیدی SDR که مبنای طراحی این پژوهش‌اند (در بخش ۸-۴ به صورت تفصیلی به این ویژگی‌ها پرداخته شده است):

۱. **هم‌جوشی معنایی:** واژه‌های هم‌معنا الگوهای فعال‌سازی مشابه دارند.
۲. **تحمل نویز:** از دست رفتن بخشی از بیت‌ها، معنا را تخریب نمی‌کند.
۳. **ترکیب‌پذیری:** ادغام (OR) دو SDR یک SDR معنادار می‌سازد؛ حذف بیت‌های مشترک، تفاضل معنایی می‌دهد.
۴. **سرعت محاسباتی:** عملیات منطقی و ضرب داخلی روی بردارهای دودویی بسیار ارزان است.
۵. **فشرده‌گی:** با ذخیره صرفاً شاخص بیت‌های فعال (نمایه‌گذاری تنک) حجم ذخیره‌سازی حداقلی می‌شود.

پژوهش جاری در ادامه این موج جدید تحقیقاتی و به دنبال استفاده از روش خوشه‌بندی معنایی در حوزه بازیابی و پاسخگویی به سوالات انجام گرفته است.

۸-۲. خوشه‌بندی معنایی

۸-۲-۱. ایده اصلی خوشه‌بندی معنایی

Semantic Folding رویکردی برای تبدیل نمایش نمادین زبان، مانند کلمات و عبارات متنی، به یک نمایش فضایی و ساختاریافته است. ایده اصلی این رویکرد آن است که به جای نمایش یک واژه صرفاً به عنوان یک نماد مستقل، موقعیت آن در یک فضای معنایی توپولوژیک نیز در نظر گرفته شود.

در نظریه Semantic Folding، واژه‌ها بر اساس روابط معنایی و توزیعی میان آن‌ها در یک فضای دوبعدی قرار می‌گیرند. در نتیجه، واژه‌هایی که از نظر معنایی یا زمینه‌ای به یکدیگر نزدیک هستند، در بخش‌های نزدیک‌تری از این فضا قرار می‌گیرند. سپس این موقعیت فضایی می‌تواند برای ایجاد یک نمایش sparse از متن مورد استفاده قرار گیرد. در مقاله اصلی Semantic Folding، این فرآیند به عنوان تبدیل نمایش نمادین زبان به یک نمایش sparse و مبتنی بر موقعیت در یک فضای معنایی مطرح شده است. ([arXiv](https://arxiv.org/abs/1908.08080))

۲-۸-۲. Semantic Space

نقشه معنایی، فضایی است که در آن عناصر زبانی بر اساس روابط معنایی یا توزیعی خود سازمان‌دهی می‌شوند.

در پروژه حاضر، این مفهوم به صورت یک فضای دوبعدی پیاده‌سازی شده است. ابتدا برای عبارات موجود در واژگان، یک نمایش مبتنی بر اطلاعات زمینه‌ای ساخته می‌شود. سپس با استفاده از روش کاهش بُعد، این نمایش چندبعدی به مختصات دوبعدی تبدیل می‌شود.

۲-۸-۳. Topological Representation

یکی از ایده‌های مهم Semantic Folding، استفاده از نمایش توپولوژیک است.

در نمایش معمولی، ممکن است دو مفهوم کاملاً متفاوت از نظر شناسه عددی، مثلاً:

cat → 125

dog → 782

باشند و فاصله عددی بین آن‌ها هیچ معنای خاصی نداشته باشد.

اما در یک نمایش توپولوژیک، هدف این است که روابط و همسایگی عناصر حفظ شود.

مثلاً:

animal

•

• •

cat dog

در این حالت، **cat** و **dog** در یک ناحیه معنایی قرار می‌گیرند و **animal** نیز در نزدیکی آن‌ها قرار دارد.

بنابراین اطلاعاتی مانند:

- همسایگی
- فاصله
- ساختار محلی
- ارتباط میان مفاهیم

می‌تواند بخشی از نمایش متن شود.

این ایده با هدف Semantic Folding برای ایجاد یک فضای معنایی توپولوژیک و سپس تبدیل آن به نمایش sparse مرتبط است. ([arXiv](https://arxiv.org/))

۲-۸-۴. Semantic Fingerprint

Semantic Fingerprint نمایش فشرده‌ای از یک عنصر زبانی بر اساس موقعیت آن در فضای معنایی است. در نتیجه، عبارت به جای یک شناسه ساده، دارای یک **الگوی فضایی** می‌شود.

در نظریه Semantic Folding، این فرآیند به تولید یک نمایش sparse و مبتنی بر موقعیت معنایی منجر می‌شود. ([arXiv](#))

۲-۸-۵. ارتباط Semantic Folding با پروژه حاضر

در پروژه حاضر، ایده Semantic Folding به صورت یک pipeline محاسباتی پیاده‌سازی شده است. روند کلی به صورت زیر است:

Corpus



Phrase Extraction



Term/Context Representation



TF-IDF + Co-occurrence



Dimensionality Reduction



2D Semantic Space



64×64 Grid



Phrase Fingerprint



Document Fingerprint

بنابراین در این پژوهش، **Semantic Folding** صرفاً به عنوان یک مفهوم نظری استفاده نشده است؛ بلکه به عنوان مبنایی برای ایجاد نمایش فضایی عبارات و اسناد در سیستم بازیابی مورد استفاده قرار گرفته است.

۹-۲. کاهش بُعد و نگاشت به فضای معنایی

پس از ایجاد نمایش زمینه‌ای برای عبارات، مشکل مهمی وجود دارد: این نمایش معمولاً دارای تعداد زیادی بُعد به اندازه تعداد ویژگی‌های زمینه‌ای است که برای ایجاد Semantic Space دوبردی، لازم است ابعاد به دو بعد کاهش پیدا کند که به این فرآیند **Dimensionality Reduction** گفته می‌شود.

سه روش مهم زمینه کاهش بُعد، عبارت‌اند از:

* PCA

* t-SNE

* UMAP

۲-۹-۱. PCA

Principal Component Analysis (PCA) یک روش کاهش بُعد خطی است.

ایده اصلی PCA پیدا کردن محورهایی از فضای چندبعدی است که بیشترین میزان واریانس موجود در داده را توضیح می‌دهند و ادامه دادن این روند تا رسیدن به فضای دوبعدی است.

مزیت مهم PCA سرعت بالا و سادگی آن است و همچنین مؤلفه‌های آن بر اساس واریانس داده قابل تفسیر هستند.

اما محدودیت اصلی PCA این است که یک روش **خطی** است. بنابراین اگر ساختار واقعی داده در یک manifold غیرخطی قرار داشته باشد، PCA ممکن است نتواند روابط پیچیده میان نقاط را به خوبی حفظ کند. منابع مروری نیز PCA را در مقابل روش‌های غیرخطی مانند t-SNE و UMAP قرار می‌دهند. ([arXiv](https://arxiv.org/)))

۲-۹-۲. t-SNE

t-Distributed Stochastic Neighbor Embedding (t-SNE) یک روش کاهش بُعد غیرخطی است که تمرکز اصلی آن حفظ ساختار محلی داده‌ها است.

به زبان ساده، t-SNE تلاش می‌کند نقاطی که در فضای اصلی همسایه یکدیگر بوده‌اند، در فضای دوبعدی نیز تا حد امکان نزدیک بمانند.

این ویژگی باعث شده است t-SNE برای مشاهده ساختارهای محلی و خوشه‌ها بسیار محبوب باشد.

با این حال، t-SNE برای داده‌های بزرگ پرهزینه است و تفسیر فاصله‌های global در خروجی آن نیز باید با احتیاط انجام شود. ([arXiv](#))

۲-۹-۳. UMAP

Uniform Manifold Approximation and Projection (UMAP) یا تقریب و تصویر منیفولد یکنواخت یک روش کاهش بُعد غیرخطی و مبتنی بر ایده‌های manifold learning و توپولوژی است.

UMAP تلاش می‌کند ساختار همسایگی داده‌ها را در فضای کم‌بعدی حفظ کند و در مقایسه با t-SNE معمولاً مقیاس‌پذیری بهتری دارد. مقاله اصلی UMAP آن را روشی عملی و مقیاس‌پذیر برای کاهش بُعد معرفی می‌کند که از نظر کیفیت embedding با t-SNE رقابت می‌کند و می‌تواند ساختار global بیشتری را حفظ کند. ([arXiv](#))

۲-۹-۴. علت انتخاب UMAP در پروژه

در واقع انتخاب UMAP در پروژه حاضر با ماهیت مسئله سازگار است. هدف صرفاً کاهش تعداد ابعاد نیست؛ بلکه خواسته این است که عباراتی که در فضای زمینه‌ای مشابه هستند، در فضای دوبعدی نیز موقعیت‌های نسبتاً نزدیک داشته باشند.

از طرف دیگر، Semantic Folding به یک فضای توپولوژیک و spatial نیاز دارد. UMAP نیز به‌طور مشخص با ساختار همسایگی و manifold داده‌ها سروکار دارد. ([arXiv](#))

لذا با توجه به ماهیت غیرخطی فضای زمینه‌ای، اهمیت حفظ ساختار همسایگی و نیاز پروژه به نگاشت عبارات به یک فضای دوبعدی و همچنین پر هزینه بودن t-SNE برای داده‌های بزرگ و از طرفی بهتر بودن نتایج در کاهش ابعاد در روش UMAP نسبت به t-SNE، در نهایت UMAP به عنوان روش اصلی کاهش بُعد انتخاب شد.

مطابق با متن مقاله اصلی UMAP، رفتار این روش به داده‌ها و پارامترها وابسته است، لذا در برخی موارد ساختار global را بهتر از t-SNE حفظ می‌کند؛ با این وجود دلیل انتخاب این روش بهترین گزینه بودن UMAP در برخی شرایط بر اساس ماهیت داده، ساختار همسایگی، غیرخطی بودن و نیاز pipeline به نگاشت دوبعدی است. ([arXiv](#))

بنابراین در پروژه حاضر زنجیره زیر شکل می‌گیرد:

Context Similarity → UMAP Neighborhood → 2D Position → Spatial Fingerprint

[text{Context Similarity}]

rightarrow

text{UMAP Neighborhood}

rightarrow

text{2D Position}

rightarrow

text{Spatial Fingerprint}]

اثرانگشت یک نمایش عددی و فضایی از متن است که ویژگی‌های اصلی متن را در قالب مجموعه‌ای از موقعیت‌ها با سلول‌های فعال نمایش می‌دهد.

هدف این نیست که کل متن به صورت مستقیم ذخیره شود؛ بلکه اطلاعات مربوط به موقعیت و ساختار معنایی آن در یک نمایش فشرده‌تر ذخیره می‌شود. ([arXiv](#))

۲-۱۰-۲. Phrase Fingerprint

اولین سطح fingerprint مربوط به **Phrase** است که در آن سلول‌های مربوط به مفاهیم معنایی مستقلی که عبارت در آنها بوده است، فعال است. در پروژه جاری شبکه 64×64 در نظر گرفته شده است؛ در نتیجه هر phrase یک fingerprint با اندازه 64×64 دارد و بنابراین هر عبارت را می‌توان با یک بردار 4096 بعدی نمایش داد.

۲-۱۰-۳. Document Fingerprint

یک سند معمولاً شامل چندین phrase است. بنابراین برای تولید اثرانگشت سند که نماینده فضایی کل سند است، لازم است که fingerprintهای عبارات موجود در سند را با وزن‌های مناسب تجمیع و با یکدیگر ترکیب کرد. جزئیات وزن‌دهی اثرانگشت عبارات در فصل سوم ارائه شده است.

۲-۱۰-۴. Spatial Representation

نکته مهم در روش SF این است که fingerprint فقط یک بردار عددی معمولی نیست؛ بلکه ساختار فضایی دارد که در آن هر نقطه یا سلول می‌تواند نشان‌دهنده حضور یک

phrase یا بخشی از اطلاعات معنایی آن باشد. سپس این شبکه می‌تواند برای محاسبه شباهت میان query و document مورد استفاده قرار گیرد. بنابراین در fingerprint، نزدیکی فضایی نیز حامل اطلاعات است.

۲-۱۰-۵. Morton Z-order

برای تبدیل ساختار دوبعدی شبکه به یک نمایش خطی، در پروژه از **Morton Z-order** **encoding** استفاده می‌شود. Morton Z-order برای نگاشت و یا نمایه‌سازی مکانی (spatial indexing) مختصات دوبعدی و مدیریت برخوردها (collision handling) استفاده می‌شود؛ که در آن معیار اصلی مقایسه بین fingerprint پرس‌وجو و سند، شباهت کسینوسی است. همچنین SSIM نیز به‌عنوان یک روش جایگزین برای بررسی ساختاری fingerprintها در بنچمارک تکمیلی ارزیابی شده است.

ایده Morton order این است که مختصات دوبعدی (row,col) با درهم‌تنیدن بیت‌های دو مختصات، به یک index تبدیل شوند.

برای مثال به صورت مفهومی:

row = 101	row = 101
col = 011	
interleave:	col = 011
1 0 1	interleave:
0 1 1	
→ 100111	1 0 1
	0 1 1
	→ 100111

در نتیجه یک مختصات دوبعدی می‌تواند به یک بردار خطی تبدیل شود.

مزیت این روش این است که می‌توان شبکه دوبعدی را به یک بردار خطی تبدیل کرد و در عین حال تا حدی محلی‌بودن فضایی را حفظ کرد.

این بخش در قسمت پیاده‌سازی اهمیت زیادی دارد، زیرا فایل fingerprint نهایی به شکل ماتریسی با ابعاد تعداد عبارات در ۴۰۹۶ ذخیره می‌شود.

$$N_{phrases} \times 4096$$


$$[N_{\{phrases\}} \times 4096]$$

۶-۱۰-۲. هموارسازی گاوسی (Gaussian Smoothing)

در Gaussian smoothing، مقدار Gaussian روی اثرانگشت عبارت یا سند اعمال می‌شود تا فعال‌سازی مکانی نرم‌تر شود و به جای اینکه فعال‌سازی یک سلول به شکل کاملاً گسسته باقی بماند، در اطراف سلول نیز به صورت تدریجی پخش می‌شود. این روش برای پایدارسازی نمایش به کار می‌رود.

به صورت مفهومی:

کم



کم

مرکز بیشترین activation را دارد و هرچه از مرکز دور شویم، مقدار activation کاهش پیدا می‌کند.

بنابراین به جای بردار $(0 \ 0 \ 0 \ 1 \ 0 \ 0 \ 0 \ 0)$ چیزی شبیه $(0/01 \ 0/05 \ 0/25 \ 1/0 \ 0/25 \ 0/05 \ 0/01)$ ایجاد می‌شود. در نتیجه، fingerprint نسبت به جابه‌جایی‌های بسیار کوچک در فضای معنایی مقاوم‌تر (**robust**) می‌شود.

۷-۱۰-۲. پراکندگی فضایی (Spatial Spreading)

اگر برای هر عبارت فقط یک سلول مربوط به آن فعال شود، کوچک‌ترین تغییر در موقعیت عبارت می‌تواند باعث تغییر شدید اثرانگشت شود. برای جلوگیری از این تغییرات شدید فقط هنگام پردازش پرس‌وجو و برای بالا بردن تحمل نویز و خطا، علاوه بر Gaussian smoothing، در pipeline از **spreading** نیز برای گسترش مکانی فعال‌سازی استفاده می‌شود.

برای مثال:

قبل:

0 0 1 0 0

بعد:

0 1 0 0 0

اگر صرفاً exact cell matching داشته باشیم، این دو نمایش کاملاً متفاوت به نظر می‌رسند. برای کاهش این حساسیت، می‌توان activation را به سلول‌های اطراف نیز گسترش داد:

این همان ایده **spatial spreading** است. این روش برای پایداری نمایش به کار می‌رود.

در نتیجه اگر دو phrase در فضای معنایی نزدیک باشند، fingerprint آن‌ها نیز می‌تواند همپوشانی بیشتری داشته باشد.

این ویژگی دقیقاً برای retrieval اهمیت دارد.

SPLADE ۱۱-۲ و بازیابی Sparse عصبی

۱۱-۲-۱. ایده اصلی SPLADE

با گسترش روش‌های بازیابی عصبی، یکی از رویکردهای مهم، استفاده از نمایش‌های **sparse عصبی** به جای نمایش‌های dense بوده است. مدل **SPLADE (Sparse Lexical and Expansion Model for First Stage Ranking)** با هدف ایجاد یک نمایش sparse برای پرس‌وجو و سند ارائه شده است.

ایده اصلی SPLADE این است که از یک مدل زبانی مبتنی بر BERT استفاده شود تا برای متن ورودی، یک بردار با ابعاد متناظر با واژگان مدل ایجاد شود؛ اما برخلاف embedding های dense، تنها تعداد محدودی از ابعاد دارای مقدار غیرصفر باشند. این نمایش از طریق **regularization مربوط به sparsity** و تابع **log-saturation** به سمت نمایش‌های sparse هدایت می‌شود. ([arXiv](https://arxiv.org/abs/2005.00690))

SPLADE به طور مشخص برای ایجاد بازنمایی‌های sparse از پرس‌وجو و سند طراحی شده و هدف آن ترکیب مزایای مدل‌های عصبی با ویژگی‌هایی مانند تطبیق واژگانی صریح و نمایه‌سازی مبتنی بر inverted index است. ([arXiv](#))

به صورت ساده می‌توان روند را چنین نمایش داد:

Query / Document



BERT



Contextual representations



MLM vocabulary projection



Weighted vocabulary terms



Sparse vector

بنابراین برخلاف روش‌هایی که متن را مستقیماً به یک بردار dense با مثلاً چند صد یا چند هزار مؤلفه تبدیل می‌کنند، SPLADE تلاش می‌کند یک بردار بسیار بزرگ اما **sparse** ایجاد کند.

۲-۱۱-۲. Sparse Lexical Expansion

یکی از ویژگی‌های مهم SPLADE، مفهوم **Lexical Expansion** است.

در روش‌های واژگانی سنتی، تطبیق معمولاً زمانی اتفاق می‌افتد که واژه‌های پرس‌وجو و سند با یکدیگر اشتراک داشته باشند.

برای مثال:

Query:

"car repair"

Document:

"automobile maintenance"

در یک روش lexical ساده، ممکن است تطبیق بسیار کمی وجود داشته باشد، زیرا:

car $\neq$ automobile

repair $\neq$ maintenance

SPLADE تلاش می‌کند با استفاده از مدل زبانی، علاوه بر واژه‌های صریح موجود در متن، **واژه‌های مرتبطی را نیز فعال کند.**

به صورت مفهومی:

Query

"car repair"



Sparse Expansion



car

repair

automobile

maintenance

vehicle

...

بنابراین دو متن ممکن است حتی در صورت نداشتن تطابق واژگانی کامل، از طریق واژه‌های گسترش‌یافته امکان تطبیق پیدا کنند.

این ویژگی یکی از تفاوت‌های مهم SPLADE با روش‌هایی مانند ۲۵BM است. در SPLADE، expansion توسط یک مدل عصبی آموخته می‌شود، در حالی که ۲۵BM عمدتاً بر تطبیق واژگان موجود در پرس‌وجو و سند تکیه دارد. مقاله اصلی SPLADE دقیقاً بر ترکیب **lexical matching** و **learned expansion** تأکید دارد. ([arXiv](https://arxiv.org/abs/2005.00371))

۳-۱۱-۲. چرا SPLADE همچنان Sparse است؟

یک سؤال مهم این است که اگر SPLADE قرار است واژگان جدیدی را فعال کند، چرا خروجی آن dense نمی‌شود؟

فرض کنید واژگان مدل دارای ۳۰,۰۰۰ بعد باشد، یک نمایش dense ممکن است تقریباً همه این ابعاد را دارای مقدار غیرصفر کند:

[0.12, 0.31, 0.07, 0.44, ...]

اما SPLADE تلاش می‌کند چیزی شبیه این ایجاد کند:

[0, ..., 0, 0.83, 0.41, 0, ..., 0]

SPLADE برای دستیابی به این هدف از regularization مربوط به sparsity استفاده می‌کند. در نسخه اصلی، این سازوکار با هدف ایجاد توازن میان اثربخشی بازیابی و هزینه محاسباتی طراحی شده است. ([arXiv](#))

۴-۱۱-۲. استفاده از نمایه‌سازی معکوس (Inverted Index)

یکی از مزایای مهم sparse بودن SPLADE این است که می‌توان نمایش تولیدشده را با ساختارهای سنتی بازیابی مانند **نمایه‌سازی معکوس** مورد استفاده قرار داد.

این ویژگی تفاوت مهمی با بسیاری از روش‌های dense retrieval دارد.

در روش dense:

Document



Dense Vector



ANN Search



Nearest Documents

اما در SPLADE:

Document



Sparse Vector



Inverted Index



Candidate Documents

در نتیجه SPLADE می‌تواند بخشی از مزایای روش‌های کلاسیک lexical retrieval، مانند
تطبیق صریح واژگان و استفاده از inverted index، را با قابلیت‌های مدل‌های عصبی
ترکیب کند. (arXiv)

۵-۱۱-۲. مزایای SPLADE

مهم‌ترین مزایای SPLADE را می‌توان در چند مورد خلاصه کرد.

۱. حفظ lexical matching

چون خروجی SPLADE روی واژگان مدل تعریف شده است، تطبیق صریح واژگان همچنان
امکان‌پذیر است.

۲. امکان lexical expansion

مدل می‌تواند واژه‌هایی را فعال کند که به صورت صریح در متن اولیه وجود ندارند اما از نظر معنایی یا زمینه‌ای برای بازیابی مفید هستند. ([arXiv](#))

۳. استفاده از inverted index

Sparse بودن نمایش اجازه می‌دهد از ساختارهای کارآمد بازیابی sparse استفاده شود. ([GitHub](#))

۴. ترکیب قابلیت‌های مدل زبانی و retrieval واژگانی

SPLADE تلاش می‌کند میان دو رویکرد زیر قرار گیرد:

Lexical Retrieval



SPLADE



Neural Retrieval

به همین دلیل، SPLADE را می‌توان یک **neural sparse retriever** دانست. ([GitHub](#))

۶-۱۱-۲. محدودیت‌های SPLADE

با وجود مزایای SPLADE، این روش محدودیت‌هایی نیز دارد.

اولین مسئله، **هزینه محاسباتی تولید representation** است. برخلاف ۲۵BM که می‌تواند مستقیماً روی متن و index واژگانی عمل کند، SPLADE برای تولید نمایش به یک مدل زبانی عصبی نیاز دارد.

محدودیت دیگر، وابستگی نمایش sparse به **واژگان مدل زبانی** است. نسخه‌های اصلی SPLADE روی واژگان WordPiece مدل BERT تعریف شده‌اند؛ پژوهش‌های بعدی مانند Expanded-SPLADE نیز دقیقاً به مسئله امکان استفاده از واژگان دلخواه پرداخته‌اند. ([Google Research](#))

همچنین میزان sparsity با کیفیت بازیابی و هزینه retrieval در تعامل است. پژوهش SPLADE نشان می‌دهد که تنظیم regularization می‌تواند trade-off میان **effectiveness** و **efficiency** را تغییر دهد. ([arXiv](#))

۷-۱۱-۲. نقش SPLADE در پروژه حاضر

در پژوهش حاضر، Semantic Folding و SPLADE دو نمایش متفاوت از متن ایجاد می‌کنند.

Semantic Folding:

Text



Phrase Extraction



term_Context_matrix



Semantic Space



Spatial Fingerprint

SPLADE:

Text



Language Model



Sparse Lexical Expansion



Sparse Vector

بنابراین این دو روش از دو دیدگاه متفاوت به متن نگاه می‌کنند:

نوع اطلاعات اصلی

روش

ساختار فضایی و زمینه‌ای

Semantic Folding

اطلاعات واژگانی + expansion عصبی

SPLADE

در پروژه حاضر، هدف از استفاده از SPLADE، ایجاد یک مسیر بازیابی مکمل برای Semantic Folding است.

یعنی رتبه مقایسه پرس‌وجو و اسناد از مسیر Semantic Folding و SPLADE به صورت جداگانه محاسبه می‌شود، سپس می‌توان این دو رتبه را با روش‌های fusion ترکیب کرد.

این طراحی امکان بررسی این سؤال پژوهشی را فراهم می‌کند که:

آیا ترکیب نمایش فضایی Semantic Folding با نمایش sparse عصبی SPLADE می‌تواند نسبت به استفاده مستقل از هر یک، کیفیت بازیابی را بهبود دهد؟

که طبق آزمایشات گرفته شده، مشخص شد جواب مثبت است.

۲-۱۱-۸. Hybrid Retrieval

بازیابی ترکیبی ((Hybrid Retrieval به رویکردی گفته می‌شود که در آن نتایج حاصل از بیش از یک روش بازیابی با یکدیگر ترکیب می‌شوند.

SPLADE یک **neural sparse retriever** است؛ که خروجی آن sparse است، تولید این sparse representation توسط یک مدل عصبی انجام می‌شود؛ پس بهتر است SPLADE با **BM25** و **Dense Retrieval** ترکیب نشود ([GitHub](#)). همین ویژگی SPLADE است که منجر به انتخاب آن برای بخش Hybrid پروژه جاری شد؛ لذا منظور از بازیابی ترکیبی در این پژوهش با توجه به ترکیب نتایج دو روش SF و SPLADE به معنای ترکیب دو نوع اطلاعات مکمل است.

۲-۱۱-۹. Sparse–Dense Hybrid Retrieval

یک شکل رایج دیگر از hybrid retrieval، ترکیب یک retriever sparse و یک retriever dense است. ایده اصلی این است که این دو روش نقاط قوت متفاوتی دارند. به همین دلیل ترکیب sparse و dense می‌تواند اطلاعات مکملی را در اختیار سیستم retrieval قرار دهد.

۲-۱۱-۱۰. Hybrid Retrieval در پژوهش حاضر


در پژوهش حاضر، ساختار hybrid کمی متفاوت و در واقع متناسب با هدف اصلی پژوهش است:


[boxed{Semantic Folding + SPLADE}]

یعنی یک مسیر مبتنی بر **spatial representation** و یک مسیر مبتنی بر **neural sparse lexical expansion** در کنار یکدیگر قرار می‌گیرند.

ساختار کلی:

Query





در این معماری، ترکیب **Linear** و **RRF** دو روش متفاوت برای آزمایش هستند. بنابراین می‌توان در فصل نتایج مقایسه کرد که SF در برابر SPLADE و همچنین $\{SF+SPLADE_RRF\}$ در برابر $\{SF+SPLADE_linear\}$ چه عملکردی دارد.

در پروژه حاضر از این طراحی استفاده شده است؛ چون به جای اینکه SPLADE صرفاً به عنوان یک baseline معرفی شود، از آن به عنوان **مسیر مکمل برای ارزیابی توان Semantic Folding هم** استفاده شده است.

نکته: از نظر مفهومی، **Semantic Folding** و **SPLADE** رقیب صرف نیستند؛ می‌توانند مکمل یکدیگر باشند Semantic Folding : ساختار فضایی حاصل از روابط زمینه‌ای را وارد retrieval می‌کند، در حالی که SPLADE از یک مدل زبانی برای ایجاد نمایش sparse همراه با lexical expansion استفاده می‌کند. خود پژوهش SPLADE نیز هدف اصلی خود را ایجاد نمایش‌های sparse عصبی با مزایای lexical matching و inverted index معرفی می‌کند. ([arXiv](#))

۱۲-۲. معیارهای ارزیابی

ارزیابی عملکرد سامانه‌های بازیابی اطلاعات نیازمند معیارهایی است که بتوانند کیفیت رتبه‌بندی اسناد بازیابی‌شده را اندازه‌گیری کنند. در این پژوهش، با توجه به ماهیت مسئله و خروجی سامانه، معیارهایی مانند **Mean Reciprocal Rank (MRR)**، **Average Precision (AP)** و **Normalized Discounted Cumulative Gain (NDCG)** مورد استفاده قرار می‌گیرند. این معیارها از جنبه‌های متفاوتی کیفیت نتایج بازیابی را بررسی می‌کنند.

۱-۱۲-۲. معیار MRR

معیار **Mean Reciprocal Rank** بر موقعیت اولین سند مرتبط در فهرست نتایج تمرکز دارد. برای یک پرس‌وجو، اگر اولین سند مرتبط در رتبه r قرار داشته باشد، مقدار Reciprocal Rank برابر است با:

$$[RR = \frac{1}{r}]$$

بنابراین، اگر اولین سند مرتبط در رتبه اول باشد $RR = 1$ و اگر در رتبه پنجم قرار داشته باشد $RR = \frac{1}{5}$ است.

در مجموعه‌ای شامل (N) پرس‌وجو، مقدار MRR از میانگین Reciprocal Rank پرس‌وجوها به دست می‌آید:

$$[MRR=\frac{1}{N}\sum_{i=1}^N\frac{1}{rank_i}]$$

بنابراین MRR به‌خصوص برای کاربردهای پرسش‌وپاسخ اهمیت دارد؛ زیرا نشان می‌دهد سامانه تا چه اندازه قادر است اولین سند مرتبط را در رتبه‌های بالای نتایج قرار دهد.

در پروژه حاضر، MRR می‌تواند برای بررسی این موضوع استفاده شود که آیا fingerprintهای تولیدشده از Semantic Folding قادر هستند سند مرتبط با پرس‌وجو را در رتبه‌های بالای فهرست بازیابی قرار دهند یا خیر.

۲-۱۲-۲. معیار AP و MAP

در حالی که MRR عمدتاً بر اولین سند مرتبط تمرکز دارد، معیار Average Precision (AP) کیفیت رتبه‌بندی چندین سند مرتبط را در فهرست نتایج در نظر می‌گیرد.

به‌صورت ساده، AP میانگین Precision در رتبه‌هایی است که در آن‌ها یک سند مرتبط مشاهده شده است. اگر مجموعه اسناد مرتبط برای پرس‌وجو را (R) در نظر بگیریم، AP را می‌توان به صورت زیر بیان کرد:

$$[AP=\frac{1}{|R|}\sum_{k=1}^n P(k)\times rel(k)]$$

که در آن:

- $P(k)$: مقدار Precision تا رتبه (k)
- $rel(k)$: مشخص می‌کند سند رتبه (k) مرتبط است یا خیر.
- $|R|$: تعداد اسناد مرتبط با پرس‌وجو

بنابراین AP از ترکیب Precisionهای این نقاط مرتبط به دست می‌آید.

وقتی AP برای چندین پرس‌وجو محاسبه و سپس میانگین گرفته شود، معیار **MAP** (**Mean Average Precision**) به دست می‌آید:

$$[MAP = \frac{1}{N} \sum_{i=1}^N AP_i]$$

۲-۱۲-۳. معیار **NDCG@K**

معیار **Normalized Discounted Cumulative Gain** علاوه بر مرتبط بودن اسناد، به **موقعیت آن‌ها در رتبه‌بندی** نیز توجه می‌کند.

ایده اصلی این است که یک سند مرتبط در رتبه اول ارزش بیشتری از همان سند در رتبه دهم دارد.

ابتدا مقدار DCG محاسبه می‌شود:

$$[DCG@K = \sum_{i=1}^K \frac{2^{\{rel_i\}-1}}{\log_2(i+1)}]$$

سپس مقدار به دست آمده نسبت به بهترین رتبه‌بندی ممکن نرمال می‌شود:

$$[NDCG@K = \frac{DCG@K}{IDCG@K}]$$

در نتیجه مقدار NDCG معمولاً بین صفر و یک قرار می‌گیرد و مقدار بالاتر نشان‌دهنده رتبه‌بندی بهتر است.

این معیار برای پروژه حاضر اهمیت دارد، زیرا ممکن است یک پرس‌وجو چندین سند مرتبط داشته باشد و تنها پیدا کردن اولین سند مرتبط کافی نباشد؛ بلکه **ترتیب قرار گرفتن اسناد مرتبط در نتایج** نیز اهمیت داشته باشد.

۲-۱۳. مجموعه داده‌های ارزیابی

برای ارزیابی یک روش بازایی چندزبانه، انتخاب مجموعه داده مناسب اهمیت زیادی دارد؛ زیرا مجموعه داده باید علاوه بر پوشش زبانی مناسب، دارای پرس و جوها، اسناد و قضاوت‌های relevance قابل استفاده برای ارزیابی رتبه‌بندی باشد.

در این پژوهش، مجموعه داده ^{۱۸}CAREN_Belebele به عنوان یک منبع برای بررسی قابلیت‌های چندزبانه در نظر گرفته شده است و مجموعه داده‌های Mr. TyDi و MIRACL چون مستقیماً برای مسائل retrieval طراحی شده‌اند و برای ارزیابی بخش retrieval پروژه مکمل خوبی هستند.

۲-۱۳-۱. CAREN_Belebele

Belebele یک مجموعه داده چندزبانه برای ارزیابی **Machine Reading Comprehension** است که ۱۲۲ گونه زبانی را پوشش می‌دهد. هر نمونه شامل یک متن کوتاه، یک سؤال و چهار گزینه پاسخ است. داده‌ها بر اساس متن‌های FLORES-۲۰۰ ساخته شده‌اند و به دلیل ساختار موازی مجموعه داده، امکان مقایسه عملکرد مدل‌ها در زبان‌های مختلف فراهم شده است. ([ACL Anthology](#))

بنابراین Belebele از نظر چندزبانه بودن برای پژوهش حاضر جذاب است، اما باید توجه داشت که:

مجموعه داده Belebele یک benchmark اصلی برای passage retrieval نبود. به همین دلیل، برای استفاده از آن برای ارزیابی مستقیم رتبه‌بندی اسناد Semantic Folding یک پروتکل ارزیابی مناسب طراحی شد که در نهایت منجر به تولید دیتاست CAREN_Belebele برای استفاده به عنوان بنچمارک شد.

^{۱۸} Custom AR-EN Belebele .

Mr. TyDi یک benchmark برای بازیابی تک‌زبانه (**monolingual information retrieval**) است که در ۱۱ زبان با ویژگی‌های زبانی متفاوت طراحی شده است. که با هدف ارزیابی روش‌های بازیابی متراکم در زبان‌های غیرانگلیسی ایجاد و معرفی شده است. ([ACL Anthology](#))

نکته مهم این است که Mr. TyDi در اصل Cross-Lingual Retrieval نیست؛ بلکه مسئله آن عمدتاً بازیابی تک‌زبانه است؛ به عبارتی دیگر در این بنچمارک پرسش و اسناد مورد بازیابی در یک زبان قرار دارند. بنابراین اگر Semantic Folding را روی Mr. TyDi ارزیابی کنیم، می‌توانیم بررسی کنیم که آیا روش پیشنهادی در زبان‌های مختلف و خارج از انگلیسی توانایی حفظ عملکرد خود را دارد یا خیر.

پژوهش اصلی Mr. TyDi همچنین نتیجه جالبی گزارش می‌کند: baseline مبتنی بر mDPR در آزمایش‌های آن‌ها به‌طور قابل توجهی از ۲۵BM ضعیف‌تر بود، اما نمایش‌های dense اطلاعات مرتبط ارزشمندی ارائه کردند و ترکیب sparse و dense توانست نتایج ۲۵BM را بهبود دهد. (([ACL Anthology](#)))

MIRACL یک benchmark چندزبانه برای **ad hoc retrieval** است که ۱۸ زبان را پوشش می‌دهد و داده‌های آن بر پایه Wikipedia ایجاد شده‌اند.

این مجموعه شامل بیش از ۷۲۶,۰۰۰ قضاوت relevance برای حدود ۷۸,۰۰۰ پرس‌وجو است. ارزیابی‌ها توسط گویشوران بومی زبان‌های مربوطه انجام شده‌اند. ([MIT Press Direct](#))

یکی از تفاوت‌های مهم MIRACL با Mr. TyDi، تعداد و تنوع قضاوت‌های relevance است. در Mr. TyDi، به‌طور میانگین برای هر پرس‌وجو تنها حدود یک متن مرتبط وجود دارد، در حالی که MIRACL برای پرس‌وجوها تعداد بیشتری برچسب مثبت و منفی فراهم می‌کند. ([MIT Press Direct](#))

این ویژگی برای معیارهایی مانند:

• AP / MAP

• NDCG

مهم است، زیرا این معیارها زمانی اطلاعات بیشتری ارائه می‌کنند که برای هر پرس‌وجو چندین سند مرتبط وجود داشته باشد.

بنابراین می‌توان گفت:

Mr. TyDi برای ارزیابی ranking و مقایسه با baseline‌هایی مانند BM25 و dense retrieval بسیار مناسب است، در حالی که MIRACL به دلیل تعداد بیشتر قضاوت‌های relevance، برای تحلیل دقیق‌تر کیفیت رتبه‌بندی و hybrid retrieval نیز ارزش بالایی دارد.

۴-۱۳-۲. مجموعه داده XOR-TyDi

یک نمونه مهم از بازیابی بین زبانی XOR-TyDi QA است که مسئله متفاوتی را بررسی می‌کند. این مجموعه داده طراحی شده است تا مشخصاً مسئله Cross-Lingual Open Retrieval Question Answering را هدف قرار دهد. ([ACL Anthology](#))

XOR-TyDi شامل حدود ۴۰ هزار پرسش و پاسخ در ۷ زبان غیرانگلیسی است و از پرسش‌هایی در TyDi QA ساخته شده که برای آن‌ها در همان زبان پاسخ مناسبی پیدا نشده بود. ([ACL Anthology](#))

در این مسئله، ممکن است پرسش به زبان یک کشور مطرح شود، اما اطلاعات مورد نیاز برای پاسخ در منابع انگلیسی یا زبان دیگری قرار داشته باشد.

XOR-TyDi سه سطح وظیفه را نیز معرفی می‌کند:

۱. XOR-RETRIEVE: بازیابی passage‌های انگلیسی دارای اطلاعات لازم برای پاسخ.

۲. XOR-ENGLISHSPAN: پیدا کردن span پاسخ در passage‌های بازیابی‌شده.

۳. XOR-FULL: تولید پاسخ نهایی در زبان پرسش با استفاده از منابع انگلیسی و

زبان هدف. ([ACL Anthology](#))

بنابراین XOR-TyDi برخلاف Mr. TyDi، مستقیماً یک cross-lingual open-retrieval multilingual QA benchmark است. ولی با توجه به تمرکز این پژوهش بر monolingual retrieval در محیط بسته، TyDi-XOR در بنچمارک‌های این پژوهش استفاده نشده است.

۱۴-۲. پیشینه پژوهش

پیشینه پژوهش در این حوزه را نمی‌توان صرفاً به معرفی ترتیبی مقالات محدود کرد؛ زیرا روش‌های بازیابی اطلاعات در سال‌های اخیر از روش‌های مبتنی بر تطبیق واژگانی به سمت نمایش‌های dense، sparse neural و روش‌های hybrid حرکت کرده‌اند.

برای ایجاد یک ساختار منطقی، در این بخش، مطالعات مرتبط در شش دسته اصلی بررسی و در پایان، جایگاه دقیق پژوهش حاضر نسبت به آن‌ها مشخص شده است.

۲-۱۴-۱. روش‌های بازیابی واژگانی و کلاسیک

پایه‌ای‌ترین چارچوب نظری این حوزه، چارچوب احتمالاتی ارتباط (Probabilistic Relevance Framework) است که توسط Robertson & Zaragoza (۲۰۰۹) [۳۹] ارائه شد و منجر به الگوریتم BM25 گردید. این روش با وجود سادگی، همچنان یکی از قوی‌ترین baseline های بازیابی محسوب می‌شود و در بنچمارک‌های چندزبانه مانند Mr. TyDi عملکرد رقابتی از خود نشان داده است (Zhang et al, ۲۰۲۱).

روش‌های این دسته عبارت‌اند از:

- TF-IDF
- BM25
- مدل‌های مبتنی بر Bag-of-Words

در این روش‌ها، ارتباط پرس‌وجو و سند عمدتاً از طریق اشتراک واژگان و وزن آن‌ها محاسبه می‌شود.

۲-۱۴-۲. روش‌های بازیابی Dense

در dense retrieval، متن به یک بردار متراکم با ابعاد ثابت نگاشت می‌شود و ارتباط پرس‌وجو و سند بر اساس فاصله یا شباهت بین بردارهای آن‌ها تعیین می‌شود.

Karpukhin et al (۲۰۲۰) [۶۱] با معرفی Dense Passage Retrieval (DPR) نشان دادند که بازنمایی‌های متراکم مبتنی بر مدل‌های از پیش آموزش‌دیده می‌توانند در بازیابی عملکرد بهتری از روش‌های واژگانی داشته باشند، هرچند این روش‌ها به داده آموزشی نسبتاً زیادی نیاز دارند و در تنظیمات چندزبانه با کاهش عملکرد مواجه می‌شوند.

روش‌هایی مانند DPR نمونه مهمی از این رویکرد هستند و Mr. TyDi نیز مشخصاً برای مطالعه dense retrieval در زبان‌های مختلف طراحی شده است. ([ACL Anthology](#))

۳-۱۴-۲. روش‌های بازیابی Sparse Neural

فرمال و همکاران (۲۰۲۱) با معرفی SPLADE، رویکردی ارائه کردند که با استفاده از مدل‌های زبانی، بازنمایی‌های sparse مبتنی بر واژگان را گسترش می‌دهد و بدین ترتیب مزایای تفسیرپذیری روش‌های sparse را با قدرت معنایی مدل‌های عصبی ترکیب می‌کند [۳۸].

این دسته برای پژوهش حاضر اهمیت ویژه‌ای دارد، زیرا SPLADE در معماری پیشنهادی به‌عنوان یک مؤلفه مکمل برای Semantic Folding در نظر گرفته شده است.

۴-۱۴-۲. روش‌های بازیابی ترکیبی (Hybrid Retrieval)

روش‌های hybrid تلاش می‌کنند اطلاعات حاصل از چند نوع retriever را ترکیب کنند. ترکیب سیگنال‌های sparse و dense، از جمله با روش Reciprocal Rank Fusion (Cormack, Clarke & Büttcher, ۲۰۰۹)، بارها نشان داده که می‌تواند عملکرد بهتری نسبت به هر روش به‌تنهایی ارائه دهد. نتایج Mr. TyDi نیز این یافته را در تنظیمات چندزبانه تأیید می‌کند (Zhang et al, ۲۰۲۱).

برای مثال می‌توان به ترکیب BM25 با Dense Retrieval یا Sparse Neural Retrieval با Semantic Retrieval اشاره کرد.

این دسته مستقیماً با ایده استفاده از ترکیب Semantic Folding با SPLADE در پروژه حاضر مرتبط است.

۵-۱۴-۲. روش‌های بازیابی Multilingual و Cross-Lingual

با افزایش نیاز به دسترسی اطلاعات، در زبان‌های مختلف، مسئله multilingual retrieval اهمیت زیادی پیدا کرده است. مجموعه داده MIRACL با پوشش ۱۸ زبان [۶۰] و فراهم کردن تعداد زیادی قضاوت relevance و با بنچمارک XOR-TyDi برای بازیابی بین‌زبانی^{۱۹} [۶۲] از منابع اصلی ارزیابی در این حوزه هستند. این مطالعات نشان می‌دهند که چالش‌های اصلی بازیابی چندزبانه شامل عدم تقارن منابع آموزشی میان زبان‌ها، ویژگی‌های زبانی و دشواری انتقال دانش معنایی است.

۶-۱۴-۲. روش‌های مرتبط با اثرانگشت معنایی

Webber (۲۰۱۵) با معرفی نظریه Semantic Folding، چارچوبی ارائه کرد که در آن واحدهای زبانی به‌جای بردارهای متراکم معمول، در یک فضای معنایی توپولوژیک دوبعدی نگاشت شده و بر پایه موقعیت مکانی، یک بازنمایی sparse موسوم به fingerprint تولید می‌شود. کاربرد اصلی این نظریه در ادبیات موجود، عمدتاً محدود به طبقه‌بندی و شباهت‌سنجی متن بوده و – تا جایی که در این پژوهش بررسی شد – کاربرد آن در مسئله بازیابی اطلاعات چندزبانه دامن‌بسته و به‌ویژه ترکیب آن با روش‌های sparse neural مانند SPLADE، در ادبیات منتشر شده گزارش نشده است.

۷-۱۴-۲. جمع‌بندی و جایگاه پژوهش حاضر

جدول ۱-۲ خلاصه‌ای از این شش دسته و ارتباط هرکدام با پژوهش حاضر را نشان می‌دهد.

ردیف	حوزه	نمونه مطالعات	نقطه قوت	محدودیت نسبت به مسئله این پژوهش
۱	واژگانی کلاسیک	Robertson & Zaragoza (2009) [39]	ساده، سریع، baseline قوی	عدم تطابق واژگانی بین زبان‌ها
۲	Dense Retrieval	Karpukhin et al. (2020) [61]	درک معنایی فراتر از واژه	نیازمند داده آموزشی زیاد، تفسیرناپذیر
۳	Sparse Neural	Formal et al. (2021)	تفسیرپذیر معنایی	+ بدون فضایی/توپولوژیک بازنمایی
۴	Hybrid	Cormack et al. (2009) [63]; Zhang et al. (2021)	ترکیب مزایا	ترکیب صرفاً در سطح امتیاز، نه بازنمایی
۵	چندزبانه	Zhang et al. (2023); Asai et al. (2021)	بنچمارک استاندارد	خنثی نسبت به روش بازیابی
۶	Semantic Folding	Webber (2015)	بازنمایی تفسیرپذیر	فاقد ارزیابی در بازیابی چندزبانه

بر این اساس، **خلاً مشخص پژوهشی** که پایان‌نامه جاری به آن می‌پردازد عبارت است از: نبود بررسی تجربی و مقایسه‌ای کاربرد Semantic Folding در بازیابی چندزبانه دامنه‌بسته و نبود مطالعه‌ای که این رویکرد را با روش‌های sparse neural نوین (SPLADE) در قالب یک چارچوب benchmark یکپارچه ترکیب و ارزیابی کرده باشد.

۸-۱۴-۲. کارهای پیشین مبتنی بر خوشه‌بندی معنایی

۱. Cortical.io (۲۰۱۵-۲۰۲۲) پیاده‌سازی تجاری نظریه؛ گزارش‌های دسته‌بندی متن روی ۱۶ مجموعه داده در مقایسه با BERT با تأکید بر سرعت و مصرف انرژی [۳۶].
۲. **کاربردهای جزئی:** ترکیب با TextRank برای خلاصه‌سازی خودکار [۵۲]، تشخیص ناهنجاری در لاگ‌های سامانه [۵۳]، و حافظه یادگیری SDR برای قطعه‌بندی زبان تایلندی [۵۴].
۳. **SemFold – پایان‌نامه کارشناسی ارشد مهدی‌زاده (۱۴۰۳) [۵۱]:** نخستین پیاده‌سازی جامع آکادمیک برای پاسخگویی به پرسش‌های چندگزینه‌ای روی CommonSenseQA/QASC/ARC با چهار الگوریتم کاهش بعد (SOM/t-) و هفت معیار شباهت؛ نتایج کلیدی: برتری Cosine، برتری SNE/UMAP/MDS و هفت معیار شباهت؛ نتایج کلیدی: برتری Cosine، برتری UMAP در سرعت ساخت، بهترین دقت ۵۲/۰/۷۰/۷۱/۶۰/۸۹ درصد (در سطح GloVe/FastText و پایین‌تر از BERT)، اما سرعت پاسخگویی حدود ۲۰ برابر سریع‌تر از BERT (۱۳۷-۱۸۴ ثانیه در برابر ۲۵۵۲-۳۷۱۵ ثانیه). همچنین ترفند «جایگزینی بردار سوال با شبیه‌ترین سند» (با LanceDB) دقت را افزایش داد.
۴. **Cai et al. (2024) [16]:** نخستین مبنای ارزیابی استاندارد برای «تقسیم معنایی جمله» با ۳,۲۱۶ جمله و داوری متخصصان؛ ابزار سنجش کیفیت نقشه‌های معنایی.

در این پایان نامه مسئله پژوهشی به صورت بازیابی رتبه‌ای در دامنه بسته و متون چندزبانه صورت‌بندی شده، خط لوله برای پیکره‌های واقعی تخصصی طراحی شده، وزن‌دهی TF-IDF/هم‌رخدادی، تنک‌سازی توپولوژی‌محور، انتشار فعال‌سازی و فیوژن با مدل عصبی SPLADE افزوده و ارزیابی با پروتکل استاندارد IR و آزمون معناداری آماری انجام شده است.

۱۵-۲. جمع‌بندی فصل

بررسی مبانی نظری و پژوهش‌های پیشین نشان می‌دهد که بازیابی اطلاعات از روش‌های کلاسیک مبتنی بر تطبیق واژگانی به سمت استفاده از نمایش‌های معنایی، dense retrieval، sparse neural retrieval، و در نهایت روش‌های hybrid حرکت کرده است.

در این میان، Semantic Folding رویکرد متفاوتی را مطرح می‌کند که به جای نمایش متن صرفاً به صورت یک بردار واژگانی یا یک بردار dense، مفاهیم و عبارات را در یک فضای معنایی توپولوژیک قرار داده و از موقعیت فضایی آن‌ها برای ایجاد fingerprint استفاده می‌کند و سپس استفاده از این fingerprintها برای بازیابی در یک محیط بسته چندزبانه، مسئله‌ای است که پژوهش حاضر به بررسی و ارزیابی آن پرداخته است. ([arXiv](https://arxiv.org/))

لذا شکاف پژوهشی مشخص شده در این فصل به این شرح است که خوشه‌بندی معنایی مزیت‌های نظری (سبکی، بدون ناظر بودن، تفسیرپذیری، استقلال زبانی) دارد اما فاقد ارزیابی نظام‌مند در سناریوی بازیابی در یک محیط بسته چندزبانه است.

در فصل بعد، معماری پیشنهادی برای پر کردن این شکاف، شرح داده شده است.

فصل ۳: روش پژوهش


۳-۱. نمای کلی معماری

در این فصل، معماری کلی سیستم پیشنهادی و مراحل الگوریتمی آن تشریح می‌شود. معماری پیشنهادی در قالب یک خط لوله سه مرحله‌ای بازتولیدپذیر (اسکرپت‌های نوشته شده به زبان پایتون) پیاده‌سازی شده است.

مرحله اول نمایه سازی

مرحله دوم پردازش پرس‌وجوها

مرحله سوم تولید گزارش



شکل ۳-۱. معماری خط لوله پیاده‌سازی شده

مرحله نمایه‌سازی متشکل از پنج گام است که در آن ابتدا استخراج عبارات (Phrase Extraction) از پیکره متن ورودی انجام می‌شود و یک ماتریس «واژه-مفهوم» برای عبارات

ساخته می‌شود. سپس با استفاده از روش کاهش بُعد UMAP عبارات در یک فضای دوبعدی معنایی جایابی شده و به یک ماتریس 64×64 نگاشت می‌گردند. در ادامه اثرانگشت معنایی عبارات با توجه به آمدن یا نیامدنشان در مفاهیم معنایی مختلف ساخته می‌شود. برای افزایش پایداری، مقدار سلول فعال به نواحی اطراف گسترش (spreading) یافته و با یک کرنل گوسی ($\sigma = 1/5$) هموار می‌شود و در ادامه، Fingerprint اسناد با تجمیع وزن دار اثرانگشت‌های عبارات خود حاصل می‌شود.

در ادامه مرحله پردازش پرس‌وجوها شروع می‌شود که در آن ابتدا پرس‌وجوها نیز با همان گام‌های اولیه مرحله نمایه‌سازی (استخراج عبارات و نگاشت به شبکه) به Fingerprint پرس‌وجو تبدیل می‌شوند. سپس اندازه‌گیری شباهت میان Fingerprint پرس‌وجو و اسناد، منجر به رتبه‌بندی نتایج می‌شود. برای مقایسه اصلی از شباهت کسینوسی استفاده می‌شود. در پیاده‌سازی نهایی، normalization اسناد مطابق configuration به صورت PL و سپس scaling بر اساس $\sqrt{\text{nnz}}$ انجام می‌شود. فرمول نهایی امتیاز هم به صورت $\text{score}(Q, D_i) = \frac{q \cdot d_i}{\|q\|_2 \text{nnz}(d_i)}$ است. علاوه بر این مسیر بازیابی «Semantic Folding»، مسیر مکمل مبتنی بر SPLADE معرفی می‌شود که با تبدیل پرس‌وجو و اسناد به بردارهای sparse واژگانی، یک رتبه‌بندی موازی ایجاد می‌کند. نهایتاً نتایج دو مسیر با روش‌هایی مانند ادغام خطی یا Reciprocal Rank Fusion ترکیب و با پاسخ صحیح پرس‌وجو مقایسه می‌شوند؛ که جزئیات مراحل با گام‌های آنها در ادامه تشریح می‌گردد.

در جدول (۱-۳) نحوه پیاده‌سازی گام‌های مختلف خط لوله نشان داده شده است؛ گام‌های ۱ تا ۶ (مرحله نمایه‌سازی) یکبار اجرا می‌شوند و پردازش پرس‌وجوها (گام ۷) برای پاسخگویی صرفاً روی اثرانگشت‌های از پیش ساخته‌شده انجام می‌گیرد.

جدول ۱-۳. نحوه پیاده‌سازی گام‌های مختلف خط لوله.

گام‌های خط لوله	ماژول پیاده سازی
۱. پیش‌پردازش و استخراج عبارات از پیکره متنی	lib.py phrase_extractor.py
۲. ساخت ماتریس واژه-مفهوم	term_context.py
۳. تنظیم پارامترها و نگاشت نقشه معنایی	semantic_space.py
۴. تولید اثرانگشت معنایی عبارات	fingerprint_builder.py, phrase_fingerprints.py
۵. تولید اثرانگشت معنایی اسناد	phrase_fingerprints.py, doc_fingerprints.py
۶. نمایه‌سازی پایگاه اثرانگشت‌ها	CSR/LanceDB
۷. پردازش پرس‌وجو، جست‌جو در اسناد و تعیین پاسخ صحیح	customtext_fingerprints.py, query_processor.py
۸. ارزیابی و مقایسه	dataset_benchmark/*
۹. تولید گزارش	outputs/*_report.md

۲-۳. گام ۱: پیش‌پردازش و استخراج عبارات از پیکره متنی

هر خط پیکره متنی تک‌زبانه به شکل **شناسه، متن** و در پیکره‌های متنی دوزبانه به شکل **شناسه، متن_عربی | ترجمه_انگلیسی** است که در آنها هر دو زبان به یک شناسه مفهوم تعلق دارند.

برای آماده‌سازی متن اسناد و پرس‌وجوها، ابتدا اقدام به پاک‌سازی (Clean-up) و نرمال‌سازی شده است. در این مرحله مواردی مانند حروف بزرگ و کوچک، حذف ایست‌واژه‌های دو زبان، حذف نویسه‌های غیرمتنی (همزه‌ها، تشدیدها، علایم نگارشی)، اعداد یا نشانه‌های خاص (در صورت نیاز) و حداقل طول واژه کنترل می‌شود زیرا اثرانگشت چنین کلماتی کمک کننده نیست و صرفاً زمان پردازش را بیشتر و سرعت روش را کاهش می‌دهد. تمام نرمال‌سازی‌ها قبل از تطبیق زیررشته‌ای اعتبارسنجی عبارات اعمال می‌شود تا سطح نمایش و سطح جست‌وجو یکسان بمانند.

در نهایت از پیکره متنی، عبارات کاندید استخراج می‌شود، این گام برای زبان انگلیسی با استفاده از کتاب‌خانه اسپپسی^{۲۰} و برای زبان عربی با الگوهای نحوی انجام می‌شود:

• **تک‌واژه‌ها^{۲۱}:** توکن‌های $2 \leq$ نویسه با $\{POS \in \{NOUN, PROPN, ADJ, VERB, ADV\}$ و

غیرایست‌واژه (برای عربی: حذف حروف وظیفه و جداسازی ضمائر متصل مانند

«ال»، «و»، «ب»، «ل» با حفظ واژگان حداقلی دو حرفی مثل «طه»).

• **دوواژه‌ای‌ها^{۲۲}:** انگلیسی از noun chunks اسپپسی (+زنجیره ترکیب‌ها و

همپایه‌ها)؛ عربی با الگوی `NLTK [NN*/JJ/VBN] + [N*]`.

^{۲۰}. spaCy

^{۲۱}. unigram

^{۲۲}. bigram

- سه واژه‌ای‌ها^{۲۳}: زیربازه‌های چپ‌لنر noun chunk (انگلیسی) و الگوی سخت‌گیرانه $3 \times [NN/JJ/VBN]$ (عربی).

خروجی این گام واژه‌نامه‌ای از عبارات است که هر کدام در اسناد مختلفی ظاهر شده‌اند.

واژه‌نامه عبارت - تعداد تکرار و نگاشت دوبخشی عبارت - [شناسه مفاهیم].

۳-۲-۱. شبکه واژگان و مدیریت واژگان خارج از پیکره

واژه خارج از واژه‌نامه (OOV) اثرانگشت تهی می‌سازد و عملاً از فرآیند پاسخگویی حذف می‌شود. برای جلوگیری از، از دست دادن اطلاعات این واژگان، سازوکاری طراحی شده بر پایه شبکه واژگان (WordNet) که به شرح زیر است:

۱. برای هر واژه OOV پرس‌وجو، لمای آن بازیابی و از WordNet [۴۵] مترادف‌ها (synsets) و واژه‌های هم‌ریشه استخراج می‌شود.

۲. اگر هر یک از مترادف‌ها در واژه‌نامه پیکره موجود باشد، اثرانگشت آن (یا میانگین وزن دار چند مترادف موجود) به عنوان اثرانگشت تقریبی واژه OOV به کار گرفته می‌شود.

۳. وزن این اثرانگشت‌های تقریبی با ضریب کاهشی $\gamma > 1$ مقیاس می‌شود تا عدم قطعیت نگاشت منعکس گردد.

این سازوکار در قالب یک آزمایش کنترل‌شده روی بنچمارک CAREN_Belebele ارزیابی شده است؛ در آن واریانت عملیاتی «جانشینی سطح-متن» ($\gamma=1$) پیاده‌سازی شد و نتایج آن در بخش ۴-۴-۴ گزارش شده است.

این سازوکار بیشترین سود را برای اسم‌های عام دارد؛ نام‌های علمی و واژگان بسیار تخصصی بدون پوشش WordNet همچنان تهی می‌مانند (در تحلیل خطاهای فصل ۴ اشاره شده است).

۳-۳. گام ۲: ساخت ماتریس واژه-مفهوم^{۲۴}

پس از استخراج عبارات (شامل اسم‌ها، ترکیبات فعل و متمم و ...)، یک ماتریس تنک واژه-مفهوم ساخته می‌شود تا بتوان هر مفهوم را به یک نمایش عددی برداری تبدیل کرد. سطرهاى ماتریس متناظر با عبارات استخراج‌شده و ستون‌ها مفاهیم معنایی مربوط به اسناد هستند. مقدار هر خانه نشان‌دهنده تعداد حضور عبارت در مفهوم معنایی مربوطه است. این ماتریس به صورت فراوانی هم‌رخدادی و TF-IDF بین عبارات‌ها و مفاهیم هم‌زمینه اعمال شده آن‌ها است. به این صورت که برای هر عبارت در متن، کلماتی را که در پنجره مشخص ± 5 کلمه اطراف آن قرار می‌گیرند، به عنوان مفهوم هم‌زمینه در نظر گرفته و فراوانی آن‌ها محاسبه می‌شود. به بیان دیگر، ماتریس واژه-مفهوم، یک ماتریس بزرگ با ابعاد «تعداد عبارات $\times$ تعداد مفاهیم کل» است که در آن المان (i,j) نمایانگر میزان ارتباط یا هم‌رخدادی عبارت (i) با مفهوم (j) می‌باشد. در این مرحله از TF-IDF برای وزن‌دهی استفاده شده است. هدف این ماتریس، نگاشت هر سند به برداری است که نشان‌دهنده ویژگی‌های مفهومی و زمینه‌ای آن باشد.

۳-۳-۱. نقش هم‌رخدادی و TF-IDF

دو مؤلفه اصلی و متمایز با نقش‌های مختلف برای وزن‌دهی و ساخت این ماتریس استفاده می‌شوند:

- وزن TF-IDF واژگانی: برای هر عبارت (p) و سند (d)، تعداد وقوع عبارت (p) در تمام اسنادی که شامل (p) است، شمرده می‌شود و سپس با استفاده از فرمول

TF-IDF وزن دار می شود. و همین فرمول برای پرس وجو. نقطه تقارن سند-پرسش این است که هر دو از یک فایل `idf_weights.json` تغذیه می شوند. نرمال سازی: $\frac{1}{\sqrt{nnz}}$ برای پرس وجو و $\frac{1}{\sqrt{nnz}}$ برای اسناد.

- **همرخدای عبارات (Co-occurrence):** به علاوه، برای هر دو عبارت (p) و (q) یک ویژگی تعریف می شود که تعداد اسنادی را نشان دهد که هر دو عبارت در آن ها ظاهر شده اند. به عبارتی یک ماتریس همرخدای (C) از اندازه (N*N) ساخته می شود که $C[p,q]$ تعداد اسناد مشترک حاوی هر دو (p) و (q) است. این ماتریس نیز با $\{\mathrm{IDF}\}$ وزن دهی می شود. وجود همرخدای بین عبارات، نشان دهنده پیوند معنایی و وجود مفهوم مشترک است و تعیین می کند کدام سلول های نقشه در اثر انگشت هر عبارت فعال شوند.

۳-۳-۲. نحوه ساخت ماتریس نهایی واژه-مفهوم

ابتدا ماتریس TF-IDF واژگانی ساخته می شود، سپس هر سطر با بردار متناظر در ماتریس همرخدای همانند مقادیر اضافی الحاق می شود. به این ترتیب، هر سند (d) به یک بردار عددی $(v_d \in \mathbb{R}^V)$ تبدیل می شود که (V) برابر با مجموع تعداد واژگان مدنظر و تعداد عبارات (در حالت استفاده از همرخدای) است. این بردار (v_d) نمایش مفهومی و معنایی اولیه ی اسناد را در ابعاد بالا فراهم می کند.

۳-۳-۳. شبه کد ساخت ماتریس واژه-مفهوم

```
# Build term-context matrix
```

```
for each document in corpus:
```

```
    tokens = tokenize(doc)
```

```
    phrases = extract_phrases(tokens, max_len=N)
```

```
    for phrase in phrases:
```

```
contexts = get_contexts(phrase, doc_window)
```

```
for c in contexts:
```

```
    term_context_matrix[phrase][c] += 1
```

۳-۳-۴. شبه‌کد نگاشت وزن‌دهی عبارات و مفاهیم معنایی

```
# Apply TF-IDF weighting (per phrase and per context term)
```

```
    for each context_term c:
```

```
        df_c = number_of_phrases_with_c()
```

```
    for each phrase p where term_context_matrix[p][c] > 0:
```

```
        tf = term_context_matrix[p][c]
```

```
        tfidf[p][c] = tf * log(N_phrases / (1 + df_c))
```

۳-۴. گام ۳: تنظیم پارامترها و نگاشت نقشه معنایی

۳-۴-۱. تنظیم پارامترها

پارامترها روی بخشی از داده تنظیم و روی مجموعه داده‌های جداگانه اعتبارسنجی شده‌اند (جزئیات در فصل ۴).

- **UMAP:** از پیاده‌سازی umap-learn با پارامترهای زیر استفاده شد (داده ورودی، ماتریس واژه-مفهوم)

n_neighbors = 15: تعداد همسایه‌های محلی برای هر نقطه، که تأثیر زیادی بر حفظ ساختار محلی هر نقطه و خوشه‌بندی نهایی دارد.

min_dist = 0.1: حداقل فاصله مجاز بین نقاط در فضای دوبعدی خروجی، که سخت‌گیری حفظ فواصل نزدیک را کنترل می‌کند. مقدار کوچک‌تر امکان ایجاد نواحی متراکم‌تر را فراهم کند.

metric = 'cosine': برای مقایسه بردارهای ورودی از شباهت کسینوسی استفاده می‌شود. این انتخاب برای نمایش‌های متنی مناسب است، زیرا جهت بردار و الگوی توزیع ویژگی‌ها در بسیاری از کاربردهای متنی اهمیت زیادی دارد.

این تنظیمات بر اساس ارزیابی‌های اولیه و مستندات UMAP انتخاب شده‌اند؛ از آنجا که داده‌های زمینه‌ای به ندرت خطی هستند، UMAP یک روش مناسب برای نگاشت غیرخطی و حفظ ساختار معنایی است.

- **انتخاب ابعاد ماتریس:** با پیکره‌های ۲۰~ سندی، ۶۴×۶۴ چگالی اثرانگشت ۷-۱۰٪ می‌دهد (بهینه)؛ در پیکره‌های بزرگ‌تر (۶,۲۳۶ آیه قرآن، ۴۸۸ قطعه دوزبانه) نیز همین ابعاد پس از خروجی ارزیابی‌ها بهترین بود.

قاعده کلی: چگالی یا $\rho = \text{nnz}(F_d)/g$ باید در بازه ۵-۱۵٪ بماند.

در تئوری Semantic Folding اصلی (شرکت Cortical.io) از ماتریس (۱۲۸*۱۲۸) استفاده شده است. در این پروژه با توجه به خروجی ارزیابی‌ها، کاهش محاسبات و حافظه و همچنین برای امکان اجرا توسط لپ‌تاپ شخصی، ماتریس (۶۴*۶۴) در نظر گرفته شده است. نتیجه، حفظ توپولوژی نسبی معانی در ابعاد کوچک‌تر است.

- **Morton (Z-Order) Encoding:** تبدیل مختصات دوبعدی ماتریس ((i,j)) به یک عدد تک با بینجی bit-interleave انجام شد؛ یعنی بیت‌های باینری (i) و (j) را به هم تنیدیم تا یک شناسه (۴۰۹۵..۰) ایجاد شود. این کار نظم مکانی را تا حدی حفظ می‌کند.

- **گسترش، هموارسازی و شدت فعال‌سازی:** کد گسترش به سادگی با جابه‌جایی اندیس‌ها (± 1) اعمال شد و برای هموارسازی از تابع گوسی پیاده‌سازی شده در SciPy با $(1/5 = \sigma)$ استفاده شد.

Spreading=1: فعال‌سازی را به اطراف سلول اصلی منتقل می‌کند. این با ایده کلی Semantic Folding سازگار است که در آن موقعیت‌های نزدیک در semantic map بخشی از ساختار نمایش معنایی را تشکیل می‌دهند.

Gaussian smoothing=1.5: یک روش ریاضی برای ایجاد نوع پخش‌شدن نرم و تدریجی اطراف سلول اصلی است.


Decay=0.5: این پارامتر مشخص می‌کند که با هر اندازه دور شدن از سلول اصلی، شدت فعال‌سازی سلول‌های اطراف چقدر کاهش یابد. مقدار برابر با 0.5 در این پروژه یعنی، به ازای هر یک فاصله از سلول اصلی شدت فعال‌سازی 50% درصد شود.

- **تنک‌سازی (sparsification):** پس از تولید fingerprint، برای کنترل تعداد سلول‌های فعال، تنک‌سازی با $top_percent=0.10$ انجام می‌شود.

خلاصه‌ای از پارامترهای اصلی مطابق با پیاده‌سازی انجام شده در پژوهش جاری، در بخش ۲-۱۱-۳ ذکر شده است.

۲-۴-۳. کاهش بعد و نگاشت به فضای معنایی دوبعدی

در ابتدا مفاهیم به همان صورت که در مجموعه داده آمده بودند در کنار هم قرار می‌گیرند، در ادامه سعی بر این است که مفاهیم به دست آمده بر حسب فاصله در کنار هم قرار بگیرند (شکل ۳).




شکل ۳. ایجاد نقشه معنایی بر اساس ارتباط بین مفاهیم

بردارهای (v_d) تولید شده برای مفهوم معنایی اسناد ممکن است در ابعاد بسیار بالایی (V) بزرگ) باشند. برای ایجاد یک فضای معنایی دوبعدی توپولوژیک و آسان‌تر کردن نمایش و شباهت‌ها، از روش غیرخطی UMAP (Uniform Manifold Approximation and Projection) برای کاهش بُعد استفاده می‌شود. UMAP بردارهای (v_d) را به نقاطی (x_d, y_d) در فضای دوبعدی نگاشت می‌کند، به‌طوری که ساختار همسایگی (نشانه‌های معنایی مشترک) تا حد ممکن حفظ شود.

پس از به‌دست آوردن مختصات پیوسته (x_d, y_d) برای هر عبارت، باید این نقطه روی یک شبکه گسسته قرار داده شود. برای این کار، یک ماتریس دوبعدی با ابعاد 64×64 تعریف شده است. ابتدا بازه مختصات (x, y) به فاصله‌های 64 تایی تقسیم شده، سپس هر نقطه (x_d, y_d) به نزدیک‌ترین سلول ماتریس اختصاص داده می‌شود. به این ترتیب، برای مفهوم معنایی سند (d)، شناسه سلول ($2^{\{63, i_d, j_d\}} \in \{0, \dots\}$) مشخص می‌شود.

به طور خلاصه در این مرحله، با استفاده از روش کاهش ابعاد UMAP، روابط میان عبارات و اسناد به فضای دو بعدی منتقل شده و بر روی یک ماتریس 64×64 نگاشت می‌شوند.

در شکل ۳-۲ نقشه معنایی حاصل از UMAP برای پیکره دوزبانه CAREN_Belebele نشان داده شده است، که در آن هر نقطه یک مفهوم معنایی مجزا است و مجاورت نقاط بیانگر



اشتراک واژگانی بین آنها است.

شکل ۳-۲. نقشه معنایی حاصل از UMAP برای پیکره دوزبانه CAREN_Belebele

۳-۴-۳. شبه‌کد کاهش ابعاد با روش UMAP

Dimensionality reduction using UMAP

umap_model = UMAP(

n_components=2, # embedding in 2D

n_neighbors=15,

```

min_dist=0.1,

metric='cosine',

random_state=42

)

phrase_vectors_2d = umap_model.fit_transform(tfidf_matrix)

```

۵-۳. گام ۴: تولید اثرانگشت معنایی عبارات

با دانستن سلول (i_d, j_d) متناظر با مفهوم هر سند، اثرانگشت معنایی برای تمام عبارات ساخته می‌شود. فرآیند ایجاد fingerprint عبارات، عبارت است از:

۱. یک ماتریس اولیه صفر از ابعاد $(۶۴*۶۴)$ ایجاد می‌شود.
۲. مقدار سلول $((i_d, j_d))$ برابر ۱ قرار داده می‌شود (این سلول فعال اصلی است).
۳. گسترش فضایی (Spatial Spreading): برای افزایش پایداری نمایش و همپوشانی معنایی، سلول‌های همسایه (با فاصله منتهن ۱) فعال می‌شود. با پارامتر $(l=radius)$ ، سلول مرکزی (i_d, j_d) با مقدار ۱ و هشت همسایه اطراف آن (بالا، پایین، چپ، راست و قطرهای) با مقدار $(decay=۰/۵)$ مقداردهی می‌شوند. به عبارت دیگر اگر $f(x,y)$ مقدار اولیه سراغدار عبارت روی شبکه باشد:

$$[f(i_d, j_d)=1, \quad f(i_d \pm 1, j_d)=f(i_d, j_d \pm 1)=0.5, \quad f(i_d \pm 1, j_d \pm 1)=۰/۵], \text{ سلول‌های خارج این شعاع مقدار } ۰ \text{ دارند.}$$

این کار باعث می‌شود عبارات شبیه، در فضای معنایی، Fingerprintهایی تا حدی همپوشان، داشته باشند.

بنابراین اگر سلول اصلی مقدار ۱ داشته باشد، سلول‌های اطراف می‌توانند activation کمتری دریافت کنند.

به صورت مفهومی:

0.5

0.5 1 0.5

0.5

۴. Gaussian Smoothing: برای ایجاد انتشار پیوسته‌تر، یک هموارسازی گوسی با انحراف معیار ($\sigma = 1/5$) روی ماتریس اعمال می‌شود. بدین ترتیب مقدار هر سلول در اطراف مرکز به شکل تدریجی کاهش می‌یابد (مقدار ۱ در مرکز و مقادیری کمتر در همسایگی). به طور مفهومی، پس از هموارسازی، ماتریس به صورت زیر در خواهد آمد (اعداد مثال):

0.05 0.12 0.05

0.12 1.00 0.12

0.05 0.12 0.05

اعمال این مرحله باعث پخش پیوسته‌تر مقادیر و مقاوم‌تر شدن fingerprint نسبت به جابه‌جایی‌های کوچک موقعیت می‌شود.

نتیجه‌ی نهایی پس از مراحل فوق Fingerprint عبارت (p) خواهد بود که آن با برداری با $(64 \times 64 = 4096)$ مؤلفه نیز در بعضی زمان‌ها بر حسب نیاز، در نظر گرفته می‌شود.

به طور خلاصه، اثراگشت تولیدی برای عبارت (p) اغلب ترکیبی از مقادیر ۰، ۰/۵ و ۱ است که پس از smoothing به صورت ترکیبی از مقادیر پیوسته نیز قابل تنظیم و ذخیره سازی است و پردازش‌هایی مانند Morton Z-order بر روی آن قابل اعمال هستند.

۳-۵-۱. شبه‌کد تولید اثراگشت معنایی عبارات

```
# Create phrase fingerprint (sparse vector)
```

```
grid = zeros((64,64))
```

```
x, y = get_grid_coords(phrase_vectors_2d[p])
```

```
grid[x,y] = 1.0 # center activation
```

```
# Spatial spreading with decay:
```

```
for dx,dy in neighbors_within_radius(r=1):
```

```
    dist = sqrt(dx^2 + dy^2)
```

```
    weight = decay # dist=0.1, decay=0.5
```

```
    grid[x+dx, y+dy] += weight
```

```
# Gaussian smoothing:
```

```
grid = gaussian_filter(grid, sigma=1.5)
```

Flatten to 4096-length fingerprint vector

phrase_fp = grid.flatten()

۳-۶. گام ۵: تولید اثرانگشت معنایی اسناد

یک سند شامل چندین عبارت استخراج شده است $(p_1, p_2, \dots, p_k)$. برای ساخت Fingerprint سند، Fingerprint های این عبارات با وزن دهی مناسب تجميع می شوند تا Fingerprint هر سند نیز در فضای ۴۰۹۶ بعدی به دست آید. یعنی

$$[FP(d) = \sum_{i=1}^k w(p_i, d) * FP(p_i)]$$

که در آن $w(p_i, d)$ مقدار $(\text{TF-IDF}(p_i, d))$ است. به این ترتیب، عبارات مهم تر در سند (آنهایی که تکرار بیشتری داشته اند یا نادرترند) سهم بیشتری در Fingerprint سند می گیرند. سپس با آشکارساز قلّه توپولوژی محور، فقط top-percent سلول های برتر (پیش فرض ۱۰٪) در قالب قله های محلی حفظ می شود – نه برش سراسری ساده – تا خوشه های فضایی معنادار تخریب نشوند. در نتیجه:


Phrase FPs



weighted aggregation



Document Fingerprint



شکل ۳-۳. اثرانگشت دوبعدی رمزگشایی‌شده دو سند نمونه (ماتریس 64×64). چپ: مقادیر فعال‌سازی؛ راست: ماسک سلول‌های فعال. خوشه‌بندی سلول‌های فعال بیانگر مفاهیم غالب سند است.

۳-۶-۱. شبکه‌کد تولید اثرانگشت معنایی اسناد

```
# Compute document fingerprint
```

```
doc_fp = zeros(4096)
```


```
for phrase, tfidf_w in document_phrase_tfidf.items():
```

```
    phrase_fp = load_phrase_fingerprint(phrase) # precomputed
```

```
    doc_fp += tfidf_w * phrase_fp
```

۳-۷. گام ۶: نمایه‌سازی پایگاه اثرانگشت‌ها

بعد از بررسی و تنظیم معیارها و تولید اثرانگشت معنایی برای عبارات و اسناد، مختص به همان عبارات و اسناد در پایگاه داده اثرانگشت‌های معنایی نمایه سازی می‌شود، که برای به دست آوردن اثرانگشت معنایی هر متن دلخواه نیز کافیسیت با استفاده از پایگاه داده اثرانگشت‌های معنایی، اثرانگشت معنایی تک تک عبارات تشکیل دهنده آن را ترکیب کرد و به اثرانگشت معنایی متن مورد نظر رسید (شکل ۴).



شکل ۴. تولید اثرانگشت معنایی جمله با استفاده از اثرانگشت کلمات تشکیل دهنده [۱۳]

اثرانگشت اسناد به صورت ماتریس تنک CSR^{۲۰} در حافظه نگهداری می‌شود؛ backend اختیاری LanceDB برای ANN و ذخیره‌سازی بلندمدت. تُرم‌های ۲L اسناد پیش‌محاسبه می‌شوند.

۸-۳. گام ۷: پردازش پرس‌وجو، شباهت شماتیک و تعیین پاسخ

برای بازیابی، پرسوجو نیز مانند یک «سند کوچک» در نظر گرفته می‌شود. مراحل زیر برای پرسوجو (q) انجام می‌گیرد:

۱. استخراج عبارت‌های پرسوجو: همانند اسناد، ابتدا عبارات پرسوجو استخراج و با واژه‌نامه تطبیق داده می‌شوند و عبارات غایب از مسیر شبکه‌ی واژگان عبور می‌کنند.
۲. ساخت fingerprint پرسوجو: بر اساس جمع وزن دار اثرانگشت عبارات پرسوجو بعلاوه نرمال‌سازی PL، اثرانگشت پرسوجو (FP(q)) ساخته می‌شود.
۳. محاسبه شباهت: برای هر سند (d) در مجموعه، با استفاده از spatial spreading و معیار شباهت کسینوسی، یک امتیاز شباهت میان (FP(q)) و (FP(d)) محاسبه می‌شود که در نهایت اسناد بر اساس این امتیاز رتبه‌بندی شده و مجموعه‌ای از اسناد نامزد برای ارزیابی انتخاب می‌شوند. یک گزینه ساده و مؤثر برای محاسبه شباهت، ضرب داخلی بردارها است: $\text{score}(q,d) = \text{FP}(q) \cdot \text{FP}(d)$ [مقدار بزرگ‌تر نشان‌دهنده همپوشانی بیشتر و نزدیک‌تر بودن مفاهیم سند و پرسوجو هستند.
۴. انتشار فعال‌سازی (شباهت شماتیک نرم): هر سلول فعال، فعال‌سازی خود را به همسایه‌های موری (Chebyshev) با شعاع $r=1$ و میرایی $\text{decay}=0.5$ گسترش می‌دهد تا اسنادی که مفاهیمشان مجاور سلول‌های پرسوجو هستند نیز امتیاز بگیرند. کرنل هندسی اختیاری 3×3 (مرکز $=0.1$ ، همسایه قائم $=0.5$ ، قطر $=0.25$) همین ایده را به صورت کانولوشن پیاده می‌کند – این دو سازوکار، مصداق عملی «بررسی شماتیک اثرانگشت‌ها نه صرفاً درصد همپوشانی بیت‌ها» هستند.
۵. امتیازدهی و رتبه‌بندی:

$$\text{score}(q,d) = \frac{q \cdot d}{\|q\|_2 \cdot \sqrt{\text{nnz}(d)}}$$

در پیاده‌سازی محاسبه ضرب داخلی بردارهای ۴۰۹۶ بعدی سنگین است؛ لذا در عمل از تکنیک‌های sparse بودن یا کاهش تعداد محاسبه استفاده می‌شود. از آنجا که Fingerprintها معمولاً تنک (تک‌شدت یا sparse) هستند، ابتدا اسناد فاقد هیچ بُعد مشترکی با پرس‌وجو حذف می‌شوند.

۳-۸-۱. ترکیب با SPLADE

افزون بر مسیر Semantic Folding فوق، یک مسیر موازی مبتنی بر SPLADE (نمایش sparse عصبی) نیز در این معماری قرار دارد. SPLADE یک مدل بازیابی عصبی sparse است که به صورت زیر عمل می‌کند:

۱. تبدیل متن به بردار sparse: با استفاده از یک مدل زبانی (معمولاً BERT یا multilingual BERT) برای هر سند و پرس‌وجو یک بردار sparse تهیه می‌شود. به طور خاص، خروجی مدل BERT تحت یک لایه CLS-to-vocab (معمولاً مشتق‌شده از مدل Masked LM) قرار می‌گیرد تا برای هر واژه یا subword یک وزن تولید شود. این وزن‌ها بعد از اعمال regularization و log-saturation به بردار sparse تبدیل می‌شوند. نتیجه نهایی، یک بردار با بعد برابر اندازه واژگان (مثلاً چند ده هزار) و تعداد کمی مختصات غیرصفر است.

۲. شاخص‌گذاری اسناد: بردار sparse هر سند با یک نمایه‌سازی معکوس (inverted index) همانند روش‌های کلاسیک ذخیره می‌شود. به عبارت دیگر، در شاخص‌گذاری ۲۵BM به ازای هر واژه فهرستی از اسناد وجود دارد؛ در SPLADE نیز همین کار انجام می‌شود، با این تفاوت که وزن هر واژه برابر مقدار تولید شده توسط مدل است.


۳. جستجو با SPLADE: برای هر پرس‌وجو، پس از محاسبه بردار sparse آن، اسناد در شاخص sparse مانند ۲۵BM جستجو می‌شوند. معمولاً روش‌هایی مانند ضرب

داخلی وزن‌های مشترک یا جمع وزن‌ها (با نرمال‌سازی) برای رتبه‌بندی اولیه استفاده می‌شود. این روند به دلیل sparse بودن بردارها و شاخص‌گذاری معکوس، بسیار شبیه ۲۵BM عمل می‌کند اما واژگان فعال شده توسط مدل عصبی ممکن است فراتر از واژگان پرس‌وجوی اصلی باشد (Lexical Expansion).

به این ترتیب، دو مسیر بازیابی به‌دست می‌آید: یکی مبتنی بر Fingerprints معنایی و دیگری مبتنی بر نمایش sparse عصبی (SPLADE). هر دو مسیر به طور مستقل فهرستی از اسناد رتبه‌بندی شده تولید می‌کنند.


۲-۸-۳. روش‌های ترکیب نتایج بازیابی

هنگامی که چند بازیابی کننده^{۲۶} مستقل وجود دارد، مسئله بعدی این است که چگونه نتایج آن‌ها در یک رتبه‌بندی نهایی تبدیل شود. در پروژه حاضر ترکیب نتایج بازیابی به شکل زیر تعریف شده است:



SF Ranking

SPLADE Ranking



Fusion



Final Ranking

دو روش مهم برای ترکیب نتایج عبارت‌اند از:

• Linear Fusion

• Reciprocal Rank Fusion (RRF)

که در این پایان‌نامه برای بهره‌گیری از نتایج هر دو روش، خروجی‌های مسیر SF و SPLADE با هم ترکیب می‌شوند.

۱-۲-۸-۳. ادغام خطی (Linear Fusion)

در این روش امتیازهای تولید شده جداگانه، توسط دو روش با استفاده از ضریب آلفا (عددی بین ۰ و ۱) به صورت زیر محاسبه و با هم ترکیب می‌شوند:

فرض کنید $((\mathrm{score})_{\{SF\}}(q,d))$ و $((\mathrm{score})_{\{SP\}}(q,d))$ امتیازات به‌دست‌آمده از مسیر Semantic Folding و SPLADE هستند.

$$[\mathrm{score}]_{\{final\}}(q,d);=\alpha, \mathrm{score}_{\{SF\}}(q,d)+(1-\alpha), \mathrm{score}_{\{SP\}}(q,d).]$$

مثلاً اگر آلفا برابر با ۰/۷ باشد، S_{final} برابر با $S_{sf} * ۰/۷$ و $S_{sp} * ۰/۳$ خواهد شد، در نتیجه Semantic Folding وزن بیشتری خواهد داشت.

مقادیر مختلف α در بنچمارک‌های مقدماتی بررسی شده‌اند و در نهایت در پیکربندی نهایی $\alpha = 0.3$ انتخاب شده است.

در ادغام خطی مسئله مهم این است که scoreهای دو سیستم ممکن است در مقیاس یکسانی نباشند؛ لذا قبل از این ترکیب، مقیاس امتیازات هر سیستم با نرمال‌سازی (با تقسیم بر بیشینه مقدار) یکسان می‌شود تا سیستم با دامنه بزرگ‌تر، همه‌چیز را تحت‌الشعاع قرار ندهد.

$$\begin{aligned} S_{SF}(q, d) \\ S_{SP}(q, d) \\ S_{final}(q, d) = \alpha S_{SF}(q, d) + (1 - \alpha) S_{SP}(q, d) \\ 0 \leq \alpha \leq 1 \end{aligned}$$

مثلا اگر در Semantic Folding:

$$ID = 0.91 \text{ و } 2D = 0.87$$

و همچنین در SPLADE:

$$ID = 15.2 \text{ و } 2D = 13.8 \text{ باشد؛}$$

ترکیب مستقیم این مقادیر باعث می‌شود سیستم دارای scale بزرگ‌تر تأثیر بیشتری داشته باشد. به همین دلیل قبل از ادغام خطی نیاز به نرمال‌سازی وزن‌ها یا طراحی مناسب وزن‌ها وجود دارد.

۳-۸-۲-۲. ادغام رتبه متقابل (Reciprocal Rank Fusion (RRF))

این روش برای ترکیب رتبه‌ها مورد استفاده قرار می‌گیرد که در آن به جای تکیه مستقیم بر مقدار امتیاز، از رتبه سند در هر روش استفاده می‌کند؛ لذا **مزیت مهم** آن این است که **نیازی به همسان‌سازی مقیاس‌ها ندارد**. به این ترتیب، خروجی نهایی رتبه‌بندی، یک فهرست اسناد است که با ترکیب مناسب خروجی‌های دو روش SF و SPLADE حاصل شده است. پژوهش اصلی RRF نیز آن را به عنوان روشی برای ترکیب رتبه‌بندی‌ها و مقایسه با روش‌های دیگر ادغام بررسی کرده است. ([Google Research](#))

فرمول RRF به شکل زیر است:

$$RRF(d) = \sum_{r \in R} \frac{1}{k + rank_r(d)}$$

$$RRF(d) = \sum_{r \in R} \frac{1}{k + rank_r(d)}$$

که در آن:

- R : مجموعه ranking‌ها
- $rank_r(d)$: رتبه سند (d) در ranking مربوط به سیستم (r)
- k : یک ثابت مثبت (معمولاً برابر با ۶۰) برای کاهش تأثیر رتبه‌های بسیار بالا (تعدیل اختلاف رتبه‌ها)

۳-۹. گام ۸: ارزیابی و مقایسه

- معیارها: MRR, AP, NDCG@K (میانگین خردشده روی کوئری‌ها).
- اجرای سه مرحله‌ای:

(۱) نمایه‌سازی یک باره کل پیکره (گام‌های ۱-۶)

(۲) اجرای گام ۷ به تفکیک پرس و جو و پس فیلتر به کاندیدهای رسمی

(۳) تولید گزارش خودکار

- **خطوط مبنا:** sklearn: BM25 ، همان پیکره/کوئری/طلایی) و SPLADE.
- **معناداری آماری:** Wilcoxon signed-rank دوطرفه روی RR هر کوئری + McNemar دقیق (دوجمله ای شرطی) روی ۱@hit.

۱۰-۳. شبه کد الگوریتم کلی و پیچیدگی زمانی آن

۱-۱۰-۳. شبه کد مراحل الگوریتم

مرحله اول: نمایه سازی اسناد

for each p in ExtractPhrases:

context_vector[p] = BuildTermContextVector(p, d)

مرحله دوم: کاهش ابعاد و نگاشت فضای معنایی

UMAP_embedding = UMAP(term_context_matrix, params = {n=15,
min_dist=0.1, metric='cosine'})

مرحله سوم: ساخت اثرانگشت عبارات

for each p in ExtractPhrases:

(x_p, y_p) = UMAP_embedding(p)

(i_p, j_p) = MapToGrid(x_p, y_p, grid_size=64)

```
phrase_FP[p] = CreateSpatialFingerprint(i_p, j_p, radius=1, decay=0.5,  
                                         sigma=1.5)
```

مرحله چهارم: ساخت اثرانگشت اسناد

for each d in documents:

```
FP(d) = sum_{p in d}( TFIDF(p,d) * phrase_FP[p] )
```

مرحله پنجم: ساخت شاخص SPLADE (در پس زمینه)

for each d in documents:

```
sparse_vector_sp[d] = SPLADE_encode(d)
```

```
Index_SPLADE = BuildInvertedIndex(sparse_vector_sp)
```

مرحله ششم: پاسخ به پرس و جو

for each q in queries:

```
q_Phrases = ExtractPhrases(q)
```

for each q_Phras in q_Phrases:

```
FP(q) += TFIDF(q_Phras, q) * phrase_FP[q_Phras]
```

مرحله هفتم: بازیابی از طریق SF و SPLADE

```
sparse_vector_q = SPLADE_encode(q)
```

for each d in documents:

```
score_SF[d] = similarity( FP(q), FP(d) )
```

$\text{score_SP}[d] = \text{RetrieveFromIndex}(\text{sparse_vector_q}, \text{Index_SPLADE})$

مرحله هشتم: ترکیب نتایج

در ادغام خطی SPLADE، بعد از نرمال سازی score_SF و score_SP :

$$\text{Linear_score}[d] = \alpha * \text{score_SF}[d] + (1 - \alpha) * \text{score_SP}[d]$$

در ادغام رتبه متقابل SPLADE:

compute: $\text{rank_SF}[d]$, $\text{rank_SP}[d]$

$$\text{RRF_score}[d] = 1 / (k + \text{rank_SF}[d]) + 1 / (k + \text{rank_SP}[d])$$

مرحله آخر: بازگرداندن رتبه بندی نهایی بر اساس Linear_score یا RRF_score

۲-۱۰-۳. پیچیدگی زمانی الگوریتم

- ساخت ماتریس واژه-مفهوم برای (N) عبارت و (D) سند: $O(N * D)$.
- پیچیدگی زمانی $O(N \log N)$ برای UMAP (بسته به پیاده سازی).
- تولید هر fingerprint عبارت و سند با پیچیدگی $O(1)$ برای هر عبارت (زیرا اعمال روی ماتریس کوچک ثابت $(64 * 64)$ است). تجمیع Fingerprint سند با $O(P)$ است که (P) تعداد عبارات سند است.
- در بازیابی ساده، اگر همه اسناد را اسکن کنیم، زمان $O(D)$ برای هر سند (ضرب داخلی 4096 بعدی)، که برای مجموعه بزرگ اسناد سنگین است. در عمل با استفاده از نمایه سازی و محدود کردن کاندیدها پیچیدگی کاهش یافت.
- استقرا: SPLADE نیز هزینه تولید بردار sparse (که معمولاً با BERT همراه است) و سپس بازیابی با ایندکس معکوس پیچیدگی مشابه روش های کلاسیک دارد.

ملاحظات حافظه: ذخیره ماتریس زمینه‌ای می‌تواند هزینه‌بردار باشد. همچنین ذخیره Fingerprintهای اسناد به عنوان بردارهایی (۴۰۹۶) بعدی برای هر سند نیازمند حافظه مناسبی است. لذا از ساختارهای sparse و فشرده‌سازی استفاده شده است.

قابل تکرار بودن: برای اطمینان از امکان بازتولید نتایج، ثابت کردن دانه‌های تصادفی (random seed)، مستندسازی دقیق پارامترها (مانند مقادیر $(k\backslash)$ ، (α) ، اندیس‌های جدول tf-idf و ...) و تعیین روال دقیق پیش‌پردازش انجام شد که تمامی این موارد در جدول (لیست کنترل قابلیت بازتولید) در فصل بعد خواهد آمد.

۱۰-۳. نمودار کلی معماری

در شکل ۳-۴ نمودار کلی معماری پیشنهادی نشان داده شده است. در این نمودار مراحل اصلی معماری از ابتدا (پیکره متن ورودی) تا خروجی نهایی (رتبه‌بندی اسناد) قابل مشاهده است.



mermaid

flowchart TD

subgraph A

۱] "اسناد" A

۲] "استند" A

۳] "ماتر" A

۴] "گاه" A

A ۵["نگاشت به فضای $D \setminus n^2$ ماتریس 64×64 "]

A6["Fingerprint عبارات \ Gaussian \n(spreading radius=1, decay=0.5, $\sigma = 1/\delta$ "]

A7["Fingerprint اسناد \n(جمع وزنی (TF-IDF"]

end

subgraph B ["تولید اثرانگشت پرس وجو"]

B ۱["پرس وجوی ورودی"]

B ۲["(استخراج عبارات پرس وجو)"]

B ۳["نگاشت عبارات پرس وجو \n(U-MAP و گرید)"]

B4["Fingerprint پرس وجو"]

end

subgraph C ["بازیابی با SF"]

C ۱["محاسبه شباهت SF: ضرب داخلی $FP(q)$ و $FP(d)$ "]

C ۲["لیست رتبه بندی SF"]

end

subgraph D ["بازیابی با SPLADE"]

D ۰["(شاخص گذاری اسناد (SPLADE)"]

D ۱["محاسبه بردار sparse پرس وجو (SPLADE)"]

D ۲["جستجو در شاخص SPLADE\n(فهرست نتایج مرتب)"]

D ۳["لیست رتبه‌بندی SPLADE"]

end

E subgraph E ["ادغام نتایج و پاسخ به پرس‌وجو"]

E1["SF + SPLADE Linear"]

E2["SF + SPLADE RRF"]

E ۳["نتایج نهایی"]

end

A1 --> A2 --> A3 --> A4 --> A5 --> A6 --> A7

B1 --> B2 --> B3 --> B4

B4 --> C

A7 --> C

A7 --> D

C --> E

D --> E

E1 --> E3

E2 --> E3

...

در این نمودار روند گام به گام سیستم نشان داده شده است: ابتدا استخراج عبارات و ساخت فضای معنایی، سپس تولید Fingerprint، و در نهایت پاسخ به پرس و جو با دو مسیر SF و SPLADE و ادغام نتایج.

۱۱-۳. خلاصه معماری و پیکربندی نهایی

۱-۱۱-۳. خلاصه معماری

بطور خلاصه، روش پیشنهادی ترکیبی از یک نمایش معنایی توپوگرافیک Fingerprint و یک رتبه‌بند sparse عصبی (SPLADE) است. مسیر Semantic Folding عبارات را به فضاهای sparse تبدیل می‌کند که نزدیکی‌های معنایی را در ساختار مکانی نگاشت‌شده حفظ می‌کند. مسیر SPLADE از یک مدل زبانی عصبی برای استخراج ویژگی‌های واژگانی و توسعه آن‌ها استفاده می‌کند. در نهایت، نتایج این دو روش با هم ادغام می‌شوند. آرایش کلی سیستم را می‌توان به صورت زیر نشان داد:

Query

|

———— Semantic Folding Pipeline ———> Rank_SF

|

———— SPLADE Pipeline ———> Rank_SPLADE

|

———— Fusion (Linear / RRF) ———→ Final Ranking

۳-۱۱-۲. پیکربندی نهایی و پارامترهای کلیدی

در جدول (۳-۱۲) خلاصه‌ای از پارامترهای اصلی مطابق با پیاده‌سازی انجام شده در پژوهش جاری ذکر شده است که در ادامه قابل مشاهده است.

جدول ۳-۱۲. پارامترهای نهایی روش پیاده‌سازی شده

پارامتر	مقدار یا انتخاب
روش کاهش ابعاد	method = UMAP *
تعداد همسایه در UMAP	n_neighbors = 15
حداقل فاصله در UMAP	min_dist = 0.1
معیار شباهت در UMAP	metric = cosine
ابعاد نقشه معنایی	grid_size = 64 # 64 × 64
گام گسترش مکانی (spreading_steps)	radius = 1
هموارسازی گاوسی (فیلتر گاوسی)	$\sigma = 1.5$
نرخ تضعیف	decay = 0.5
تنک‌سازی (sparsification)	top_percent = 10 ** درصد فعال‌سازی
morton ***	true
وزن‌دهی (weighting)	idf
تعداد بازگردانی اسناد	top_k = 100
دانه تصادفی	random_seed = 42
BM25 (K_1)	۱/۲ پیش‌فرض

۰/۷۵ پیش فرض	BM25 (b)
۶۰ توصیه شده	SPLADE ادغام رتبه متقابل (k)
۰/۳ بهترین انتخاب	SPLADE ادغام خطی (α)

* قابلیت پشتیبانی از t-SNE و PCA

** برای مجموعه داده قرآن، فقط ۵ درصد بالای سلول‌های فعال، نگه داشته شدند.

*** حالت فعال یا غیرفعال آن، تاثیری در نتایج نداشت.

مقادیر بهینه شده ذکر شده در جدول بالا بر اساس ارزیابی‌های انجام گرفته شده و راهنمای تنظیم پارامترها انتخاب شده‌اند (توجیه انتخاب هر یک از پارامترهای ذکر شده در جدول فوق در بخش ۴-۵ ارائه شده است). این فصل مبنای نظری و فنی پیاده‌سازی را فراهم کرده است و در فصل بعدی نتایج ارزیابی‌ها و تحلیل عملکرد ارائه خواهند شد.

فصل ۴: پیاده‌سازی و نتایج ارزیابی‌ها

در این فصل، جزییات پیاده‌سازی روش پژوهشی و تنظیمات نحوه ارزیابی آن شرح داده شده است. ابتدا محیط سخت‌افزاری و نرم‌افزاری مورد استفاده معرفی و سپس مجموعه داده‌های مورد آزمون و مراحل پیش‌پردازش توضیح داده شده است. به دنبال آن معیارها و خطوط مبنای مقایسه شامل ۲۵BM و DPR (به عنوان نمونه‌ای از retrieval متراکم) معرفی شده و در ادامه طرح کلی ارزیابی نیز ارائه گردیده است. سپس نتایج ارزیابی‌ها با جداول و نمودارهایی که روش‌های مختلف را در هر مجموعه داده مقایسه می‌کنند نمایش داده شده و تحلیل آماری گزارش شده است و در نهایت نکات قابل توجه و توصیه‌های پیاده‌سازی هم گردآوری شده است.

۴-۱. محیط اجرای روش پژوهشی

۴-۱-۱. سخت‌افزار

تمام بنچمارک‌گیری‌ها روی لپ‌تاپ شخصی با مشخصات زیر انجام شده است:

پردازنده‌ی مرکزی اینتل نسل ۵ با ۴ هسته و ۲.۴ گیگاهرتز ظرفیت

یک واحد پردازش گرافیکی NVIDIA GeForce MX ۳۳۰ برای تسریع عملیات مدل‌ها

۸ گیگابایت حافظه‌ی RAM (حداقل مقدار حافظه ضروری برای بارگذاری ماتریس‌های sparse (TF-IDF و هم‌رخدادی) و نگهداری Fingerprint‌ها است).

۴-۱-۲. نرم‌افزار و کتابخانه‌ها

پیاده‌سازی به زبان Python انجام و از کتابخانه‌های اصلی زیر استفاده شده است:

- NumPy/SciPy: برای محاسبات عددی ماتریس و بردارهای sparse.
- scikit-learn: برای محاسبه TF-IDF و همچنین الگوریتم‌های پایه UMAP.
- umap-learn: پیاده‌سازی اصلی UMAP.
- Transformers: برای استفاده از مدل‌های BERT و استخراج بردارهای SPLADE.
- PyTorch/TensorFlow: چارچوب اجرای مدل‌های عصبی (طبق انتخاب مدل SPLADE، معمولاً PyTorch).
- Pyserini یا Lucene: برای پیاده‌سازی BM25 (پایپرینی یک واسط پایتونی برای Lucene/Anserini است).
- سایر کتابخانه‌های کمکی مانند pandas و tqdm برای مدیریت داده و نمایش پیشرفت‌ها.

نکته: برای ساخت SPLADE از پیاده‌سازی‌های موجود استفاده شده است. همچنین به دلیل ماهیت چندزبانه، از مدل‌های چندزبانی (مثل mBERT یا mDPR) برای مسیر dense و SPLADE استفاده شده است.

۲-۴. مجموعه داده‌ها و پیش‌پردازش

۱-۲-۴. قرآن

- مجموعه‌ای دوزبانه (عربی-انگلیسی) متشکل از ۶,۲۳۶ آیه قرآن کریم به‌عنوان پیکره اسناد، همراه با ۳۰ جفت پرسش-پاسخ ساده‌شده با قضاوت ارتباط دودویی یک سند طلایی به ازای هر پرسش. این مجموعه با هدف سنجش عملکرد خط‌لوله دو بعدی در یک زبان با ساختار صرفی و نحوی متفاوت از انگلیسی انتخاب شد.

- دریافت و قالب: پیکره آیات و پرسش‌های ساده‌شده به‌صورت داخلی برای این پژوهش آماده و در قالب فایل‌های ساختاریافته (JSON) ذخیره شدند. ارزیابی با تنظیم $top_k=100$ انجام شد.
- پیش‌پردازش: مشابه رویه به‌کاررفته برای سایر مجموعه‌ها (بخش ۱-۴-۴)، با این تفاوت که به دلیل نبود عملیات ریشه‌یابی (stemming) در مرحله استخراج واژگان کلیدی پرسش، اشکال مفرد و جمع یک واژه (مانند «ملائکه» و «ملک») به‌صورت مستقل در نظر گرفته شدند؛ این موضوع در تحلیل خطا (بخش ۴-۴-۵) به‌عنوان یکی از علل اصلی افت عملکرد بررسی شده است.
- ویژگی کلیدی: تنها ۱۱ پرس‌وجو از ۳۰ پرس‌وجو موفق به بازیابی سند مرتبط با رتبه غیرصفر شدند (MRR بزرگ‌تر از صفر)؛ ۱۹ پرس‌وجوی باقی‌مانده با $MRR=0$ مواجه شدند. علل اصلی این شکست‌ها عبارت‌اند از: (۱) پرس‌وجوهای موضوعی و انتزاعی (مانند عدالت، رحمت، صبر) که بیش‌ازحد کلی هستند، (۲) عدم تطابق اشکال مفرد/جمع واژگان به دلیل نبود ریشه‌یابی، و (۳) بازگشت به حالت پرس‌وجوی کامل در مواردی که هیچ واژه کلیدی از فیلتر واژگان عبور نکرد (پرسش‌های ۲۸Q تا ۳۰Q).

۴-۲-۲. Belebele

Belebele یک مجموعه داده MRC چندگزینه‌ای چندزبانه با ۱۲۲ زبان است. این مجموعه برای QA طراحی شده و شامل جمله و گزینه پاسخ است. با این حال، از آنجا که ساختار بازیابی مستقیم (passage retrieval) ندارد، در این پژوهش از Belebele صرفاً به عنوان مجموعه داده QA یاد کردیم و تمرکز اصلی CAREN_Belebele بود.

۴-۲-۳. مجموعه AR-EN سفارشی

- پیکره‌ای دوزبانه موازی شامل ۴۸۸ سند به دو زبان عربی و انگلیسی، همراه با ۴۸۸ پرس‌وجوی متناظر که هر یک دقیقاً یک سند طلایی از میان کل ۴۸۸ سند

نامزد دارد. برخلاف Mr. TyDi و MIRACL که پرس‌وجو و سند در یک زبان واحدند، این مجموعه برای سنجش عملکرد روش در حالت **چندزبانگی هم‌ردیف** (هر دو طرف پرس‌وجو و سند، ترکیبی از دو زبان در یک پیکره مشترک) طراحی شده است نه بازیابی میان‌زبانی به معنای واقعی.

- تنظیمات: $grid_size=64$ ، و برای مقایسه معیار شباهت تصویری (SSIM) در برابر شباهت کسینوسی، $\sigma=1.5$ با ناحیه فعال (active region) استفاده شد.
- کاربرد در پژوهش: این مجموعه در دو آزمایش مجزا به کار رفت: (۱) مقایسه معیار شباهت کسینوسی با SSIM (بخش ۴-۴-۵)، که برتری معیار کسینوسی را نشان داد؛ و (۲) مقایسه نهایی روش پیشنهادی با BM۲۵ و ترکیب‌های SPLADE (جدول ۴-۲).

۴-۲-۴. مجموعه داده BEIR

در حال تکمیل

۴-۲-۵. Mr. TyDi

- Mr. TyDi یک مجموعه داده بازیابی چندزبانه است که ۱۱ زبان گوناگون را پوشش می‌دهد. در این مجموعه، پرس‌وجوها و اسناد در یک زبان واحد هستند (کار monolingual retrieval). Mr. TyDi شامل حدود ۳,۰۰۰-۵,۰۰۰ پرس‌وجو در هر زبان با به‌طور میانگین ۱/۸ متن مرتبط برای هر پرس‌وجو است (یعنی تقریباً هر پرس‌وجو فقط یک یا دو سند مرتبط دارد).
- دریافت و قالب: اسناد و پرس‌وجوها را از ریپازیتوری Mr. TyDi بارگیری شده است. هر زبان یک فایل JSON و TSV مجزا دارد.
- پیش‌پردازش: برای هر زبان، اسناد و پرس‌وجوها با همان توکن‌ساز (Tokenizer) مربوطه پردازش شد. غیرحروف و علائم خاص حذف شد، اسامی خاص و اعداد بدون تغییر ماندند. برای استخراج عبارات، ما n-گرام‌های ۱ تا ۳ را در نظر گرفتیم و

عبارات با فراوانی کمتر از ۵ حذف شدند. (در صورت دسترسی، می‌توان از واژگان‌های توکار BERT یا spaCy استفاده کرد؛ در اینجا پیاده‌سازی فاصله‌ای ساده به‌کار رفته است.)

۴-۲-۶. MIRACL

- MIRACL یک پایگاه داده Retrieval چندزبانه برای ۱۸ زبان مختلف (از جمله زبان‌های انگلیسی، عربی، فارسی، هیندی، اسپانیایی و غیره) است. این مجموعه شامل بیش از ۷۸,۰۰۰ پرس‌وجو و حدود ۷۲۶,۰۰۰ قضاوت relevance است (به‌طور متوسط بیش از ۹ سند مرتبط برای هر پرس‌وجو). داده‌ها از صفحات ویکی‌پدیا تهیه شده‌اند و توسط گویشوران بومی بی‌طرف ارزیابی شده‌اند.
- دریافت و قالب: MIRACL را از وب‌سایت رسمی آن بارگیری شده است. ساختار شامل سوالات، اسناد (ویکی‌پدیا) و قضاوت‌ها به‌صورت فایل TSV و JSON است.
- پیش‌پردازش: مشابه Mr. TyDi، هر زبان جداگانه پردازش شد. از آنجا که تعداد اسناد مرتبط برای هر پرس‌وجو در MIRACL بیشتر است، معیارهایی مانند MAP و NDCG به خوبی پاسخ می‌دهند. روش استخراج عبارات مشابه استفاده از n-گرام در نظر گرفته شد.

جدول ۴-۱. مجموعه داده‌های ارزیابی

مجموعه داده	زبان	پیکره	پرسش	ماهیت
قرآن کریم	عربی	۶,۲۳۶ آیه	۳۰ (چندمرتبط)	دینی/تخصصی

CAREN_Belebele	عربی+انگلیسی	۴۸۸ قطعه موازی	۴۸۸ (تکمرتبط)	دوزبانۀ موازی
mixed_ar_en	عربی+انگلیسی	همان ۴۸۸	۴۸۸ (پرسش ترکیبی)	دوزبانۀ
Belebele [55]	انگلیسی	۴۷۶ قطعه	۱۰۰	درک مطلب
NarrativeQA [58]	انگلیسی	۱۹,۵۸۵ قطعه	۵۰ (چندمرتبط)	روایت
PubMedQA [56]	انگلیسی	۱,۴۷۵ قطعه	۱۷۲-۳۱۱	پزشکی
PopQA [57]	انگلیسی	۱,۴۷۵ قطعه	۱,۰۰۰-۵۰۰	موجودیت محور
MuSiQue [40]	انگلیسی	۱,۸۶۲~ پاراگراف	۱۰۰ (کاندید ۲۰ تایی)	استدلالی
SciFact nfcopus SciDocs (BEIR [41])	انگلیسی	BEIR	۲۰۰-۳۰۰	علمی
cross_ar_en	عربی→انگلیسی	۴۸۸	۵۰	cross-lingual محض

Mr.TyDi-ar [59] عربی ~۵,۲k pooled (pool=100) ۱۹۹ چندزبانه باز

MIRACL-ar [60] عربی ~۵,۴k pooled (pool=100) ۲۰۰ چندزبانه باز

توجیه جایگزینی دیتاست‌های پروپوزال: مجموعه‌های پیشنهادی پروپوزال (SQuAD، NQ^{۲۷}، MS MARCO، XQuAD) همگی دامنه باز هستند (ویکی‌پدیا/وب)، درحالی‌که عنوان پژوهش «دامنه بسته» را هدف گرفته است. معادل‌های دامنه بسته جایگزین شدند: قرآن و پیکره دوزبانه دینی برای سناریوی چندزبانه (چالش XQuAD را با شدت بیشتر می‌پوشاند)، PubMedQA برای حوزه تخصصی پزشکی و BEIR برای مقایسه با ادبیات بازیابی.

۴-۳. معیارها و خطوط مبنای مقایسه

۴-۳-۱. معیارها

از معیارهای متداول زیر برای سنجش و ارزیابی استفاده شده است.

MRR: میانگین حاصل معکوس رتبه اولین سند مرتبط

MAP: میانگین دقت متوسط اسناد مرتبط

NDCG@k: مقدار نرمال‌شده DCG تا k نتیجه اول، که با توجه به رتبه اسناد مرتبط اهمیت را لحاظ می‌کند. به‌ویژه وقتی چند سطح ارتباط (مثلاً مرتبط کامل یا جزئی) وجود دارد مفید است.

در بنچمارک‌های گرفته شده بر روی مجموعه‌های تک‌مرتبط مانند CAREN_Belebe به دلیل وجود تنها یک پاسخ مرتبط برای هر پرس‌وجو، همیشه مقدار $MAP \equiv MRR$ است.

۲-۳-۴. خطوط مبنای مقایسه

- **BM25:** این شاخص یکی از بهترین خط‌مبناهایی است که می‌شد برای ارزیابی خوشه‌بندی معنایی استفاده کرد، چون یک روش واژگانی^{۲۸} کلاسیک و بسیار شناخته‌شده است در مقابل SF، که قرار است از ساختار فضای معنایی استفاده کند. ([Stanford NLP](#)) در نتیجه به عنوان خط‌مبنا واژگانی، از پیاده‌سازی BM25 موجود در Pyserini با پارامترهای پیش‌فرض $(k=1, b=0.75)$ استفاده شد.
 - **بازیابی متراکم (Dense Retrieval):** در این نوع خط‌مبنا می‌توان برای مقایسه از BERT، mDPR، DPR یا mBERT استفاده نمود. با توجه به چندزبانه بودن برخی مجموعه‌داده‌ای انتخابی برای ارزیابی، در این پژوهش از DPR چندزبانه (mDPR) استفاده شد تا عملکرد مدل‌های متراکم نشان داده شود.
 - **SPLADE:** از مدل پیش‌آموزش‌دیده [naver/splade-cocondenser-ensembledistil](#) در نسخه جدید SPLADE (نسخه ۲۷) استفاده شد. برای هر سند و پرس‌وجو، بردار sparse از توکن‌های کلمه به کلمه BERT تولید شد. در پیاده‌سازی نیز، بردارهای SPLADE را با یک ساختار معکوس (مانند Pyserini با قابلیت بارگذاری بردارهای sparse) ثبت شد.
- در بخش ۴-۷-۱ برای مقایسه خط‌مبنای بازیابی متراکم با BM25 و ترکیب SF+SPLADE از مدل **MiniLM** روی مجموعه‌داده SciFact استفاده شد؛ در جدول ۴-۷، به نتیجه خروجی اشاره شده است.

۴-۴. طرح کلی ارزیابی

ارزیابی بر پایه پروتکل استاندارد بازیابی است یعنی برای هر پرس و جو در مجموعه داده‌ها، روش باید اسناد مرتبط از میان پیکره متنی را بر اساس میزان شباهت رتبه‌بندی کند و معیارهای ارزیابی روی خروجی محاسبه شود و در نهایت نتایج با آزمون‌های معنی‌داری تایید یا رد شود. همه اجراها با دانه تصادفی برابر با ۴۲ بازتولیدپذیر هستند.

مرجع تجمیعی نتایج:

[outputs/COMPREHENSIVE_RESULTS_SUMMARY.md](#)

در پروتکل استاندارد بازیابی، ۱۰۰ نتیجه برتر هر کدام از روش‌های بازیابی برای مقایسه آنها به دست آورده شده است، که چارچوب کلی روش‌ها در جدول ۴-۵ نشان داده شده است.

جدول ۴-۲. چارچوب کلی روش‌های بازیابی

روش	نوع	نقش
BM25	پراکنده واژگانی	خط‌مبنا کلاسیک
DPR	عصبی متراکم	خط‌مبنا معنایی
SPLADE	عصبی پراکنده	خط‌مبنا ترکیبی
SF	معنایی فضایی	روش اصلی
SF + Linear SPLADE	ترکیبی	روش پیشنهادی
SF + RRF SPLADE	ترکیبی	روش پیشنهادی

برای سنجش نتایج روش‌ها، معیارهای MAP، MRR و NDCG@k در نظر گرفته شده‌اند.

در تحلیل تغییرات پارامترها و انجام آزمون معنی‌داری، برای بررسی اهمیت هر مؤلفه، ارزیابی‌هایی نظیر حذف گسترش یا استفاده از حالت فقط TF یا فقط هم‌رخدادی نیز اجرا شده است. برای هر مقایسه هم، آزمون‌های آماری برای تأیید معنی‌دار بودن بهبودها مورد استفاده قرار گرفته است.

۴-۴-۱. نتایج کمی ارزیابی‌ها

ارزیابی نتایج به دست آمده روش‌ها با معیارهای MAP، MRR و $NDCG@20$ روی مجموعه داده سفارشی دوزبانه عربی-انگلیسی^{۲۹}، در ادامه و در جدول ۴-۶ ارائه شده است.

جدول ۴-۳. عملکرد روش‌های بازیابی با معیارهای سنجش

روش / معیار	MRR	MAP *	NDCG@20
BM25	0.7854	0.7854	0.8233
mDPR	0.310	0.310	0.290
SPLADE	0.4811	0.4811	0.5152
SF	0.8166	0.8166	0.8472
SF+Linear SPLADE	0.8248	0.8248	0.8472
SF+RRF SPLADE	0.7001	0.7001	0.7557

* از آنجا که در مجموعه داده انتخابی هر پرس‌وجو دقیقاً یک سند مرتبط دارد، مقادیر MAP و MRR طبق فرمول برابرند.

۴-۴-۴-۱. تحلیل آماری معناداری نتایج در برابر خطمبنا ۲۵BM

در این بخش برای بنچمارک CAREN_Belebele، با توجه به پاسخ روش‌ها به هر کدام از پرس‌وجوها، آزمون‌های معنادار زوجی (paired) در برابر ۲۵BM بر روی مقادیر به‌تفکیک هر یک از ۴۸۸ پرس‌وجو انجام شد؛ نتیجه آزمون در جدول ۴-۴ نشان داده شده است.

در ادامه برای بنچمارک CAREN_Belebele، به بررسی آماری معنادار بودن تفاوت عملکرد روش‌های پیشنهادی در برابر خطمبنای ۲۵BM پرداخته شد. آزمون‌ها به‌صورت زوجی (paired) و بر روی مقادیر به‌تفکیک هر یک از ۴۸۸ پرس‌وجو انجام گرفتند. از آنجا که خطمبنای ۲۵BM در گزارش اولیه تنها به‌صورت میانگین ثبت شده بود، برای بازیابی مقادیر زوجی، روی همان ورودی‌ها (پیکره متن، پرس‌وجوها و جواب‌ها) دوباره اجرا شد که منجر به بازتولید عدد $MRR = 0.7854$ شد؛ لذا یکسان بودن داده‌ها نیز تایید شد.

جدول ۴-۴. آزمون معناداری آماری SF در برابر ۲۵BM

روش	بهبود نسبت به ۲۵BM	Wilcoxon p	McNemar p	نتیجه
SF	+0.031	3.85e-02	3.63e-02	بهتر از ۲۵BM
SPLADE	-0.304	1.29e-31	1.05e-24	بدتر از ۲۵BM
SF+Linear SPLADE	+0.039	1.64e-02	3.80e-02	بهتر از ۲۵BM
SF+RRF SPLADE	-0.085	5.13e-06	1.07e-05	بدتر از ۲۵BM

جزئیات تحلیل آماری: روی ۴۸۸ پرس‌وجو دو آزمون به‌کار گرفته شدند؛ (۱) آزمون ناپارامتریک **ویلکاکسون نشانه‌دار** (Wilcoxon signed-rank) (روی نمره بازآوری متقابل به‌تفکیک هر پرس‌وجو (per-query Reciprocal Rank) که با توجه به تک‌مرتبط‌بودن هر پرسش با میانگین دقت (AP) برابر است؛ و (۲) آزمون **مکنمار** (McNemar) (دقیق روی

متغیر دودویی موفقیت در رتبه اول ($1@hit$) با به دست آوردن p -value به روش دقیق شرطی دوجمله‌ای (exact conditional-binomial).

منبع: بخش Statistical Significance در `comparison_report.md` (داده per-query و اسکریپت `significance.py` ضمیمه همان شاخه)

تحلیل جدول ۴-۳ و ۴-۴

نتایج نشان داد که روش SF خالص ($MRR = 0.8166$ ؛ Pure SF) و ادغام خطی آن با SPLADE (با وزن MRR $\alpha = 0.3$) هر دو به طور معناداری از BM25 ($MRR = 0.7854$) بهتر عمل می‌کنند ($p > 0.05$ در هر دو آزمون؛ طبق جدول آماره‌ها و p -value). با اعمال اصلاح بونفرونی ($4/\alpha$) نیز همین نتایج پابرجا است چون کوچک‌ترین p در گروه برتر $p \approx 0.02$ است که حتی با $4/\alpha = 0.125$ هم معنادار می‌ماند؛ فقط RRF/SPLADE-only که خیلی کوچک‌ترند اصلاً تغییر نمی‌کنند.

در مقابل، به کارگیری SPLADE به تنهایی ($MRR = 0.4811$ ؛ $\alpha = 0$) و ادغام رتبه‌ای متقابل RRF (با MRR $k = 60$) هر دو به طور معناداری ضعیف‌تر از BM25 هستند ($p > 10^{-5}$). بر این اساس، افزودن مؤلفه واژگانی از مسیر RRF یا تکیه صرف بر نمایش SPLADE، کارایی را در این مجموعه دوزبانه کاهش می‌دهد؛ در حالی که رتبه‌بندی مبتنی بر SF – به ویژه با ادغام خطی SPLADE – بهترین عملکرد و برتری آماری نسبت به خط‌مبنا را فراهم می‌آورد.

ادغام SF با SPLADE خطی بهترین عملکرد کلی را در این مجموعه دارد، اما ادغام SF با SPLADE رتبه متقابل در این مجموعه داده عملکرد ضعیف‌تری نسبت به SF خالص نشان می‌دهد؛ لذا انتخاب روش ادغام باید بسته به ویژگی‌های مجموعه داده صورت گیرد.

همچنین مطابق با نتایج گرفته شده در بنچمارک‌گیری روی مجموعه داده Mr. TyDi، عملکرد DPR از ۲۵BM ضعیف‌تر است.

یافته کلیدی

در متون دوزبانه دامنه بسته، رتبه‌بندی مبتنی بر SF به‌طور معنادار از تطابق واژگانی ۲۵BM قوی‌تر است (از مهم‌ترین ادعاهای قابل دفاع پایان‌نامه برای برتری روش SF).

۴-۴-۲. بهترین نتیجه روی بنچمارک‌های تخصصی

در جدول ۷-۴ بهترین نتیجه ارزیابی نوع‌های روش SF و ۲۵BM روی بنچمارک‌های مختلف ذکر شده است.


جدول ۴-۵. عملکرد نوع‌های روش SF و ۲۵BM روی بنچمارک‌گیری‌های مختلف

#	بنچمارک	نوع SF و top_k	MRR	MAP	MRR BM25	MAP BM25	برنده
1	Belebele (100q)	Linear, 50	1.000	1.000	0.995	0.995	SF
2	NarrativeQA (50q)	Linear, 50	1.000	0.161*	0.980	0.776	SF
3	PubMedQA (172q)	RRF, 100	1.000	0.946	1.000	0.952	Tie
4	PopQA (500q)	RRF, 100	0.990	0.698	0.100	1.000	BM25
5	MuSiQue (100q)	Pure, 20	0.507	0.306	0.622	0.447	BM25
6	قرآن (۳۰q)	RRF, 60	0.538	0.218	0.155	0.072	SF
7	SciFact (200q)	Linear, 100	0.966	0.966	0.947	0.943	SF
8	nfcorpus (200q)	Linear, 100	0.655	0.423	0.686	0.393	BM25
9	SciDocs (300q)	Linear, 100	0.947	0.719	0.946	0.731	SF

SF	0.785	0.785	0.825	0.825	Linear, 100	CAREN_Belebele (488q)	10
lose**	-	-	0.020	0.020	Pure, 100	cross_ar_en (50q)	11

* وجود چندسند مرتبط؛ ** در بخش ۴-۴-۶ به این قسمت پرداخته شده است.

در ادامه در شکل ۴-۱ برتری روش‌ها بر یکدیگر نشان داده شده است.



شکل ۴-۱. بهترین نوع خانواده SF در مقایسه با BM25 بر حسب MRR

۴-۴-۳. بنچمارک‌های چندزبانه استاندارد Mr.TyDi و MIRACL عربی

برای سنجش روش روی دو مجموعه داده چندزبانه شناخته شده، زیرمجموعه‌های pooled-۱۰۰ از بخش عربی ۱/۱ Mr.TyDi و ۱/۰ MIRACL ساخته شد: ۲۰۰ پرس‌وجو، هر یک با یک سند مرتبط رسمی و ۹۹ سند نامرتب، نمونه‌گیری شده از پیکره متنی کامل (حدود ۵ هزار تایی با seed=۴۲)؛ نمایه‌سازی SF با روش کاهش ابعاد tsne.

در مجموعه داده MIRACL، به دلیل انفجار ماتریس واژگان عربی ویکی‌پدیا، شرط تعداد تکرار لازم برای اضافه شدن واژه به لیست برابر با ۳ در نظر گرفته شد (۳=min_freq).

جدول ۴-۶. عملکرد روش‌های بازیابی با معیارهای سنجش

روش	TyDi-ar MRR	MIRACL-ar MRR
E5-multilingual	0.989	0.860
BM25	0.881	0.815
Pure SF	0.544	0.542

نتیجه تست معناداری: برتری معنادار E5 بر SF در هر دو مجموعه داده ($p < 1e-11$)؛ برتری E5 بر BM25 در TyDi شدید ($p < 1e-5$) و در MIRACL مرزی ($p = 0.056$).

تفسیر: این نتیجه مرز کاربرد روش را شفاف می‌کند – روی قطعات دانشنامه‌ای دامنه‌باز با تنوع واژگانی عربی بالا، توپولوژی 64×64 ظرفیت تفکیک کافی ندارد و مدل‌های تراکمی‌چندزبانه غالب‌اند؛ برتری‌های مستند SF در فصل حاضر به مجموعه داده‌های تخصصی دامنه بسته تعلق دارد.

۴-۴-۴. آزمون شبکه واژگان (WordNet) برای واژگان خارج از پیکره

برای بررسی مزیت افزودن شبکه واژگان، سازوکار بخش ۴-۴-۱ به صورت زیر آزموده شد: روی همان ۴۸۸ پرسش مجموعه داده CAREN_Belebele، هر واژه انگلیسی خارج از واژگان پیکره (۷۴۹ مورد) با نخستین مترادف WordNet موجود در واژگان جانشین شد (۴۴۸ واژه یکتا؛ نرخ پوشش ۸۹.۹٪؛ ۳۷۷ پرسش دست‌خورده) و کل خط‌لوله SF خالص بدون هیچ تغییر دیگری اجرا گردید. در ادامه نتایج آزمون در جدول ۴-۷ آورده شده است.

جدول ۷-۴. آزمون سازوکار شبکه‌ واژگان: واریانت ۱۷ (جانشینی متن) و ۲۷ (ادغام اثرانگشت با میرایی)

معیار	Baseline: Pure SF	۱۷: جانشینی متن ($\gamma=1$)	۲۷: ادغام اثرانگشت ($\gamma=0.3$)	v2: $\gamma=0.6$
MRR	0.8166 / 0.8322*	0.8044	0.8328	0.8315
P@1	0.7664 / 0.7828*	0.7459	0.7848	0.7828
NDCG@20	0.8472 / 0.8608*	0.8384	0.8611	0.8601
پرسش‌های دست‌خورده	—	377	149	149
Wilcoxon p	—	۰/۰۲۴ (افت معنادار)	۰/۵۳۱ (بی‌معنا)	۰/۱۷۰ (بی‌معنا)

* دو خط پایه: رسمی (اجرای subprocess) / بازتولید کنترل‌شده درون‌فرآیندی بدون انتشار
که مبنای مقایسه ۲۷ است؛ هر مقایسه فقط با خط پایه هم‌مسیر خود معتبر است.

تحلیل: دو واریانت، دو درس طراحی می‌دهند.

۱. ۱۷ (جانشینی سطح-متن، $\gamma=1$): افت معنادار. بازرسی نگاشت‌ها نشان داد بخش

عمده «واژگان خارج از پیکره» صرفاً صورت‌های جمع/تصریف‌شده بودند

(borders→border) که لم‌سازی داخلی خط لوله خودشان مدیریت می‌کند؛

جایگزینی متن این هم‌ارزی را می‌شکند و ساختار عبارت‌سازی را مخدوش می‌سازد؛ برخی نگاشت‌ها هم معناشکن بودند (five→cinque).

۲. ۲۷ (ادغام اثرانگشت با میرایی): بی‌ضرر اما تقریباً بی‌اثر. با قاعدهٔ «فقط OOV» پس از لم‌سازی، پرسش‌های واقعاً متأثر از ۳۷۷ به ۱۴۹ کاهش یافت و در $\gamma=3/0$ هیچ تخریب معناداری رخ نداد ($p=3/5$) ولی بهبود نیز ناچیز بود؛ زیرا OOV حقیقی در این پیکره کمیاب و عمدتاً غیرتعیین‌کننده است.

جمع‌بندی طراحی: سازوکار شبکهٔ واژگان باید

(الف) پس از لم‌سازی داخلی فعال شود.

(ب) در سطح اثرانگشت و با ضریب میرایی $\gamma \geq 3/0$ ادغام گردد.

(ج) در پیکره‌های بسیار تخصصی فعال شود؛ چون بیشترین سود خود را در پیکره‌هایی خواهد برد که OOV حقیقی پرتکرار است (واژگان بسیار تخصصی)، نه پیکره‌های عمومی.

منبع:

[outputs/custom_ar_en_benchmark/benchmarks/benchmark_20260818_104602/wordnet_oov/](https://github.com/google-research/google-research/blob/master/wordnet_oov/outputs/custom_ar_en_benchmark/benchmarks/benchmark_20260818_104602/wordnet_oov/)

(v1: queries_wordnet.txt, substitutions.json, all_results.json,

v2: v2_summary.json) summary_metrics.json,

و اسکریپت‌های [wordnet_oov.py](#), [wordnet_eval.py](#), [wordnet_v2.py](#) در همان شاخه.

۴-۴-۵. نمودارها

برای نمایش چشم‌انداز کلی نتایج، از دو نوع نمودار استفاده می‌کنیم:

- نمودار میله‌ای (Bar Chart): مقایسه روش‌ها در معیار MRR در هر مجموعه.
- نمودار خطی (Line Chart) به ازای هر زبان: روند عملکرد برای روش‌های مختلف در زبان‌های متفاوت (به ویژه MIRACL).

۴-۵. تحلیل حساسیت پارامترها (بیاد قبل ۴-۴)

پیش از ارائه نتایج نهایی، لازم است پارامترهای اصلی خط‌لوله خوشه‌بندی معنایی شامل ابعاد نقشه معنایی، مقدار گسترش مکانی، درصد فعال‌سازی اثرانگشت، روش وزن‌دهی، انحراف معیار هموارسازی گاوسی (σ)، ضریب ادغام خطی با SPLADE و غیره، ارزیابی و مقدار بهینه هرکدام تعیین شود. این تحلیل، مبنای انتخاب پارامترهای نهایی گزارش‌شده در جدول پارامترهای فصل سوم (بخش ۳-۱۱-۲) را فراهم می‌کند.

منبع:

[semantic_folding/parameters_tuning.md](#)

۴-۵-۱. ابعاد نقشه معنایی

جدول ۴-۵-۱ نتایج آزمایش حساسیت اندازه ماتریس را روی مجموعه کوچک ۲۰ سندی با ۵ پرس‌وجو^{۳۰} را نشان می‌دهد.

جدول ۴-۵-۱. آزمایش حساسیت ابعاد نقشه معنایی

ابعاد نقشه معنایی	MRR	MAP	NDCG@5
64×64	1.000	0.869	0.919

0.888	0.836	0.900	128×128
-------	-------	-------	---------

طبق نتایج برای مجموعه‌های کوچک، نقشه معنایی با ابعاد ۶۴×۶۴ در تمام معیارها نسبت به ۱۲۸×۱۲۸ عملکرد بهتری دارد. علت این امر آن است که در پیکره‌های کوچک، افزایش ابعاد ماتریس باعث پراکندگی بیش‌ازحد فعالیت‌های اثرانگشت و کاهش هم‌پوشانی میان اسناد مرتبط می‌شود. بر این اساس، اندازه ۶۴×۶۴ به‌عنوان مقدار پیش‌فرض برای پیکره‌های کوچک تا متوسط انتخاب شد؛ برای مجموعه‌های بزرگ‌تر، در صورت پشتیبانی سخت‌افزاری مقیاس‌دهی به ۱۲۸ پیشنهاد می‌شود.

۲-۵-۴. گام گسترش مکانی (spreading_steps)

بررسی مقادیر مختلف گام گسترش مکانی نتایج زیر را نشان داد:

- در $\text{spreading_steps} = 0$ ، برخی اسناد مرتبط در پرس‌وجوها شناسایی نمی‌شود.
- در $\text{spreading_steps} = 1$ ، تمام اسناد مرتبط در همه پرس‌وجوها به‌درستی بازیابی می‌شوند؛ این مقدار به‌عنوان مقدار پیش‌فرض و بهینه انتخاب شد.
- در $\text{spreading_steps} = 2$ ، بهبود محسوسی نسبت به حالت قبل مشاهده نشد و صرفاً نویز بیشتری به اثرانگشت‌ها اضافه شد.

این یافته نشان می‌دهد که یک گام گسترش به همسایگی Moore، تعادل مناسبی میان پوشش معنایی کافی و جلوگیری از نویز اضافی برقرار می‌کند.

۳-۵-۴. درصد فعال‌سازی (top_percent)

- در $\text{top_percent} = 5$ (کم‌ترین تراکم)، سند اول در پرس‌وجوی پنجم مجموعه ۲۰ سندی از دست می‌رود؛ با این حال، همین مقدار روی پیکره قرآن به دلیل تفکیک‌پذیری بهتر میان اسناد، نتیجه بهتری داد.

- $\text{top_percent} = 10$ در مجموع متعادل‌ترین عملکرد را داشت و به‌عنوان مقدار پیشنهادی برای بنچمارک نهایی انتخاب شد.
- در $\text{top_percent} = 15$ (بیشترین تراکم)، هم سند اول از دست می‌رود و هم تمایز معنایی اثرانگشت‌ها کاهش می‌یابد.

نتیجه نشان می‌دهد که مقدار بهینه درصد فعال‌سازی به ماهیت پیکره متنی وابسته است؛ پیکره‌های با واژگان نزدیک به هم (مانند متون دینی) از تراکم پایین‌تر (۵) سود می‌برند، در حالی‌که برای پیکره‌های عمومی‌تر تراکم بیشتر (۱۰) ترجیح داده می‌شود.

۴-۵-۴. روش وزن‌دهی

مقایسه وزن‌دهی IDF با وزن‌دهی یکنواخت (uniform) نشان داد که وزن‌دهی IDF عملکرد به‌مراتب بهتری دارد، زیرا اهمیت بیشتری به واژگان نادر و تمایز دهنده می‌دهد. در مقابل، وزن‌دهی یکنواخت باعث افت رتبه سند ۱۸ به جایگاه چهارم در پرس‌وجوی دوم و از دست رفتن سند اول در پرس‌وجوی پنجم شد. بر این اساس، وزن‌دهی IDF در تمام آزمایش‌های بعدی به‌عنوان روش پیش‌فرض به کار گرفته شد.


۴-۵-۵. پارامتر هموارسازی گاوسی (σ)

بررسی مقادیر $\sigma \in \{1.0, 1.5, 2.0\}$ تفاوت محسوسی در نتایج نشان نداد (دامنه AP بین ۰.۸۲۴ تا ۰.۸۳۶ و دامنه NDCG بین ۰.۸۷۹ تا ۰.۸۸۸). با توجه به پایداری نتایج در این بازه، مقدار $\sigma = 1.5$ به‌عنوان مقدار پیش‌فرض و ایمن انتخاب شد.

۴-۵-۶. جاروب α در ادغام خطی با SPLADE

حساسیت α در ادغام خطی SF و SPLADE روی مجموعه AR-EN Belebele با ۱۰۰ پرس‌وجو بررسی شد؛ در شکل ۴-x مقدار MRR به ازای مقادیر مختلف α نمایش داده

شده است؛ بازهٔ بهینه $\alpha \in [0.25, 0.3]$ است و به دلیل عدم تاثیر این مولفه در ۲۵BM، با تغییر آن عملکرد ۲۵BM بدون تغییر باقی مانده است.



شکل ۴-۳. مقدار α در ادغام خطی با SPALDE

نتایج جدول ۴-۳ نشان می‌دهد که با افزایش مقدار α بالاتر از ۰.۳۵، تعداد پرس‌وجوهای ناموفق به‌طور پیوسته افزایش می‌یابد، که بیانگر آن است که در این مسئله سیگنال معنایی SF نقش غالب را دارد و SPLADE باید صرفاً نقش مکمل ایفا کند. بازهٔ $\alpha = 0.25$ تا ۰.۳۰ بهترین عملکرد را ارائه داد و مقدار $\alpha = 0.3$ به‌عنوان مقدار نهایی در بنچمارک انتخاب شد (منبع outputs/fusion_comparison_report.md).

جدول ۴-۳. مقدار MRR به ازای مقادیر مختلف α

8	6	3	3	2	2	2	3	3	تعداد شکست
0.92	0.94	0.97	0.97	0.98	0.98	0.98	0.97	0.97	MRR

0.7	0.5	0.4	0.35	0.3	0.27	0.25	0.2	0.1	α
-----	-----	-----	------	-----	------	------	-----	-----	----------

در حضور SPLADE، تصمیم به اعتبارسنجی مجدد ابعاد نقشه معنایی گرفته شد؛ برای اطمینان از پایداری انتخاب اندازه ماتریس در تنظیمات ادغامی (SF+SPLADE)، این پارامتر مجدداً روی مجموعه AR-EN Belebele بررسی شد؛ نتیجه در جدول ۴-x قابل مشاهده است.

ابعاد نقشه معنایی	MRR
۳۲×۳۲	۰.۹۲
۶۴×۶۴	۰.۹۸
۴۸×۴۸	ناموفق (به دلیل نبودن توان دو)

نتیجه این آزمایش، انتخاب اندازه ۶۴×۶۴ را که پیش‌تر در بخش ۴-۴-۵-۱ روی مجموعه کوچک به دست آمده بود، در تنظیمات ترکیبی نیز تأیید می‌کند. لازم به ذکر است که اندازه ۴۸×۴۸ به دلیل عدم سازگاری با رمزگذاری Morton Z-order (که نیازمند ابعاد توان دو است) قابل اجرا نبود؛ لذا این محدودیت باید در پیاده‌سازی‌های بعدی، هنگام انتخاب اندازه ماتریس مدنظر قرار گیرد.

۷-۵-۴. تعداد بازگردانی اسناد (top_k)

جهش اصلی نتیجه‌های Belebele/PubMedQA/PopQA به دلیل تغییر تعداد بازگردانی اسناد از ۲۰ به ۱۰۰ است (بزرگ‌شدن استخراج^{۳۲} کاندید) که هنگام مقایسه بین مجموعه داده‌ها باید لحاظ شود

۸-۵-۴. جدول ablation – سهم هر جزء


جدول ۴-۱، نتایج آزمایش ablation – سهم هر جزء در معیارهای بازیابی، روی مجموعه کوچک ۲۰ سندی با ۵ پرس‌وجو را نشان می‌دهد (منبع [semantic_folding/parameters_tuning.md](#)).

جدول ۴-۱. ablation – سهم هر جزء در معیارهای بازیابی

AP	NDCG@5	R@5	P@5	تغییر نسبت به پایه	واریانت
0.836	0.888	1.000	0.520	—	A پایه (grid=۱۲۸)
0.784	0.848	0.933	0.480	spreading_steps=0	B بدون انتشار
0.836	0.888	1.000	0.520	spreading_steps=2	C انتشار مضاعف
0.806	0.863	0.933	0.480	top_percent=0.05	D تنک‌تر

0.779	0.848	0.933	0.480	top_percent=0.15	E متراکم‌تر
0.772	0.842	0.933	0.480	weighting=uniform	F وزن یکنواخت
0.836	0.888	1.000	0.520	$\sigma=1.0$	G هموارسازی ضعیف
0.824	0.879	1.000	0.520	$\sigma=2.0$	H هموارسازی قوی
0.869	0.919	1.000	0.520	grid_size=64	I شبکه ۶۴×۶۴

تفسیر: سه مؤلفه «حیاتی» اند – انتشار فعال‌سازی (بدون آن $R@5$ افت می‌کند)، تنک‌سازی متعادل و وزن‌دهی IDF (حالت uniform سند اول را از دست می‌دهد). مؤلفه هموارسازی کمترین حساسیت را دارد و مهم‌ترین عامل جهش، انتخاب اندازه ۶۴ برای ابعاد ماتریس است.



شکل ۴-۸. مقایسه AP واریانت‌های sweep؛ ستون سبز = پیکربندی نهایی (grid=۶۴)

۴-۵-۹. جمع‌بندی

نتایج این بخش نشان می‌دهد که ترکیب پارامتری { $\text{grid}=64 \times 64$, $\text{spreading_steps}=1$, $\text{top_percent}=10$, $\alpha=0.5$, $\text{IDF}=0.3$ } – که در جدول پارامترهای فصل سوم (بخش ۳-۱۱-۲) به‌عنوان تنظیمات نهایی معرفی شده بود – نه یک انتخاب اختیاری، بلکه نتیجه مستقیم این تحلیل حساسیت است. این نکته پایداری خط‌لوله پیشنهادی را در برابر تغییرات معقول پارامترها نشان می‌دهد.

۴-۶. سرعت و مصرف منابع

- نمایه‌سازی SF یک بار انجام می‌شود و گام ۷ تنک و برداری است؛ نُرم‌های اسناد پیش‌محاسبه می‌شوند.
- SemFold (ارشد مشه‌دیزاده) الگوی «دقت قابل قبول، سرعت ممتاز» را با پاسخگویی حدود ۲۰ برابر سریع‌تر از BERT با دقت هم‌سطح GloVe/FastText گزارش کرده است.

۴-۷. مقایسه با مدل‌های عصبی

۴-۷-۱. خط‌مبنای متراکم اجراشده روی SciFact

برای آنکه مقایسه با شبکه‌های عصبی فراتر از ارجاع ادبی باشد، یک مدل بازیابی تراکمی واقعی (`all-MiniLM-L6-v2`) با ۳۸۴ بُعد، شباهت کسینوسی روی ۲۱۳ سند و ۲۰۰ پرس‌وجو اجرا شد.

جدول ۴-۷. مقایسه خط‌مبنای بازیابی متراکم MiniLM روی SciFact.

NDCG@20	MRR	روش (SciFact))
—	0.966	SF+SPLADE Linear $\alpha=0.3$
—	0.947	BM25
0.892	0.865	Dense MiniLM-L6-v2

منبع:

۹ `outputs/scifact_benchmark/dense_baseline_summary.json` و اسکریپت `scripts/dense_baseline_scifact.py`

یافته: بهترین واریانت SF نه‌تنها از ۲۵BM بلکه از بازنمایی تراکمی یادگرفته‌شده MiniLM نیز جلوتر است؛ این در حالی است که SF کاملاً بدون ناظر و بدون هیچ داده آموزشی خارج از پیکره کار می‌کند.

گسترش به همه دیتاست‌ها (`E5-multilingual`) با همان پروتکل، مدل `multilingual-e5-small` روی مجموعه داده‌های تخصصی موجود اجرا شد:

جدول ۴-۸. MRR خط‌مبنای تراکمی E5 در مقایسه با بهترین SF و BM25.

برنده	E5-multi	BM25	Best SF	مجموعه داده
SF	0.865	0.947	0.966	SciFact
BM25	0.405	0.686	0.655	nfcorpus
SF		0.946	0.947	SciDocs
SF	0.971	0.995	1.000	Belebele
SF		0.980	1.000	NarrativeQA
SF, BM25	0.981	1.000	1.000	PubMedQA
BM25	0.996	1.000	0.990	PopQA
BM25	0.520	0.622	0.507	MuSiQue
SF	0.747	0.785	0.825	CAREN_Belebele
SF	0.235	0.155	0.538	Quran

E5	0.989	0.881	0.544	Mr.TyDi-ar
----	--------------	-------	-------	------------

E5	0.860	0.815	0.542	MIRACL-ar
----	--------------	-------	-------	-----------

منبع: `outputs/dense_e5_summary.json` و

`scripts/dense_e5_all.py`؛ ردیف‌های TyDi/MIRACL از بخش ۴-۴-۴.

الگو: در دامنه‌های بسته تخصصی (۶ از ۸ مجموعه اصلی) بهترین SF جلوتر یا هم‌تراز ۵E است؛ در مجموعه داده‌های دامنه باز دانشنامه‌ای (TyDi/MIRACL) و موجودیت‌محور، بازیابی متراکم غالب است – مرزی که در بخش ۴-۴-۴ تحلیل شد.

۴-۷-۲. مقایسه ادبی (پایان‌نامه مشه‌دیزاده [۵۱])

مقایسه مستقیم re-run نشده؛ ارجاع ادبی (برچسب صریح):

جدول ۹-۴. بهترین دقت روش‌های تعبیه کلمات روی مجموعه داده‌های چندگزینه‌ای (به نقل از [۵۱]).

مدل	CSQA	QASC	ARC	منبع
FastText	57.26%	66.27%	49.6%	پایان‌نامه مشه‌دیزاده، جدول ۸-۵
GloVe-300d	60.83%	57.39%	54.4%	همان

همان	73.2%	76.24%	69.80%	BERT
------	-------	--------	--------	------


همان	52.0%	70.71%	60.89%	SemFold
------	-------	--------	--------	---------

نکته روایت: SPLADE خود یک مدل عصبی آموزش دیده است که هم به عنوان خط مبنا و هم مؤلفه فیوژن استفاده شد؛ علاوه بر آن، خط مبنای تراکمی MiniLM نیز مستقیماً اجرا شد (بخش ۴-۷-۱). بنابراین ادعای پروپوزال درباره «مقایسه با شبکه های عصبی» از هر دو مسیر برآورده شده است. HippoRAG نیز روی MuSiQue نتایج منتشر شده دارد که برای مقایسه آینده در دسترس است [۴۲].

۴-۸. برخی از ویژگی های رفتاری اثرانگشت های معنایی

۴-۸-۱. استقلال زبانی

اثرانگشت معنایی کلمات هم معنی در زبان های مختلف با توجه به میزان شباهتی که دارند و




طبق مفهومی که از آنها برداشت می شود، درصد شباهت بالایی دارند (شکل ۶).

شکل ۶. اثرانگشت معنایی کلمه فلسفه در برخی زبان ها [۱۳]

۲-۸-۴. مقاوم در برابر ابهام

اثرانگشت معنایی کلماتی که معانی مختلفی دارند ترکیبی از اثرانگشت معنایی هر کدام از معناها می‌شود [۷] که در شکل (۷) می‌توان به وضوح این موضوع را در اثرانگشت معنایی کلمه apple مشاهده کرد.




شکل ۷. ابهام زدایی مفاهیم برداشت شده از کلمه [13] apple

۳-۸-۴. محاسبات بر روی اثرانگشت‌های معنایی

با توجه به اینکه برخی مفاهیم امکان دارد در بخشی از مفهومی که از آنها برداشت می‌شود شباهت زیادی داشته باشند، شباهت اثرانگشت‌های معنایی آنها نیز در همان بخش زیاد است. به عنوان مثال اثرانگشت معنایی یوزپلنگ و ماشین پورشه در قسمت مربوط به مفهوم سرعت، دارای شباهت زیاد و اثرانگشت معنایی یوزپلنگ و ببر در قسمت مربوط به سرعت دارای اختلاف


زیاد هستند، که اگر ما از اثرانگشت معنایی یوزپلنگ قسمت سرعت را حذف کنیم انتظار داریم که به اثرانگشت معنایی ببر برسیم (شکل ۸).



شکل ۸. انجام محاسبات بر روی اثرانگشت معنایی کلمات [۱۳]

۴-۸-۴. تحمل پذیری خطا

با توجه به نزدیکی و در کنار هم قرار گرفتن مفاهیم دارای معانی مشترک و نزدیک به هم، در صورتی که قسمتی از اثرانگشت معنایی به دلیل نویز از دست برود نیز می‌توان از روی اثرانگشت‌های مشابه مفهوم از دست رفته را تا حدی تشخیص داد، این ویژگی روش خوشه‌بندی معنایی را می‌توان به راحتی از روی شکل (۵) استنباط کرد.



شکل ۵. اثرانگشت معنایی کلمات shore و coast به معنای ساحل [۱۶]

۹-۴. تحلیل خطاها و شکست‌ها

۱. **cross-lingual** محض (cross_ar_en): پرسش عربی بدون هیچ متن موازی انگلیسی منجر به $MRR = 0.02$ شد.

نتیجه: نگاشت چندزبانه بدون پل واژگانی ممکن نیست؛ راهکار عملی همان پیکره موازی دوزبانه (CAREN_Belebele) است که موفق بود.

۲. **پرسش‌های موضوعی قرآن**: واژه‌های کلیدی عام (عدالت، مهربانی) در نقشه پراکنده می‌شوند؛ استخراج عبارات نیازمند گسترش پرسش یا ریشه‌یابی (stemming) است.

۳. **واژگان خارج از پیکره (OOV)**: نام‌علم‌ها و صیغه‌های غایب در واژه‌نامه اثرانگشت تهی دارند (سازوکار شبکه واژگان در بخش ۳-۲-۱ برای همین طراحی شد).

۴. استدلال چندمرحله‌ای^{۳۳}: (MuSiQue) روش SF تک‌پرسی است؛ ترکیب چند سند مرتبط نیازمند سازوکار استدلال (کار آینده، مانند شبکه‌توجه گرافی^{۳۴}) است.

۵. **AP** پایین در **NarrativeQA** محدودیت معیاری/ساختاری است (هر پرسش چندین سند مرتبط دارد)، نه ضعف الگوریتمی.

۶. مجموعه داده‌های دامنه باز TyDi و MIRACL poole عربی: MRR ≈ 0.54 در برابر BM ≈ 0.85 و E ≈ 0.93 مرز کاربرد روش SF را شفاف می‌کند؛ روی قطعات دانشنامه‌ای دامنه باز با تنوع واژگانی عربی بالا، توپولوژی 64×64 ظرفیت تفکیک کافی ندارد؛ لذا مرز کاربرد روش SF، مجموعه داده‌های تخصصی دامنه بسته است (بخش ۴-۴-۳).

۴-۱۰. تحلیل کیفی نتایج

نتایج بنچمارک‌گیری‌ها در دو بخش ارائه شده است: اول عملکرد هر سیستم به صورت مستقل، و سپس نتایج ترکیبی.

به طور کلی، نتایج بنچمارک‌ها نشان می‌دهد:

- (SF Semantic Folding) تنها: این سیستم توانایی شناسایی اسناد مرتبط بر اساس نزدیکی معنایی fingerprintها را دارد. در زبان‌هایی که پرس‌وجو و اسناد دارای واژگان و زمینه‌های مشابه هستند، SF عملکرد مناسبی دارد. اما در پرس‌وجوهایی که شامل واژگان فنی یا نام‌های خاص (همچون کدها، شاخص‌ها و

^{۳۳} Multi-hop .

^{۳۴} GAT .

غیره) می‌باشند، ممکن است چون SF بیش‌تر روی معنا تمرکز دارد، در مقایسه با ۲۵BM اندکی پایین‌تر عمل کند. به عنوان مثال، در Mr. TyDi زبان فارسی مشاهده شد که SF توانسته برخی از اسناد مرتبط معنایی را که ۲۵BM پیدا نکرد، شناسایی کند، ولی در مواردی که سوال شامل شناسه‌های دقیق بود، ۲۵BM بهتر عمل کرد. ۱۰@MRR و ۱۰@NDCG برای SF در حد و حدود معقول و نزدیک به ۲۵BM اندازه‌گیری شد.

- SPLADE تنها: SPLADE که یک retriever عصبی sparse است، بدتر از ۲۵BM عمل کرد. بردارهای تولیدشده توسط SPLADE از ترکیب واژگانی و تعبیه‌های مدل زبانی استفاده می‌کنند، بنابراین می‌توانند روابط معنایی فراتر از تطابق دقیق کلمات را ضبط کنند. در آزمایش‌ها، SPLADE به‌خصوص در پرس‌وجوهای کوتاه و عمومی توانست اسناد مرتبطی را رتبه‌بندی کند. با این حال، هزینه محاسباتی تولید بردار SPLADE (یک مرتبه عبور مدل BERT برای هر متن) نسبت به SF بیشتر است.
- ۲۵BM: برای مقایسه، نتایج ۲۵BM نیز به‌عنوان baseline آورده شده است. ۲۵BM یکی از بهترین baseline‌هایی است که می‌شد برای ارزیابی Semantic Folding استفاده کرد، چون یک روش واژگانی^{۳۵} کلاسیک و بسیار شناخته‌شده است؛ در مقابل SF که قرار است از ساختار فضای معنایی استفاده کند. ([Stanford NLP](#)) در اغلب مجموعه‌ها، ۲۵BM کارایی قابل قبولی داشت، به ویژه در پرس‌وجوهای با کلمات کلیدی مشخص. آمار Mr. TyDi نیز نشان می‌دهد که ۲۵BM صرفاً با بردار sparse کلاسیک در اغلب زبان‌ها از رویکردهای dense قوی‌تر است.
- Hybrid (SF + SPLADE): ترکیب نتایج دو روش فوق معمولاً بهترین نتایج را به همراه دارد. با استفاده از RRF یا ترکیب خطی، نشان داده شد که هر دو بخش اسپارس‌محور در زبان‌های مختلف سیگنال‌های مکمل فراهم می‌کنند. به طور خاص، در مواردی که SF و SPLADE هر دو سندی را رتبه‌بندی کردند، RRF امتیاز

بالاتری می‌دهد. از سوی دیگر، Linear Fusion وزن‌دهی امکان تنظیم دقت سیستم را می‌دهد. برای مثال، در زبان‌هایی که مولفه معنایی (SF) اهمیت بیشتری دارد، می‌توان (α) را بالاتر گرفت. نتایج بنچمارک‌ها نشان داد که به طور میانگین ترکیب Hybrid نسبت به هر یک به‌تنهایی برتری داشت. این نتیجه با آنچه Zhang و همکاران در Mr. TyDi گزارش کردند (بهبود ۲۵BM با سیگنال dense) همخوانی دارد.

در بخش بررسی به ازای هر معیار نیز مشاهده شد:

- MRR: ترکیب SF+SPLADE بیش‌ترین MRR را داشت، زیرا هر دو سیستم شانس قرار دادن اولین سند مرتبط را افزایش دادند. برای مثال، اگر SF اولی را رتبه ۲ و SPLADE رتبه ۴ یافته باشد، RRF ترکیبی برای رتبه‌های اول شانس بالاتری فراهم می‌کند.
- MAP و NDCG: در MIRACL برای بسیاری از پرس‌وجوها بیش از یک سند مرتبط وجود دارد؛ از این‌رو معیارهایی مانند MAP و NDCG برای ارزیابی رتبه‌بندی چندین سند مرتبط اهمیت پیدا می‌کنند. ترکیب Hybrid نیز در این معیارها عملکرد بهتری داشت؛ به خصوص $NDCG@20$. نشان داده شد که حتی در برخی زبان‌ها (مثلاً ژاپنی) که واژگان خاص فنی وجود دارد، ترکیب معنایی و عصبی توانست اسناد مرتبط بیشتری را به رتبه‌های بالاتر بیاورد.
- مقایسه مقیاس امتیازات: در ترکیب خطی، اگر امتیازات SF و SPLADE را مستقیم جمع کنیم، مشکلات مقیاس پیش می‌آید. برای اجتناب از این مشکل، ما قبل از ادغام امتیازات، هر سیستم را به دامنه $[0,1]$ نرمال کردیم. RRF از این مسئله مصون است زیرا به جای امتیاز شباهت، رتبه را در نظر می‌گیرد.

۱۱-۴. ملاحظات پیاده‌سازی

- مقیاس‌پذیری: با افزایش حجم اسناد، ساخت ماتریس ترم-زمینه و نگهداری Fingerprintها نیازمند حافظه و زمان بیشتر است. در مجموعه‌های بزرگ، از نمونه‌برداری یا روش‌های ANN برای کاهش فضای جستجو استفاده شد.
- محدودیت‌های UMAP: کاهش بُعد تصادفی است (اثر دانه تصادفی)؛ بنابراین از یک دانه ثابت (seed) برای قابلیت تکرار استفاده شد.
- سینک‌سازی مدل‌ها: از آنجا که چندین مدل مختلف (BM25, DPR, SPLADE) استفاده شد، کنترل دقیق پارامترها و نسخه‌های مدل اهمیت داشت. در پایان‌نامه یک لیست کنترل ارائه شده تا همه تنظیمات ثبت شوند.
- محاسبات تصادفی: مراحل عصبی (مانند BERT) حساس به مقداردهی تصادفی هستند؛ بنابراین برای بررسی قابلیت تکرار، عبارات ثابت (seed) در PyTorch/TensorFlow تنظیم شده‌اند.
- لیست کنترل: برای مثال، seedهای Python، NumPy و PyTorch قبل از اجرای آزمایش‌ها تنظیم شده است و نسخه‌های دقیق کتابخانه‌ها و سیستم عامل در مستندات ثبت گردیده است.
- بررسی پایداری و انتقال‌پذیری: برای اطمینان از تکرارپذیری نتایج، تمام مراحل با دقت ثبت و کدها در یک مخزن Git عمومی ذخیره شده است. دانه‌های تصادفی (random seed) برای UMAP و سایر مراحل مبتنی بر نمونه‌گیری ثابت شدند تا هر بار یکسان نتیجه حاصل شود. علاوه بر این، بهینه‌سازی‌ها (مانند وزن‌دهی هاپینگ در SPLADE یا وزن $(\alpha \backslash)$) در مجموعه ارزیابی (development) تعیین و سپس روی مجموعه تست گزارش شده‌اند. این موضوع تضمین می‌کند که نتایج در تکرارهای بعدی قابل بازتولید باشند.

۱۲-۴. جمع‌بندی نتایج

به طور خلاصه، نتایج نشان می‌دهد که روش Semantic Folding با fingerprintهای معنایی می‌تواند سیگنال‌های مفیدی برای بازیابی در محیط‌های چندزبانه فراهم کند و بهبودهایی نسبت به ۲۵BM در برخی موارد ارائه کند. ترکیب آن با SPLADE بهترین عملکرد کلی را داشت و در اغلب موارد توانسته است بر ۲۵BM غلبه کند و در معیارهای رتبه‌بندی پیش‌تاز باشد؛ روشی که مزایای تطابق واژگانی و نمایه‌سازی sparse عصبی و نیز اطلاعات معنایی را یکجا به کار می‌گیرد.

به‌علاوه، تحلیل نتایج به تفکیک زبان‌های مختلف نشان داد که عملکرد روش پیشنهادی در زبان‌های با منابع کم یا ساختار دستوری متفاوت (مثل عربی) اغلب بهبودهایی نسبت به ۲۵BM و DPR ارائه می‌دهد. نمودارها و جداول بالا این نتایج را نشان می‌دهند. این فصل همچنین محدودیت‌هایی مانند هزینه محاسباتی بالا در مجموعه‌های بزرگ را شناسایی کرده و راهکارهایی همچون شاخص‌های sparse و ANN را پیشنهاد کرد. در کل این یافته‌ها نشان داد که روش پیشنهادی پژوهش جاری، با وجود نوآوری، با مبانی و نتایج قبلی در ادبیات همراستا است و زمینه‌ی بحث‌های فصل بعد و نتیجه‌گیری کلی را فراهم آورده است.

فصل پنجم: جمع‌بندی، نتیجه‌گیری و پیشنهادها

در این فصل، مهم‌ترین یافته‌های پژوهش جمع‌بندی می‌شود و نتایج به‌دست‌آمده در ارتباط با اهداف و پرسش‌های پژوهش مورد بررسی قرار می‌گیرد. سپس دستاوردهای اصلی و محدودیت‌های روش پیشنهادی بیان شده و در پایان، مسیرهای پیشنهادی برای ادامه پژوهش ارائه می‌شوند.

در حال بازنگری

۱-۵. جمع‌بندی پژوهش

هدف اصلی این پژوهش، بررسی قابلیت استفاده از یک بازنمایی معنایی مبتنی بر **Semantic Folding** برای بازیابی اطلاعات در محیط‌های دامنه‌بسته و چندزبانه بود. تمرکز پژوهش بر بخش **بازیابی** قرار داشت؛ به این معنا که کیفیت روش بر اساس توانایی آن در یافتن و رتبه‌بندی اسناد مرتبط با پرس‌وجو ارزیابی شد و تولید پاسخ نهایی خارج از دامنه ارزیابی اصلی پژوهش بود.

برای دستیابی به این هدف، یک خط لوله بازتولیدپذیر طراحی و پیاده‌سازی شد که شامل شش مرحله اصلی پردازش و یک مرحله ارزیابی است: استخراج عبارت‌ها، ساخت ماتریس واژه-مفهوم، ایجاد فضای معنایی دوبعدی، تولید اثرانگشت عبارت، تولید اثرانگشت سند و در نهایت پردازش پرس‌وجو و بازیابی. در پیکربندی نهایی، از UMAP با پارامترهای `n_neighbors=15`، `min_dist=0.1` و معیار کسینوسی استفاده شد و فضای معنایی روی یک ماتریس ۶۴×۶۴ نگاشت شد. در مرحله بازیابی نیز انتشار فضایی با یک گام و ضریب کاهش ۰/۵ انجام شد.

در سطح بازیابی، **Pure Semantic Folding** به‌عنوان روش اصلی بررسی شد و سپس امکان ترکیب آن با **SPLADE** نیز ارزیابی گردید. برای ترکیب دو روش، دو سازوکار Linear

Fusion و Reciprocal Rank Fusion بررسی شد. در تنظیم نهایی، ضریب ترکیب Linear برابر با تقریباً 0.3 و پارامتر RRF برابر با 60 در نظر گرفته شد.

بررسی نتایج نشان داد که عملکرد Semantic Folding به ویژگی‌های مجموعه داده وابسته است. در برخی مجموعه‌های داده، به‌ویژه داده‌های دوزبانه و برخی حوزه‌های تخصصی، استفاده از بازنمایی فضایی معنایی توانست نسبت به $25BM$ بهبود ایجاد کند. در مقابل، در مجموعه‌هایی که وابستگی بیشتری به نام‌های خاص، موجودیت‌های مشخص یا استدلال چندمرحله‌ای دارند، مزیت روش کاهش یافت.

یکی از نتایج مهم پژوهش و بنچمارک‌ها، نقش مکمل SPLADE بود. ترکیب SF و SPLADE در چندین مجموعه داده عملکرد بالایی ایجاد کرد؛ با این حال، یک روش ترکیب شده واحد برای تمام مجموعه داده‌ها بهترین گزینه نبود. برای مثال، در برخی مجموعه‌ها Linear Fusion و در برخی دیگر RRF عملکرد بهتری داشتند. این موضوع نشان می‌دهد که سیگنال فضایی Semantic Folding و سیگنال sparse عصبی SPLADE می‌توانند اطلاعات مکملی در اختیار سامانه بازیابی قرار دهند. روش ترکیبی SF+SPLADE در مجموع از $25BM$ و DPR پیشی گرفته است. بهبودهای چشمگیر در معیارهای MRR و NDCG (به ویژه در مجموعه دوزبانه CAREN_Belebele) مشاهده شده است. این نتایج نشان دادند که بهره‌گیری همزمان از اطلاعات واژگانی (از طریق TF-IDF و نمایه‌سازی معکوس) و نمایه‌های معنایی توزیعی می‌تواند کارایی بازیابی را افزایش دهد.

نتایج کمی نیز این موضوع را تأیید می‌کنند. برای نمونه، در Belebele مقدار MRR روش SF+SPLADE برابر با $1/1000$ و برای $25BM$ برابر با 0.995 گزارش شده است. در SciFact نیز SF+SPLADE Linear با MRR برابر با 0.966 از $25BM$ با MRR برابر با 0.947 بهتر عمل کرده است. در مقابل، در MuSiQue مقدار MRR روش Pure SF برابر با 0.507 بوده،

در حالی که ۲۵BM به مقدار ۶۲۲/۰ رسیده است. بنابراین نمی‌توان برتری Semantic Folding را مستقل از نوع مسئله و ویژگی‌های داده به‌صورت کلی ادعا کرد.

در حوزه بازیابی چندزبانه نیز نتایج نشان دادند که روش پیشنهادی در تنظیماتی که متن‌های مرتبط در یک فضای معنایی مشترک قرار می‌گیرند، ظرفیت مناسبی دارد. در آزمایش‌های دوزبانه مانند AR-EN، عملکرد SF در مقایسه با ۲۵BM بهبود نشان داد؛ باین‌حال، نتایج مجموعه‌های عربی Mr. TyDi و MIRACL نشان دادند که روش فعلی هنوز برای بازیابی واقعی میان‌زبانی، به‌ویژه در پیکره‌های متنی گسترده دانشنامه‌ای دامنه‌باز، محدودیت دارد.

در مجموع، یافته‌های پژوهش نشان می‌دهد که Semantic Folding را می‌توان به‌عنوان یک سیگنال معنایی فضایی برای بازیابی به کار گرفت، اما کارایی آن به ساختار پیکره، نوع پرس‌وجو، پوشش واژگان و میزان نیاز مسئله به تطابق دقیق موجودیت‌ها یا استدلال چندمرحله‌ای وابسته است.

۲-۵. نتیجه‌گیری نهایی

بر اساس نتایج حاصل از آزمایش‌ها، می‌توان نتیجه گرفت که بازنمایی Semantic Folding قادر است اطلاعاتی متفاوت از تطابق صرفاً واژگانی در اختیار سامانه بازیابی قرار دهد. این ویژگی در برخی مجموعه‌های داده باعث بهبود رتبه‌بندی نسبت به ۲۵BM شده است.

یکی از مهم‌ترین یافته‌های پژوهش، عملکرد مناسب روش در داده‌های دوزبانه‌ای است که در آن‌ها ساختار مشترکی میان متن اصلی و ترجمه ایجاد شده است. در این شرایط، نمایش فضایی مشترک می‌تواند بخشی از مسئله عدم تطابق واژگانی را کاهش دهد. باین‌حال، این نتیجه نباید به معنای حل کامل مسئله cross-lingual retrieval تفسیر شود؛ زیرا نتایج Mr. TyDi و MIRACL عربی نشان دادند که روش فعلی در پیکره‌های بزرگ و واژگانی متنوع هنوز از روش‌های قوی‌تر عقب است.

دومین یافته مهم، نقش وزن‌دهی در ساخت اثرانگشت اسناد است. استفاده از وزن‌های مبتنی بر $TF-IDF/IDF$ موجب می‌شود سهم عبارت‌های مهم‌تر در fingerprint سند بیشتر از عبارت‌های عمومی باشد. در نتیجه، نمایش نهایی سند صرفاً بیانگر حضور مفاهیم نیست، بلکه اهمیت نسبی آن‌ها را نیز در نظر می‌گیرد.

سومین یافته، ارزش استفاده از معماری ترکیبی است. نتایج نشان می‌دهند که SF و SPLADE می‌توانند سیگنال‌های مکملی ارائه کنند. در بسیاری از آزمایش‌ها، ترکیب این دو روش عملکرد مناسبی ایجاد کرده است؛ با این حال، انتخاب Linear Fusion یا RRF به مجموعه داده وابسته است و نمی‌توان یکی از آن‌ها را به عنوان بهترین روش برای تمام شرایط معرفی کرد. تنظیم Linear با $\alpha \approx 0.3$ در چندین مجموعه داده عملکرد مناسبی داشته است، در حالی که RRF در برخی مجموعه‌ها از جمله قرآن، PubMedQA و PopQA مزیت بیشتری نشان داده است.

همچنین مقایسه با بازیابی تراکمی نشان داد که Semantic Folding در یک آزمایش کنترل‌شده روی SciFact توانسته است از مدل `all-MiniLM-L6-v2` عملکرد بالاتری داشته باشد. MRR روش SF+SPLADE برابر با ۰/۹۶۶، ۲۵BM برابر با ۰/۹۴۷ و مدل MiniLM برابر با ۰/۸۶۵ گزارش شده است. این نتیجه نشان می‌دهد که یک بازنمایی غیرعصبی و مبتنی بر ساختار فضایی نیز می‌تواند در برخی شرایط با یک بازیاب تراکمی سبک رقابت کند؛ با این حال، این مقایسه به یک مدل و یک مجموعه داده محدود است و نباید به تعمیم کلی به تمام مدل‌های dense منجر شود.

بنابراین، نتیجه نهایی این پژوهش آن است که Semantic Folding را می‌توان به عنوان یک رویکرد مکمل برای بازیابی اطلاعات در نظر گرفت. نقطه قوت اصلی آن، تبدیل روابط معنایی استخراج‌شده از متن به یک بازنمایی فضایی ساختاریافته است؛ در مقابل، ضعف‌های آن در پوشش موجودیت‌ها و واژگان خارج از واژگان شناخته‌شده، مقیاس‌پذیری در پیکره‌های بزرگ و مسائل نیازمند استدلال چندمرحله‌ای آشکار می‌شود.

۳-۵. دستاوردهای پژوهش

مهم‌ترین دستاوردهای این پژوهش را می‌توان به صورت زیر خلاصه کرد:

۱. **دقت در متون چندزبانه دامنه بشته:** در متون دوزبانه دامنه بسته، رتبه‌بندی مبتنی بر SF به طور معنادار از تطابق واژگانی ۲۵BM و بازیابی متراکم DPR قوی‌تر است.
۲. **برتری بر مدل بازیاب متراکم:** بهترین واریانت SF نه تنها از ۲۵BM بلکه از بازنمایی متراکم یادگرفته شده MiniLM نیز جلوتر است (اجرای `all-MiniLM-L6-v2` روی SciFact)؛ این در حالی است که SF کاملاً بدون ناظر و بدون هیچ داده آموزشی خارج از پیکره کار می‌کند.
۳. **طراحی و پیاده‌سازی یک خط لوله بازتولیدپذیر:** یک pipeline مشخص برای استخراج عبارت، ایجاد فضای معنایی، ساخت fingerprint اسناد و بازیابی طراحی و پیاده‌سازی شد. پیکربندی نهایی نیز به صورت مشخص شامل گزید 64×64 ، UMAP و پارامترهای مشخص بازیابی است.
۴. **ارزیابی Semantic Folding در چندین نوع داده:** روش پیشنهادی روی مجموعه‌هایی با ویژگی‌های متفاوت شامل داده‌های دوزبانه، متون تخصصی، داده‌های علمی، متون روایی و داده‌های موجودیت‌محور ارزیابی شد. این تنوع امکان شناسایی شرایط موفقیت و شکست روش را فراهم کرد.
۵. **ترکیب بازنمایی‌ها:** ادغام اطلاعات واژگانی (BM-IDF-۲۵) با بردارهای معنایی جدید و همچنین ترکیب سیستم‌های بازیابی (SF و SPLADE) در قالب یک معماری hybrid، یک چارچوب نوآورانه ایجاد کرد. به‌ویژه، نشان داده شد که ترکیب ظاهر داده‌های متنی (لیکسیکال) و بردارهای معنایی می‌تواند از هر یک به تنهایی مؤثرتر باشد.

بررسی ترکیب Semantic Folding و SPLADE: نتایج نشان داد که ترکیب بازنمایی فضایی SF با بازنمایی sparse عصبی SPLADE در بسیاری از مجموعه‌ها می‌تواند نسبت به استفاده مستقل از SF عملکرد بهتری ایجاد کند.

۶. **بررسی تطبیقی با BM25:** به عنوان خط مبنای واژگانی اصلی نشان داد که مزیت Semantic Folding وابسته به نوع داده است. در برخی مجموعه‌ها SF یا ترکیب آن با SPLADE برتری داشت، در حالی که در داده‌های موجودیت‌محور و چندمرحله‌ای BM25 همچنان عملکرد بهتری داشت.

۷. **تاکید بر پایداری فضایی:** استفاده از گسترش مکانی و Gaussian smoothing در fingerprintها، امنیت بیشتری در برابر تغییرات کوچک در توزیع معنایی ایجاد نمود و باعث همپوشانی بیشتر fingerprint عبارات نزدیک شد. این نوآوری منجر به بهبود در رتبه‌بندی شد.

۸. **شناسایی مرزهای کاربرد روش:** تحلیل خطاها نشان داد که OOV، نام‌های خاص، تنوع واژگانی بالا، مسائل چند-hop و مقیاس بزرگ پیکره از جمله عواملی هستند که می‌توانند عملکرد Semantic Folding را محدود کنند. بنابراین، یکی از دستاوردهای پژوهش صرفاً گزارش عملکرد بالا نیست، بلکه مشخص کردن شرایطی است که در آن روش فعلی نیازمند توسعه است.

همان‌طور که در بخش ۲-۱۳ اشاره شد، این پژوهش به خلأ عدم بررسی تجربی و مقایسه‌ای کاربرد Semantic Folding در بازیابی چندزبانه دامن‌بسته و نبود مطالعه‌ای که این رویکرد را با روش‌های sparse neural نوین (SPLADE) در قالب یک چارچوب benchmark یکپارچه ترکیب و ارزیابی کرده باشد، می‌پردازد.

۴-۵. محدودیت‌های پژوهش

۱. وابستگی به ساخت فضای معنایی

کیفیت fingerprint نهایی به کیفیت فضای معنایی دوبعدی وابسته است. UMAP باید روابط موجود در فضای اولیه را به شکلی مناسب به فضای دوبعدی منتقل کند و تغییر پیکربندی یا ویژگی‌های پیکره می‌تواند بر نتیجه اثر بگذارد.

۲. مقیاس‌پذیری

ساخت یک فضای معنایی واحد برای پیکره‌های بسیار بزرگ می‌تواند از نظر حافظه و زمان محاسباتی محدودکننده باشد. همچنین، در مرحله بازیابی، مقایسه fingerprint پرس‌وجو با تعداد زیادی از fingerprint‌های اسناد می‌تواند هزینه محاسباتی قابل‌توجهی ایجاد کند. برای مقیاس‌های بزرگ‌تر، استفاده از ساختارهای نمایه‌گذاری و روش‌های ANN^{۳۶} ضروری خواهد بود.

۳. محدودیت در بازیابی میان‌زبانی واقعی

نتایج Mr. TyDi و MIRACL عربی نشان دادند که نمایش فعلی در بازیابی میان‌زبانی گسترده هنوز با روش‌های چندزبانه قوی‌تر فاصله دارد. بنابراین، وجود داده‌های دوزبانه یا ترجمه‌شده را نباید معادل حل کامل cross-lingual retrieval در نظر گرفت.

۴. مسئله موجودیت‌ها و OOV

نام‌های خاص، اصطلاحات تخصصی و واژه‌هایی که پوشش مناسبی در سازوکار استخراج و نگاشت ندارند، ممکن است fingerprint مؤثری تولید نکنند. این مسئله به‌ویژه در مجموعه‌های موجودیت‌محور می‌تواند باعث کاهش عملکرد شود.

۵. محدودیت در مسائل چندمرحله‌ای

^{۳۶} . Approximate Nearest Neighbor

Semantic Folding در شکل فعلی عمدتاً برای رتبه‌بندی مستقیم اسناد طراحی شده است و سازوکار مستقیمی برای ترکیب چند سند و انجام استدلال چند-hop ندارد. عملکرد ضعیف‌تر در مجموعه‌هایی مانند MuSiQue با این محدودیت سازگار است.

۶. محدود بودن مقایسه با روش‌های متراکم

اگرچه مقایسه مستقیم با MiniLM روی SciFact انجام شده است، این مقایسه تنها یک مدل سبک و یک مجموعه داده را شامل می‌شود. بنابراین برای نتیجه‌گیری درباره برتری SF نسبت به روش‌های dense به‌طور کلی، آزمایش‌های گسترده‌تری لازم است.

۷. وابستگی عملکرد fusion به مجموعه داده

نتایج نشان می‌دهد که Linear Fusion و RRF در همه مجموعه‌ها رفتار یکسانی ندارند. بنابراین مقدار α یا انتخاب روش fusion را نمی‌توان بدون توجه به ویژگی‌های داده به‌صورت عمومی بهینه دانست.

۵-۵. پیشنهادها برای کارهای آینده

با توجه به نتایج و محدودیت‌های شناسایی‌شده، مسیرهای زیر برای ادامه پژوهش پیشنهاد می‌شوند:

۱. **توسعه بازیابی cross-lingual:** استفاده از واژه‌نامه‌ها و منابع بین‌زبانی مانند BabelNet یا سازوکارهای نگاشت بین‌زبانی برای ایجاد یک فضای معنایی واقعاً مشترک میان زبان‌ها.
۲. **بهبود پوشش واژگان و موجودیت‌ها:** استفاده از lemmatization و stemming مناسب برای زبان‌های مختلف و توسعه سازوکار دقیق‌تر برای نام‌های خاص و عبارتهای خارج از واژگان.

۳. **بررسی مدل‌های dense قوی‌تر:** مقایسه Semantic Folding با مدل‌هایی مانند multilingual E5، MPNet و سایر مدل‌های dense چندزبانه و انجام آزمون‌های آماری یکسان میان روش‌ها.
۴. **بررسی ابعاد مختلف گرید:** مقایسه گریدهای 64×64 ، 128×128 و ابعاد بزرگ‌تر برای بررسی trade-off میان دقت بازنمایی، مصرف حافظه و هزینه محاسباتی.
۵. **بهینه‌سازی پارامترها:** بررسی سیستماتیک پارامترهایی مانند fusion، پارامترهای UMAP، میزان spreading و پارامترهای sparsification با استفاده از روش‌هایی مانند Grid Search یا Bayesian Optimization.
۶. **افزایش مقیاس‌پذیری بازیابی:** استفاده از روش‌های Approximate Nearest Neighbor مانند HNSW یا سایر ساختارهای نمایه‌گذاری برای کاهش هزینه جست‌وجوی fingerprint اسناد در پیکره‌های بزرگ.
۷. **استدلال چندمرحله‌ای:** ترکیب Semantic Folding با ساختارهای گرافی و روش‌هایی مانند Graph Attention Network برای شناسایی و اتصال چند سند یا مفهوم مرتبط و پشتیبانی از مسائل multi-hop.
۸. **ارزیابی روی حوزه‌های تخصصی بیشتر:** آزمایش روش در دامنه‌های بسته‌ای مانند پزشکی، حقوق، فنی و علمی برای بررسی دقیق‌تر این فرضیه که Semantic Folding در پیکره‌های تخصصی و کنترل‌شده عملکرد مناسب‌تری دارد.
۹. **ارزیابی در pipeline کامل QA:** در ادامه می‌توان Semantic Folding را به یک معماری retrieve-then-read متصل کرد و اثر کیفیت retrieval آن را بر عملکرد پاسخ‌گویی نهایی با استفاده از یک مدل خواننده ارزیابی کرد.
۱۰. **به‌روزرسانی پویا فضای معنایی:** بررسی روش‌هایی برای اضافه‌کردن مفاهیم و اسناد جدید به فضای معنایی، بدون نیاز به بازسازی کامل نقشه معنایی.

۵-۶. جمع‌بندی نهایی فصل

این پژوهش Semantic Folding را به‌عنوان یک بازنمایی فضایی برای بازیابی اطلاعات بررسی و آن را در مجموعه‌ای از شرایط و داده‌های مختلف ارزیابی کرد. نتایج نشان دادند که روش پیشنهادی در برخی داده‌های دوزبانه و تخصصی می‌تواند نسبت به ۲۵BM بهبود ایجاد کند و ترکیب آن با SPLADE در بسیاری از موارد سیگنال بازیابی قوی‌تری فراهم می‌کند.

در نهایت، مهم‌ترین نتیجه پژوهش آن است که بازنمایی فضایی معنایی می‌تواند به‌عنوان یک سیگنال مکمل در سامانه‌های بازیابی مورد استفاده قرار گیرد. توسعه این ایده، به‌ویژه از طریق بهبود نگاشت چندزبانه، افزایش مقیاس‌پذیری، پوشش بهتر موجودیت‌ها و افزودن سازوکار استدلال چندمرحله‌ای، می‌تواند زمینه را برای بررسی گسترده‌تر Semantic Folding در سامانه‌های بازیابی و پاسخ‌گویی به پرسش فراهم کند.

این پژوهش جزء گام‌های اولیه در استفاده از مفاهیم الهام‌گرفته از نوروساینس (مانند Semantic Folding) در بازیابی متن است؛ باشد که ادامه مطالعات در جهت ساده‌سازی، بهبود کارایی و استفاده از نتایج در سیستم‌های QA و توسعه زبان‌های جدید بتواند بینش‌های جدیدی ارائه دهد.

چکیده

(پیش‌نویس – پس از بازبینی نهایی تکمیل می‌شود)

سامانه‌های پاسخگویی خودکار به سوال در حوزه‌های تخصصی با دو محدودیت اساسی روبه‌رو هستند: نیازمندی مدل‌های عصبی بزرگ به منابع پردازشی سنگین و داده‌ی برچسب‌خورده فراوان. این پایان‌نامه کاربرد رویکرد زیست‌الهامی «خوشه‌بندی معنایی» را برای پاسخگویی به سوالات در محیط‌های با دامنه بسته و بر پایه‌ی متون چندزبانه بررسی، ارزیابی و تحلیل می‌کند. در روش پیشنهادی، متون دامنه ابتدا به مفاهیم معنایی مجزا تقسیم و واژگان آن‌ها استخراج می‌شود؛ سپس با الگوریتم‌های کاهش بعد، نقشه‌ی معنایی دوبعدی ساخته شده و هر واژه/قطعه‌متن به اثرانگشت معنایی پراکنده‌ی دودویی نگاشت می‌گردد؛ پاسخگویی با مقایسه‌ی اثرانگشت پرس‌وجو و اسناد انجام می‌شود. برای ارتقای کیفیت، وزن‌دهی TF-IDF مبتنی بر هم‌رخدادی واژه-مفهوم، انتشار فعال‌سازی فضایی و فیوژن خطی با مدل عصبی SPLADE به کار گرفته شد. سامانه روی ۱۴ مجموعه داده استاندارد – از جمله قرآن کریم (۶,۲۳۶ آیه) و پیکره‌ی دوزبانه‌ی عربی-انگلیسی (۴۸۸ قطعه) – ارزیابی شد. نتایج نشان می‌دهد روش پیشنهادی در متون دوزبانه به‌طور معنادار ($p < 0.05$) از ۲۵BM قوی‌تر است، روی قرآن در تمامی معیارها تا سه برابر بهتر عمل می‌کند، در SciFact هم از ۲۵BM و هم از یک مدل بازیابی تراکمی عصبی جلوتر است؛ درحالی‌که سرعت پاسخگویی آن چندین مرتبه بزرگی از مدل‌های تراکمی بالاتر است. این نتایج، خوشه‌بندی معنایی را به گزینه‌ای کارآمد برای سامانه‌های پرسش‌وپاسخ سبک در دامنه‌های تخصصی چندزبانه تبدیل می‌کند.

کلیدواژه‌ها: خوشه‌بندی معنایی، اثرانگشت معنایی، پاسخگویی به سوال، دامنه بسته، متون چندزبانه، بازنمایی پراکنده توزیع‌شده

Abstract

(Draft – to be finalized)

This thesis investigates, evaluates, and analyzes the semantic folding approach for question answering over multilingual texts in closed-domain environments. The pipeline segments domain texts into distinct semantic concepts, builds a two-dimensional semantic map via dimensionality reduction, and represents words and passages as sparse binary semantic fingerprints; answering is performed by comparing query and document fingerprints under TF-IDF weighting, spatial spreading activation, and linear fusion with a neural SPLADE model. The system was evaluated on fourteen standard datasets, including the Quran (6,236 verses) and a parallel Arabic–English corpus (488 passages). Results show statistically significant improvements over BM25 on bilingual corpora ($p < 0.05$), up to 3x better performance on the Quran across all metrics, superior results on SciFact, and response speeds orders of magnitude faster than dense neural models, establishing semantic folding as an efficient alternative for lightweight closed-domain multilingual QA systems.

Keywords: Semantic Folding, Semantic Fingerprint, Question Answering, Closed Domain, Multilingual Texts, Sparse Distributed Representations

پیوست‌ها

پیوست A: مرجع پارامترهای خط لوله

پارامتر	پیش‌فرض	محدودهٔ آزموده	توضیح
grid_size	64	۱۶–۱۲۸ (توان ۲)	ابعاد نقشهٔ معنایی
method	umap	umap/tsne/pca	الگوریتم کاهش بعد
smoothing_sigma	1.5	1.0–2.0	هموارسازی گوسی عبارت/سند
top_percent	10	5–15	تنک‌سازی سند
weighting	idf	uniform/frequency/idf	وزن عبارات در پرس‌وجو
spreading_steps	1	0–2	انتشار فعال‌سازی پرس‌وجو

اندازهٔ pool کاندید	۱۰۰ (فیوژن) / 20–100	۲۰	top_k
وزن SF در فیوژن خطی	0.1–0.7	0.3	splade_alpha
ثابت RRF	—	60	rrf_k
بازتولیدپذیری	—	42	random_seed

منبع تفصیلی: [docs/thesis/thesis_organization_plan.md](#) (پیوست A انگلیسی) و [semantic_folding/parameters_tuning.md](#).

پیوست B: مجموعه داده‌ها

مسیر داده‌های آماده: [data/datasets/<name>/converted/](#).

آداپتورهای پشتیبانی‌شده:

pubmedqa، belebele، popqa، nq_rear، narrativeqa، hotpotqa، beir (nfcorpus، scifact، quora، trec-covid، 2wikimultihopqa، bioasq dbpedia).

پیکره‌های سفارشی قرآن و دوزبانه در [outputs/quran_benchmark](#) و [data/datasets/belebele/corpus_ar_en_488.txt](#).

پیوست C: فرمول معیارهای ارزیابی

- $P@K$ = |مرتبط در K اول| / K
- $R@K$ = |مرتبط در K اول| / |کل مرتبط|
- MRR = میانگین rank/1 نخستین سند مرتبط (• اگر یافت نشود)
- AP = میانگین $P@k$ روی موقعیتهای مرتبط؛ $NDCG@K = DCG/IDCG$
- آزمون معناداری: Wilcoxon signed-rank دوطرفه روی RR هر پرسش؛
McNemar دقیق (دوجمله‌ای شرطی) روی 1@hit

پیوست D: قرارداد اصطلاح‌شناسی

فارسی مصوب متن	English
خوشه‌بندی معنایی	Semantic Folding
اثرانگشت معنایی	Semantic Fingerprint
نقشه معنایی / فضای معنایی	Semantic Map / Space

Sparse Distributed Representation
(SDR)

بازنمایی پراکنده توزیع شده

Corpus

پیکره متنی

Context (corpus unit)

مفهوم معنایی مجزا

Term–Context Matrix

ماتریس واژه–مفهوم

Query

پرس و جو

Co-occurrence

هم‌رخدادی

TF / IDF

فراوانی سندی / معکوس فراوانی سند

Topology-preserving sparsification

تنک‌سازی توپولوژی‌محور

Spreading activation

انتشار فعال‌سازی

Geometric kernel

کرنل هندسی

Linear fusion / Reciprocal Rank
Fusion (RRF)

فیوژن خطی / ادغام رتبه‌ای متقابل

Out-of-Vocabulary (OOV)

واژگان خارج از پیکره

WordNet lexical database

شبکه واژگان

Mean Reciprocal Rank (MRR)

میانگین نرخ بازیابی متقابل

Average Precision (AP)

میانگین دقت

Baseline

خط مبنا

منابع

[1] Y. Wu and J. Wan, "A survey of text classification based on pre-trained language model," **Neurocomputing**, vol. 616, p. 128921, Feb. 2025, doi: 10.1016/j.neucom.2024.128921.

[2] H. Wang, J. Li, H. Wu, E. Hovy, and Y. Sun, "Pre-Trained Language Models and Their Applications," **Engineering**, vol. 25, pp. 51–65, Jun. 2023, doi: 10.1016/j.eng.2022.04.024.

- [3] L. Zhang et al., "A survey on complex factual question answering," **AI Open**, vol. 4, pp. 1–12, 2023, doi: 10.1016/j.aiopen.2022.12.003.
- [4] T. H. Alwaneen, A. M. Azmi, H. A. Aboalsamh, E. Cambria, and A. Hussain, "Arabic question answering system: a survey," **Artificial Intelligence Review**, vol. 55, no. 1, 2022, doi: 10.1007/s10462-021-10031-1.
- [5] P. Upadhyay, R. Agarwal, S. Dhiman, A. Sarkar, and S. Chaturvedi, "A comprehensive survey on answer generation methods using NLP," **Natural Language Processing Journal**, vol. 8, p. 100088, Sep. 2024, doi: 10.1016/j.nlp.2024.100088.
- [6] R. Mao et al., "A survey on semantic processing techniques," **Information Fusion**, vol. 101, p. 101988, Jan. 2024, doi: 10.1016/j.inffus.2023.101988.
- [7] Z. Lin et al., "Medical visual question answering: A survey," **Artificial Intelligence in Medicine**, vol. 143, p. 102611, Sep. 2023, doi: 10.1016/j.artmed.2023.102611.
- [8] N. Chen, X. Chen, and J. Pang, "A multilingual dataset of COVID-19 vaccination attitudes on Twitter," **Data in Brief**, vol. 44, p. 108503, Oct. 2022, doi: 10.1016/j.dib.2022.108503.
- [9] C. Rohlf, "Generalization in neural networks: A broad survey," **Neurocomputing**, vol. 611, p. 128701, Jan. 2025, doi: 10.1016/j.neucom.2024.128701.

- [10] J. Hawkins and S. Ahmad, "Why Neurons Have Thousands of Synapses, a Theory of Sequence Memory in Neocortex," **Frontiers in Neural Circuits**, vol. 10, 2016, doi: 10.3389/fncir.2016.00023.
- [11] S. C. Bhatnagar, G. T. Mandybur, H. W. Buckingham, and O. J. Andy, "Language representation in the human brain: Evidence from cortical mapping," **Brain and Language**, vol. 74, no. 2, 2000, doi: 10.1006/brln.2000.2339.
- [12] B. M. Lake, T. D. Ullman, J. B. Tenenbaum, and S. J. Gershman, "Building machines that learn and think like people," **Behavioral and Brain Sciences**, vol. 40, p. e253, Nov. 2017, doi: 10.1017/S0140525X16001837.
- [13] F. D. S. Webber, "Semantic Folding Theory And its Application in Semantic Fingerprinting," arXiv preprint arXiv:1511.08855, Nov. 2015, doi: 10.48550/arXiv.1511.08855.
- [14] H. Lu, L. Wang, X. Ma, J. Cheng, and M. Zhou, "A survey of graph neural networks and their industrial applications," **Neurocomputing**, vol. 614, p. 128761, Jan. 2025, doi: 10.1016/j.neucom.2024.128761.
- [15] J. P.J. and B. C. Kooor, "Video Question Answering: A survey of the state-of-the-art," **Journal of Visual Communication and Image Representation**, vol. 105, p. 104320, Dec. 2024, doi: 10.1016/j.jvcir.2024.104320.

- [16] K. Cai et al., "An Evaluative Baseline for Sentence-Level Semantic Division," **Machine Learning and Knowledge Extraction**, vol. 6, no. 1, 2024, doi: 10.3390/make6010003.
- [17] M. Yasunaga, H. Ren, A. Bosselut, P. Liang, and J. Leskovec, "QA-GNN: Reasoning with Language Models and Knowledge Graphs for Question Answering," in **Proc. NAACL-HLT**, Apr. 2021, doi: 10.18653/v1/2021.naacl-main.45.
- [18] J. Heyder, "Hierarchical Temporal Memory Software Agent: In the light of general artificial intelligence criteria," *Digitala Vetenskapliga Arkivet*, 2018.
- [19] W. B. Levy and R. A. Baxter, "Growing dendrites enhance a neuron's computational power and memory capacity," **Neural Networks**, vol. 164, 2023, doi: 10.1016/j.neunet.2023.04.033.
- [20] C. Wang et al., "Enriching query semantics for code search with reinforcement learning," **Neural Networks**, vol. 145, pp. 22–32, Jan. 2022, doi: 10.1016/j.neunet.2021.09.025.
- [21] P. Anderson et al., "Bottom-Up and Top-Down Attention for Image Captioning and Visual Question Answering," in **Proc. IEEE CVPR**, 2018, doi: 10.1109/CVPR.2018.00636.
- [22] T. Hernández-Del-Toro, F. Martínez-Santiago, and A. Montejo-Ráez, "Assessing classifier's performance," in **Biosignal Processing and*

Classification Using Computational Learning and Intelligence*, 2021, pp. 131–149, doi: 10.1016/B978-0-12-820125-1.00018-X.

[23] M. Beck, "Evaluating QA: Metrics, Predictions, and the Null Response," FastForward Labs, 2020. [Online]. Available: https://qa.fastforwardlabs.com/no%20answer/null%20threshold/bert/distilbert/exact%20match/f1/robust%20predictions/2020/06/09/Evaluating_BERT_on_SQuAD.html

[24] M. Taifi, "MRR vs MAP vs NDCG: Rank-Aware Evaluation Metrics And When To Use Them," Medium – The Startup. [Online]. Available: <https://medium.com/swlh/rank-aware-recsys-evaluation-metrics-5191bba16832>

[25] S. Santhosh, "Understanding BLEU and ROUGE score for NLP evaluation," Medium. [Online]. Available: <https://medium.com/@sthanikamsanthosh1994/understanding-bleu-and-rouge-score-for-nlp-evaluation-1ab334ecadcb>

[26] P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang, "SQuAD: 100,000+ questions for machine comprehension of text," in *Proc. EMNLP*, 2016, doi: 10.18653/v1/d16-1264.

[27] T. Kwiatkowski et al., "Natural Questions: A Benchmark for Question Answering Research," *Transactions of the Association for Computational Linguistics*, vol. 7, 2019, doi: 10.1162/tacL_a_00276.

- [28] T. Nguyen et al., "MS MARCO: A human generated MACHine reading COMprehension dataset," in **CEUR Workshop Proceedings**, 2016.
- [29] M. Artetxe, S. Ruder, and D. Yogatama, "On the cross-lingual transferability of monolingual representations," in **Proc. ACL**, 2020, doi: 10.18653/v1/2020.acl-main.421.
- [30] C. Antoniou and N. Bassiliades, "A survey on semantic question answering systems," **The Knowledge Engineering Review**, 2022, doi: 10.1017/S0269888921000138.
- [31] S. Anbaraki, "Evaluating and predicting the quality of answers factors in the research gate's question and answer system: A case study of the thematic domain of knowledge management," **Journal of Information Processing and Management**, vol. 36, no. 3, 2021, doi: 10.52547/jipm.36.3.709.
- [32] L. P. Acharya, "A Systematic Approach for Automatically Answering General-Purpose Objective and Subjective Questions," Ph.D. dissertation, Florida Institute of Technology, 2019.
- [33] A. Allam, A. Mohamed, N. Allam, and M. H. Haggag, "The Question Answering Systems: A Survey," **International Journal of Research and Reviews in Information Sciences**, no. October, 2016.
- [34] K. J. Hole and S. Ahmad, "A thousand brains: toward biologically constrained AI," **SN Applied Sciences**, vol. 3, no. 8, p. 743, 2021, doi: 10.1007/s42452-021-04715-0.

- [35] M. W. Mathis, "The neocortical column as a universal template for perception and world-model learning," **Nature Reviews Neuroscience**, 2023, doi: 10.1038/s41583-022-00658-6.
- [36] Cortical.io, "Semantic Folding Benchmark." [Online]. Available: <https://www.cortical.io/science/difference-with-other-approaches/>
- [37] O. Khattab and A. Zahran, "SPLADE: Sparse Lexical and Expansion Model for First Stage Ranking," in **Proc. ICTIR**, 2020, doi: 10.1145/3404835.3463098.
- [38] T. Formal, C. Lassance, B. Piwowarski, and S. Clinchant, "SPLADE v2: Sparse Lexical and Expansion Model for Information Retrieval," arXiv preprint arXiv:2109.10086, 2021.
- [39] S. Robertson and H. Zaragoza, "The Probabilistic Relevance Framework: BM25 and Beyond," **Foundations and Trends in Information Retrieval**, vol. 3, no. 4, pp. 333–389, 2009, doi: 10.1561/15000000019.
- [40] H. Trivedi, N. Balasubramanian, T. Khot, and A. Sabharwal, "MuSiQue: Multihop Questions via Single-hop Question Composition," **Transactions of the Association for Computational Linguistics**, vol. 10, 2022, doi: 10.1162/tacl_a_00466.
- [41] N. Thakur, N. Reimers, A. Rüclé, A. Srivastava, and I. Gurevych, "BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models," in **Proc. NeurIPS Datasets and Benchmarks Track**, 2021, arXiv:2104.08663.

- [42] B. J. Gutiérrez, N. McNeal, B. Washington, Y. Chen, L. Li, H. Sun, and Y. Su, "HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models," in **Proc. NeurIPS**, 2024, arXiv:2405.14831.
- [43] L. van der Maaten and G. Hinton, "Visualizing Data using t-SNE," **Journal of Machine Learning Research**, vol. 9, pp. 2579–2605, 2008.
- [44] L. McInnes, J. Healy, and J. Melville, "UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction," arXiv preprint arXiv:1802.03426, 2018.
- [45] C. Fellbaum, Ed., **WordNet: An Electronic Lexical Database**. Cambridge, MA: MIT Press, 1998.
- [46] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in **Proc. NAACL-HLT**, 2019, doi: 10.18653/v1/N19-1423.
- [47] T. Mikolov, I. Sutskever, K. Chen, G. S. Corrado, and J. Dean, "Distributed Representations of Words and Phrases and their Compositionality," in **Advances in Neural Information Processing Systems (NeurIPS)**, 2013.
- [48] J. Pennington, R. Socher, and C. D. Manning, "GloVe: Global Vectors for Word Representation," in **Proc. EMNLP**, 2014, doi: 10.3115/v1/D14-1162.
- [49] P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov, "Enriching Word Vectors with Subword Information," **Transactions of the Association for Computational Linguistics**, vol. 5, pp. 135–146, 2017, doi: 10.1162/tacl_a_00051.

[50] H. Ritter and T. Kohonen, "Self-organizing semantic maps," **Biological Cybernetics**, vol. 61, no. 4, pp. 241–254, 1989, doi: 10.1007/BF00200253.

[51] امیرمحمد مشهدیزاده، «کاربرد روش خوشه‌بندی معنایی برای پرسش و پاسخ با جواب‌های چندگزینه‌ای»، پایان‌نامه کارشناسی ارشد، دانشکده مهندسی برق و کامپیوتر، دانشگاه تهران، شهریور ۱۴۰۳.

[52] D. Karlsson, "Using semantic folding with TextRank for automatic summarization," Independent thesis, University of Skövde, 2017.

[53] G. Rydholm, "Using neurobiological frameworks for anomaly detection in system log streams," Independent thesis, University of Skövde, 2018.

[54] T. Soisoonthorn, H. Unger, and W. Maliyaem, "Thai Word Segmentation with a Brain-Inspired Sparse Distributed Representations Learning Memory," **Computational Intelligence and Neuroscience**, vol. 2023, p. 8592214, 2023, doi: 10.1155/2023/8592214.

[55] L. Bandarkar et al., "The Belebele Benchmark: A Parallel Reading Comprehension Dataset in 122 Language Variants," in **Proc. ACL**, 2024, doi: 10.18653/v1/2024.acl-long.469.

[56] Q. Jin et al., "PubMedQA: A Dataset for Biomedical Research Question Answering," in **Proc. EMNLP-IJCNLP**, 2019, doi: 10.18653/v1/D19-1259.

[57] P. Mallen et al., "When Not to Trust Language Models: Investigating Effectiveness of Parametric and Non-Parametric Memories," in **Proc. ACL**, 2023, doi: 10.18653/v1/2023.acl-long.546.

- [58] T. Kočiský et al., "The NarrativeQA Reading Comprehension Challenge," **Transactions of the Association for Computational Linguistics**, vol. 6, pp. 322–338, 2018, doi: 10.1162/tacl_a_00023.
- [59] J. Clark, D. Garrette, I. Turc, and J. Wieting, "MR. TyDi: A Multi-lingual Typed Natural Language Baseline Dataset," in **Proc. ACL-IJCNLP**, 2021, doi: 10.18653/v1/2021.acl-long.563.
- [60] X. Zhang et al., "MIRACL: A Multilingual Retrieval Dataset Covering 73 Languages," in **Proc. VLDB Endowment**, vol. 17, no. 10, 2024, arXiv:2210.09984.
- [61] V. Karpukhin, O. Oguz, S. Min, P. Lewis, L. Zettlemoyer, and W.-t. Yih, "Dense Passage Retrieval for Open-Domain Question Answering," in **Proc. EMNLP**, 2020, doi: 10.18653/v1/2020.emnlp-main.550.
- [62] A. Asai, J. Kasai, J. Clark, K. Lee, E. Choi, and Y. Tsvetkov, "XOR QA: Cross-lingual Open-Retrieval Question Answering," in **Proc. NAACL-HLT**, 2021, doi: 10.18653/v1/2021.naacl-main.46.
- [63] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods," in **Proc. SIGIR**, 2009, doi: 10.1145/1571941.1572114.